Hypothesentest (warum?)

Umsatz pro Kunde : 200 €/Monat (aus langjähriger Erfahrung)

- Stichprobe von Kunden : Ø Umsatz
  "Status quo"

$$\bar{X} \overset{a}{\sim} N\left(200; \frac{\sigma^2}{n}\right)$$

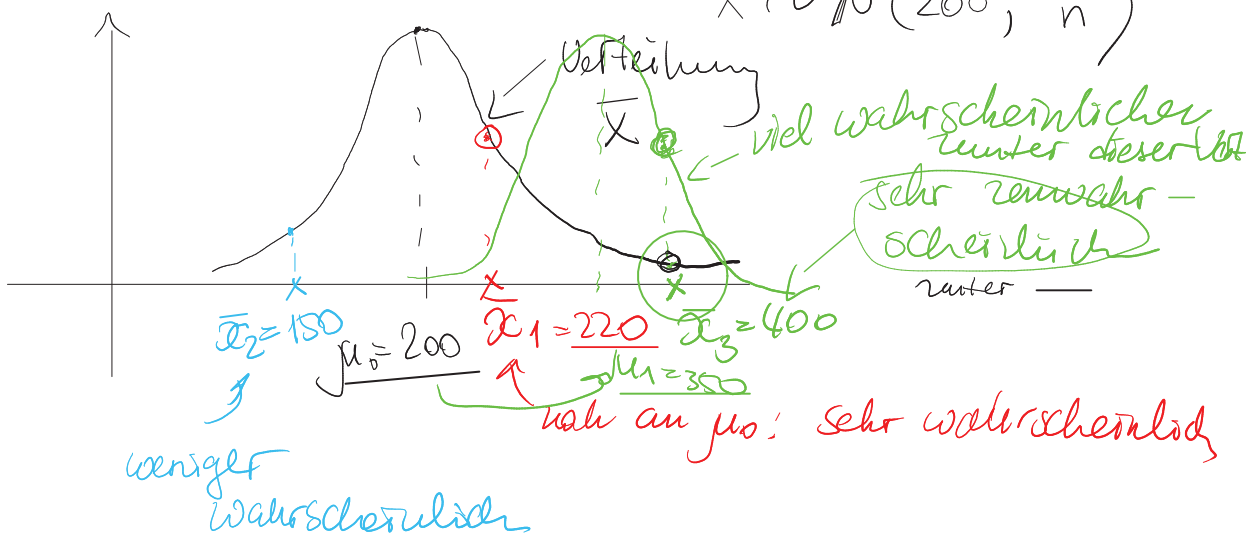

- Rabattaktion : an einer Zufallsauswahl der Kunden "ausprobieren"

  ↳ $\bar{X}$.

  → $\bar{x}_1$ hat die Umsatzsteigerung wirklich stattgefunden oder ist im Status Quo?

  → $\bar{x}_3$ – große Abweichung zu μ_0
  → statistisch gesehen könnte eine andere Verteilung mit größerem μ relevanter sein

2.5 Testen von Hypothesen

2.5.1 Grundidee des statistischen Testens

- Bisher: Statistische Schlüsse auf Basis von numerischen Schätzern (Punktschätzer und Intervallschätzer).
- Nicht alle Schätzprobleme sind numerischer Natur:
  - Ist der Angeklagte zurechnungsfähig oder nicht?
  - Soll das neue Medikament zugelassen werden oder nicht?
- **Entscheidungsproblem**:
  - Ist die Normalverteilung ein zulässiges Modell für die Tagesrenditen einer Aktie?
- **Testverfahren**:
  - Differenzieren **möglicher Schlussfolgerungen** eines Experiments (**Hypothesen**);
  - **Entscheidung** für eine der Möglichkeiten mit Werkzeugen der Wahrscheinlichkeitstheorie.
- Im Fall zweier möglicher, einander ausschließender Schlussfolgerungen:
  - **Nullhypothese H_0** ← "Status Quo"
    - wird nicht abgelehnt, solange es nicht genügend Evidenz gibt, sie zu widerlegen ("Unschuldsvermutung")
  - **Alternativhypothese H_1** ← "was man zeigen will"
    - wird akzeptiert, wenn "ausreichend" Evidenz gegen die Nullhypothese spricht
- Mögliche Schlussfolgerungen und Konsequenzen:

Entscheidung

Wirklichkeit	H_0 nicht abgelehnt	H_0 abgelehnt
H_0 ist richtig	Entscheidung richtig	Entscheidung falsch (Fehler 1. Art)
H_0 ist falsch	Entscheidung falsch (Fehler 2. Art)	Entscheidung richtig

- Ziel: Entscheidungs**strategie** so, dass Fehler 1. Art und 2. Art möglichst klein

Beispiel 2.5.1. *Rabattaktion*

- *Sie wollen überpüfen, ob eine Rabattaktion zur Steigerung des Umsatzes beigetragen hat.*
- *In einer Pilotstudie haben* 30 *zufällig ausgewählte Kunden den Rabatt angeboten bekommen.*
- *Die restlichen Kunden haben keinen Rabatt bekommen und haben einen Durchschnittsumsatz von* 25 *EUR mit einer Standardabweichung von* $\sigma = 2{,}4$.
- *Die Rabattgruppe hat einen durchschnittlichen Umsatz von* $\overline{y} = 26{,}3$ *EUR.*
- *Möglichkeiten:*

	Konsequenz falscher Entscheidung
Aktion wirkungsvoll	*Annahme, dass die Steigung der Umsätze zufällig ist ⇒ Firma gibt möglicherweise eine wirkungsvolle Kampagne auf.*
Aktion nicht wirkungsvoll	*Annahme, dass Steigung der Umsätze auf die Aktion zurückführbar ist ⇒ Kosten für eine sinnlose Rabattaktion.*

Wirklichkeit

nicht ausrollen obwohl Aktion wirkungsvoll

Aktion ausrollen obwohl keine Wirkung.

- *Wahrscheinlichkeitstheoretische Formulierung des Problems:*
  - *Stichprobe* $Y_1, Y_2, \ldots, Y_{30}$*: Umsatz von Pilotkunden.*
  - *Annahme:* $(Y_i)_{i=1,\ldots,30}$ *sind unabhängige Wiederholungen einer normalverteilten Zufallsvariable* Y *mit unbekanntem Erwartungswert* μ *und bekannter Standardabweichung* $\sigma = 2{,}4$.
  - *Folgerung: Erwartungswert* $\overline{Y}$ *der* 30 *Realisierungen ist normalverteilte Zufallsvariable mit Erwartungswert* μ *und Standardabweichung* $\sigma/\sqrt{30}$.

$\overline{Y} \sim N\left(\mu; \frac{\sigma^2}{n}\right)$
$(n = 30)$

- *Aufstellen der Hypothesen:*
  - H_0*:* $\mu = 25{,}0$ *(Aktion nicht wirkungsvoll,"Status Quo")*
  - H_1*:* $\mu > 25{,}0$ *(Aktion wirkungsvoll)*
- *Ziel: Finde* $\overline{y}^*$*, ab dem* H_0 *abzulehnen ist*

kritischer Wert

Werte führen zu der Ablehnung von Status-Quo

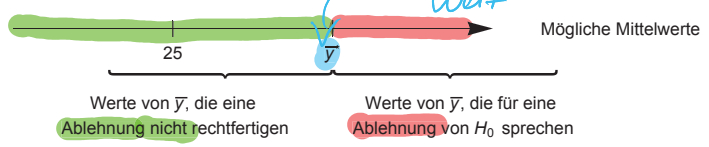

führen nicht zu der Ablehnung

- H_0 *akzeptieren, wenn* $\overline{y}$ *nur wenig größer als* 25. H_0 *ablehnen, wenn* $\overline{y}$ *deutlich größer, bspw.* 35.0. ⇝ *Finde kritisches* $\boxed{\overline{y}^*}$*, ab dem* H_0 *abgelehnt wird.*
- *Wahl von* $\overline{y}^*$ *mithilfe wahrscheinlichkeitstheoretischer Überlegungen*

- *1. Versuch:* $\overline{y}^* = 25{,}25$
- *Dann wird* H_0 *mit einer Wahrscheinlichkeit von* 28% *abgelehnt, unter der Annahme das* H_0 *zutrifft (Fehler 1. Art):*

$$\mathbb{P}(H_0 \text{ ablehnen}|H_0 \text{ ist wahr}) = \mathbb{P}(\overline{Y} \geq 25{,}25|\mu = 25{,}0) = \mathbb{P}\left(\frac{\overline{Y} - 25{,}0}{2{,}4/\sqrt{30}} \geq \frac{25{,}25 - 25{,}0}{2{,}4/\sqrt{30}}\right)$$
$$= 1 - \mathrm{N}(0{,}57) = 0{,}2843$$

$\rightsquigarrow$ *Wahrscheinlichkeit eines Fehlers 1. Art zu hoch*

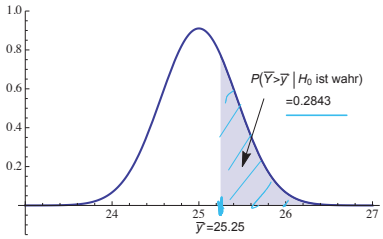

- *2. Versuch:* $\overline{y}^* = 26{,}5$
- H_0 *wird "nur" mit Wahrscheinlichkeit* $0{,}03\%$ *falsch abgelehnt:*

$$\mathbb{P}(H_0 \text{ ablehnen}|H_0 \text{ ist wahr}) = \mathbb{P}(\overline{Y} \geq 26{,}50|\mu = 25{,}0) = 0{,}0003.$$

$\rightsquigarrow$ *Wahrscheinlichkeit eines Fehlers 1. Art sehr klein (gut!)*

- **Aber**: *Wahrscheinlichkeit eines Fehlers 2. Art möglicherweise hoch (Nicht-Ablehnen von* H_0*, wenn* H_0 *falsch)*

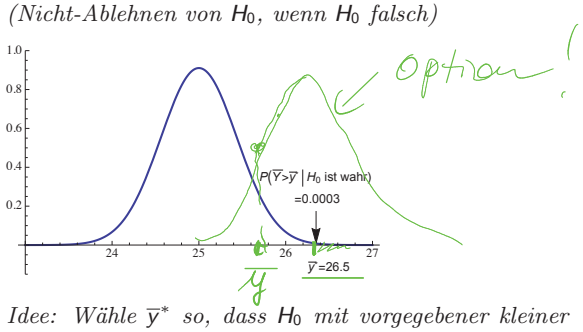

- *Idee: Wähle* $\overline{y}^*$ *so, dass* H_0 *mit vorgegebener kleiner Wahrscheinlichkeit* α*, z.B.* $\alpha = 0{,}05$*, (falsch) abgelehnt wird:*

Irrtumswahrscheinlichkeit

$$\mathbb{P}(H_0 \text{ ablehnen}|H_0 \text{ ist wahr}) = \mathbb{P}(\overline{Y} \geq \overline{y}^*|\mu = 25{,}0) = 0{,}05.$$
$$= 1 - \mathbb{P}(\overline{Y} \leq \overline{y}^*)$$

- *Dies ergibt* $\boxed{\overline{y}^* = 25{,}718.}$
- *Fazit: Ablehnen der Hypothese, Aktion habe keine Wirkung, da* $\overline{Y} = 26{,}3 \geq 25{,}718.$

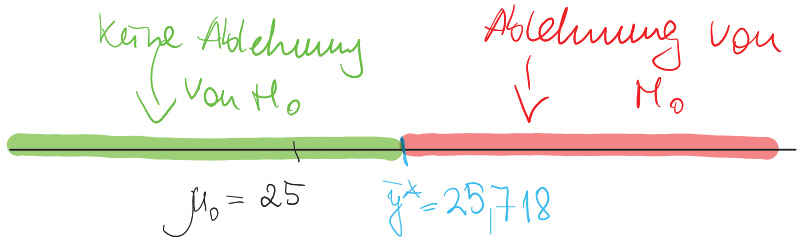

- *Beachte: Es handelt sich nicht um einen Beweis, H_0 sei falsch.*
- Hohe Evidenz gegen H_0 *führt zur Ablehnung.*
- *Denn: Falls der wahre Erwartungswert* 25,0 *ist, werden Stichproben mit* $\overline{Y} \geq$ 25,718 *nur mit einer Wahrscheinlichkeit von* 5% *auftreten.*
- **Entscheidungsregel**: *Lehne H_0 ab, falls* $\overline{Y} \geq$ 25,718.

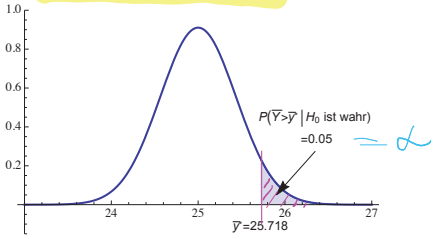

- *Wir sind noch nicht ganz fertig...*
- *Folgende Kennzahl ist noch interessant:*
  Unter der Annahme, dass H_0 gilt, wie hoch ist – bei Wiederholung des Experiments – die Wahrscheinlichkeit, ein mindestens so extremes Ergebnis wie das beobachtete zu erhalten?
- *Diese Kennzahl heißt* **p-Wert** *und wird wie folgt berechnet:*

$$\mathbb{P}(\overline{Y}_{Wdhl.} \geq \overline{y} \mid H_0) = \mathbb{P}(\overline{Y}_{Wdhl.} \geq 26{,}3 \mid \mu = 25{,}0) = 0{,}0015 = \underline{0{,}15\%.}$$

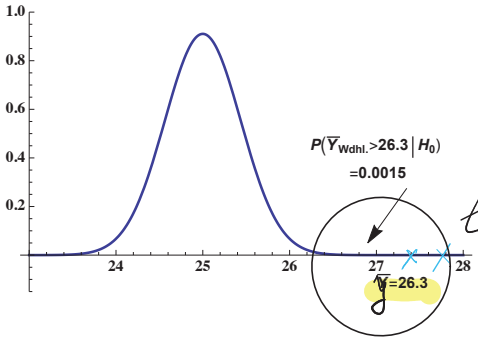

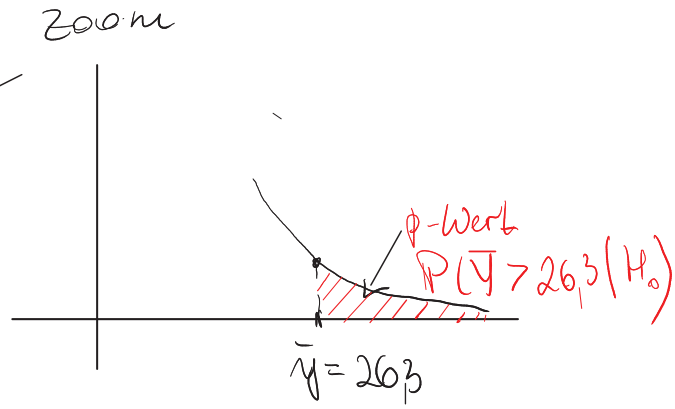

2.5.2 Der Binomialtest

Beispiel 2.5.2. *Qualitätsprüfung*

- *Vor Auslieferung einer Warenpartie soll die Qualität auf Basis einer Stichprobe geprüft werden.*
- **Attributenprüfung**: *Bei jedem produzierten Stück wird festgehalten, ob es den Qualitätsstandards genügt ("gut") oder nicht ("schlecht").*
- *Gezählt werden die schlechten Stücke – die Anzahl kann als binomialverteilt mit Parameter p angenommen werden (Ausschussanteil).*
  - *Ein Kunde akzeptiert Warenlieferung, falls Ausschussanteil unter 10%.*
  - *Aus Kostengründen kann nicht die gesamte Lieferung überprüft werden.*
  - *Stichprobe von $n = 1000$ Stücken ergibt 102 Ausschussstücke.*
  - *Ist der Unterschied von 10,2% zu 10% gering genug, um daraus schließen zu können, der tatsächliche Anteil sei kleiner als 10%?*

die Qualitätsprüfung anhand der Stichprob kann die Vermutung bestätigen oder widerlegen.

Der exakte Binomialtest

- Allgemein: Seien $X_1, \dots, X_n$ Stichprobenvariablen mit

$$X_i = \begin{cases} 1, & \text{falls } A \text{ eintritt,} \\ 0, & \text{falls } \overline{A} \text{ eintritt.} \end{cases}$$

X "Anzahl der schlechten Stücke"
H_0: $X \sim B(n=1000, p=0{,}1)$

- Die Wahrscheinlichkeit des Ereignisses $\{X_i = 1\}$ sei p (unbekannt!).
- **Statistisches Testproblem**:
  - Die interessierende Hypothese wird als **Alternativhypothese** H_1 formuliert.
  - Sie muss sich gegen die **Nullhypothese** H_0 durchsetzen.
- Bei einem statistischen Test geht es darum zu entscheiden, ob das beobachtete Verhalten auch für die Grundgesamtheit gilt.
- **Prüfgröße**, **Teststatistik**:

Anzahl Anteil

$$\text{Anzahl } X = \sum_{i=1}^{n} X_i \text{ bzw. Anteil } \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

- Ist die Annahme unabhängiger Ziehungen gerechtfertigt, so ist die Anzahl $X = \sum_{i=1}^{n} X_i$ binomialverteilt mit Parametern n und p.
- Wie groß muss X sein, so dass es extrem unwahrscheinlich ist, dass X noch unter H_0 zustande gekommen ist?
- Präzisiere zunächst "extrem unwahrscheinlich"; übliche Werte 0,01; 0,05; 0,1, bezeichnet als **Signifikanzniveau** mit Symbol α.

- Daraus ergibt sich der **Ablehnungsbereich**, also diejenigen Werte des Zufallsexperiment,
  - die in Richtung der Alternative weisen, und
  - deren W'keit kleiner als α ist.

116

Beispiel 2.5.3. *Qualitätsprüfung, siehe 2.5.2*

x_i	*101*	*102*	*105*	*110*	*115*	*120*	*125*
$\mathbb{P}(X > x_i)$	*0.432*	*0.391*	*0.278*	*0.135*	*0.053*	*0.017*	*0.005*

leicht größer als $\alpha = 0{,}05$

Wähle den kritischen Wert so, dass die Wkt $\mathbb{P}(X > x^*) \leq \alpha$

$\hookrightarrow$ $x^* = 116$

Beispiel 2.5.4. *Geburten*

- *Die Vermutung, dass es mehr Jungengeburten als Mädchengeburten gibt, soll anhand einer Stichprobe von* 10 *Geburten überprüft werden.*
- *Alternativhypothese* H_1*:* $p > 0{,}5$*; Nullhypothese* H_0*:* $p = 0{,}5$. gemeint ist "$\leq$"
- **Prüfgröße**, **Teststatistik**: *Anzahl* $X = \sum_{i=1}^{10} X_i$
- *Die Verteilung unter der Nullhypothese ist bekannt:* $X \sim B(10; 0{,}5)$.
- *Wahrscheinlichkeiten:*

x	0	1	2	3	4	5	6	7	8	9	10
$\mathbb{P}(X = x)$	0.001	0.01	0.044	0.117	0.205	0.246	0.205	0.117	0.044	0.01	0.001

$\mathbb{P}(X \geq x)$ $\quad$ $0{,}055 < \alpha$

- *Wahl des Ablehnungsbereichs bei Signifikanzniveau* $\alpha = 0{,}1$*:*
  - *weist in Richtung der Alternative, also größer als fünf,*
  - *tritt unter* H_0 *höchstens mit W'keit* $\alpha = 0{,}1$ *ein.*
- *Es ergibt sich die Menge* $\{8,9,10\}$ *als Ablehnungsbereich, da* $\mathbb{P}(X \geq 8) = 0{,}055 < 0{,}1$ *und* $\mathbb{P}(X \geq 7) = 0{,}172 > 0{,}1$.
- *In Worten: Acht oder mehr Jungengeburten können unter der Annahme, dass Mädchen- und Jungengeburten gleichwahrscheinlich sind, nur mit einer W'keit von höchstens* 10% *eintreten.*

Der approximative Binomialtest

- Für großes n kann die Binomialverteilung durch die Normalverteilung approximiert werden $\rightsquigarrow$ **approximativer Binomialtest**.

Aus der Binomialverteilung

- Sei $X = \sum_{i=1}^{n} X_i \sim B(n,p)$ für np und $n(1-p)$ ausreichend groß. Dann gilt:

$$X \overset{\text{approx.}}{\sim} \mathrm{N}(np, np(1-p)) \quad \text{bzw.}$$

$E(X) = n \cdot p$, $Var(X) = np(1-p)$

Prüfstatistik $\longrightarrow$

$$\boxed{Z = \frac{X - np}{\sqrt{np(1-p)}}} \overset{\text{approx.}}{\sim} \mathrm{N}(0,1).$$

- Daumenregel für "ausreichend groß": $np > 5$ und $n(1-p) > 5$.

Beispiel 2.5.5. *Qualitätsprüfung, siehe 2.5.2, Seite 84*

- *Formulierung des Testproblems, ob Ausschußanteil größer als* 0,1*:*

"$\leq$" $\longrightarrow$ "$=$"

$$H_0 : \boxed{p = 0{,}1} \quad \text{gegen} \quad H_1 : p > 0{,}1.$$

- *Bei einer Stichprobengröße von* $n = 1000$ *werden* $X = 102$ *Ausschußstücke beobachtet.*
- *Approximation:* $Z = \dfrac{X - 1000 \cdot 0{,}1}{\sqrt{1000 \cdot 0{,}1(1-0{,}1)}} \overset{a}{\sim} N(0;1)$
- *Ablehnungsbereich* $C = \{z : z > \mathrm{N}_{1-\alpha}\}$, *wobei* $\mathrm{N}_{1-\alpha}$ *das* $(1-\alpha)$*-Quantil der Standardnormalverteilung bezeichnet (auch als* **kritischer Wert** *bezeichnet).*
- *Dichtefunktion unter* H_0*:*

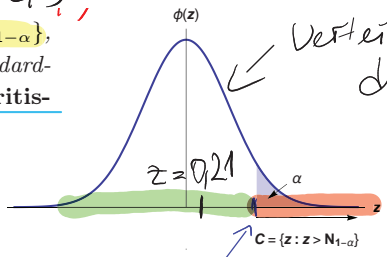

Verteilung unter der H_0.

- *Sei* $\alpha = 0{,}05$, *also kritischer Wert* $\mathrm{N}_{1-\alpha} = \mathrm{N}_{0{,}95} = 1{,}64$.

$N_{1-\alpha} = 1{,}64$

- *Prüfgröße:* $z = \dfrac{102 - 1000 \cdot 0{,}1}{\sqrt{1000 \cdot 0{,}1(1-0{,}1)}} = \dfrac{102 - 100}{\sqrt{90}} = \underline{0{,}21}$

Da $z \not> 1{,}64$ kann $H_0 \longrightarrow$ nicht ablehnen.

- *In Worten: Die Anzahl von* 102 *fehlerhaften Stücken in der Stichprobe lässt nicht den Schluss zu, dass der Anteil fehlerhafter Stücke in der* gesamten *Partie über* 10% *liegt.*
- *Alternativ: Wieviele Stücke* x^* *würden zu einer Ablehnung von* H_0 *führen? Auflösen nach* x^* *von*

$$\frac{x^* - np}{\sqrt{np(1-p)}} > \mathrm{N}_{1-\alpha},$$

ergibt

$$x^* > \sqrt{np(1-p)} \cdot N_{1-\alpha} + np =$$

$$= \sqrt{90} \cdot 1{,}64 + 100 = \underline{115{,}58}$$

Ab 116 fehlerhafte Stücke würde die Nullhypothese ablehnen.