ZGS

Stetiges Renditemodell

- Zufallsvariable: X = Monatsrendite einer Aktie (in %)
- Dichtefunktion:

$$f(x) = \begin{cases} 1-|x|, & \text{für } -1 \le x \le 1 \\ 0, & \text{sonst} \end{cases}$$

keine Normalverteilung

- Ereignis: $\{X > 0\}$ = "positive Rendite"
- Wahrscheinlichkeit: $\mathbb{P}(X > 0) = \int_0^1 (1-|x|)\,dx$ = Fläche des Dreiecks $= \frac{1}{2}$

Stichproben

Anzahl von Stichproben:

301

Mon 1	Mon 2	Mon 3	Mon 4	Mon 5	Mon 6	Mittelwert
-0.24	0.11	0.11	0.36	0.12	-0.30	0.03
0.35	-0.79	0.02	-0.32	-0.08	0.23	-0.10
-0.10	0.40	0.74	0.30	-0.36	0.67	0.28
0.52	-0.73	0.37	-0.46	0.04	-0.32	-0.10
0.65	-0.31	-0.02	0.63	-0.64	0.29	0.10
-0.70	0.49	0.53	-0.68	0.70	-0.28	0.01

Verteilung mittlerer Rendite | Wahrscheinlichkeit für positive Rendite

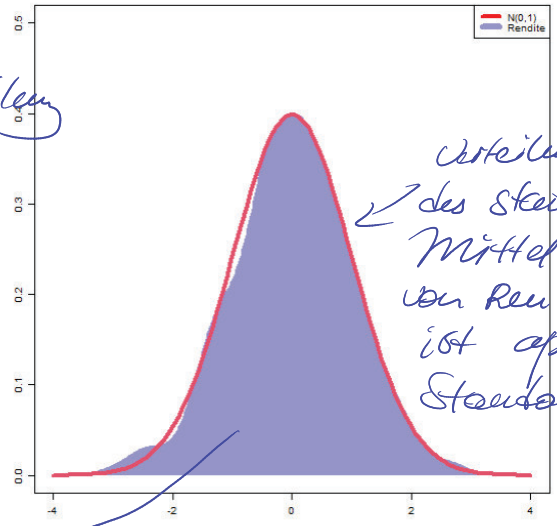

Verteilung des standardisierten Mittelwertes von Rendite ist approx. Standardnormal

GGZ

Stetiges Renditemodell

- Zufallsvariable: X = Monatsrendite einer Aktie (in %)
- Dichtefunktion:

$$f(x) = \begin{cases} 1-|x|, & \text{für } -1 \le x \le 1 \\ 0, & \text{sonst} \end{cases}$$

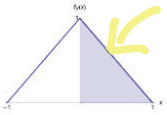

- Ereignis: $\{X > 0\}$ = "positive Rendite"
- Wahrscheinlichkeit: $\mathbb{P}(X > 0) = \int_0^1 (1-|x|)\,dx$ = Fläche des Dreiecks $= \frac{1}{2}$

Stichproben

Anzahl von Stichproben:

301

Mon 1	Mon 2	Mon 3	Mon 4	Mon 5	Mon 6	Mittelwert
-0.24	0.11	0.11	0.36	0.12	-0.30	0.03
0.35	-0.79	0.02	-0.32	-0.08	0.23	-0.10
-0.10	0.40	0.74	0.30	-0.36	0.67	0.28
0.52	-0.73	0.37	-0.46	0.04	-0.32	-0.10
0.65	-0.31	-0.02	0.63	-0.64	0.29	0.10
-0.70	0.49	0.53	-0.68	0.70	-0.28	0.01

Verteilung mittlerer Rendite | Wahrscheinlichkeit für positive Rendite

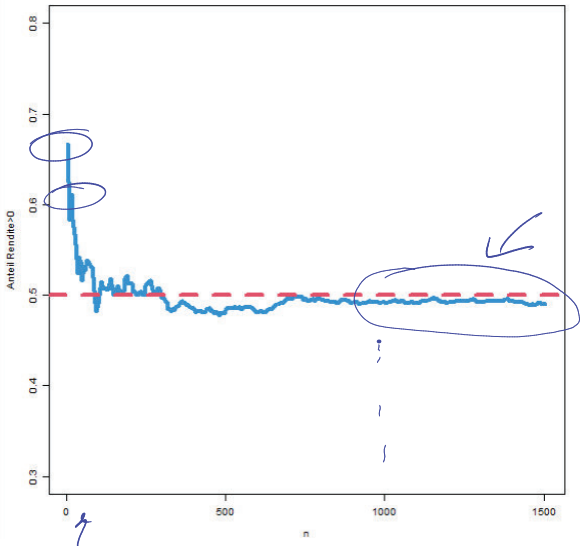

kleine Stichprobe: Schätzung nicht präzise

große Stichproben: Schätzung ziemlich genau

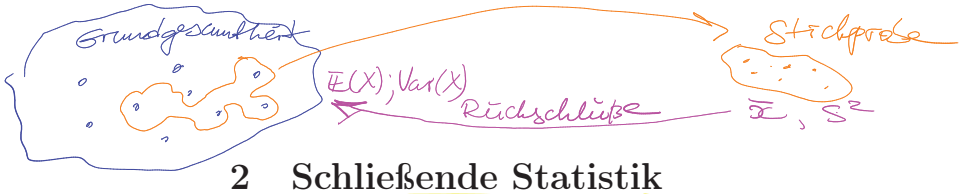

2 Schließende Statistik

2.1 Grundlagen der schließenden Statistik

Grundideen der schließenden Statistik

- Ziel der schließenden Statistik / induktiven Statistik:

  > Ziehen von Rückschlüssen auf die Verteilung einer (größeren) Grundgesamtheit auf Grundlage der Beobachtung einer (kleineren) Stichprobe.

- Rückschlüsse können sich auch auf spezielle Eigenschaften der Verteilung beschränken, z.B. Erwartungswert. , Verteilungsparameter (z.B. der Poisson Vert.)
- Wir betrachten zunächst ein elementares Beispiel.

Beispiel 2.1.1. *Grundidee*

- *Grundgesamtheit:* $N = 4$ *Kunden (A, B, C, D):* $\Omega = \{A,B,C,D\}$
- *Interessierende Variable: Zahlungsbereitschaft für Ihren Service* X *(in €) bzw. Erwartungswert* $\mathbb{E}(X)$
- *Verteilungsannahme: Verteilung von* X *unbekannt, aber sicher in der Menge der diskreten Verteilungen mit Wertemenge höchstens der Größe* $N = 4$ *und Punktwahrscheinlichkeiten, die Vielfaches von* $1/N = 1/4$ *sind.*
- *Z.B.: Zufallsvariable* X *nehme die folgenden Werte an:*

ω	A	B	C	D
$X(\omega)$	15	20	25	20

- *Zugehörige Verteilung:*

x_i	15	20	25	Σ
$p(x_i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

- *In der Praxis: Verteilung von* X *unbekannt.*
- *Einfachste Möglichkeit, um Verteilung / Erwartungswert von* X *zu ermitteln: alle vier Kunden befragen.*
- *Typische Situation: nicht alle Kunden können befragt werden, sondern nur eine kleinere Anzahl* $n < N$*, z.B.* $n = 2$.
- *Erwartungswert kann nur* **geschätzt** *werden.*
- *Ziel: Rückschluss aus der Erhebung von* $n = 2$ *Zahlungsbereitschaften auf die größere Grundgesamtheit von* $N = 4$ *Kunden.*
- *Neben Schätzung von* $\mathbb{E}X$ *auch Beurteilung der Qualität der Schätzung gewünscht (mit welchem "Fehler" ist zu rechnen).*

Vor der Befragung sind das ZV

- *Erhebung von 2 Zahlungsbereitschaften: Stichprobenzufallsvariablen X_1 und X_2.*
- **Wichtig**: *X_1 und X_2 sind* **Zufallsvariablen**, *denn* **Realisationen** x_1, x_2 *hängen davon ab, welche Kunden zufällig ausgewählt werden!*
- *Auswahlverfahren: 2-fache rein zufällige und voneinander unabhängige Auswahl eines der vier Kunden, d.h. zufälliges Ziehen mit Zurücklegen und Berücksichtigung der Reihenfolge.*
- *Alle $4^2 = 16$ Paare $(A,A), (A,B), \ldots, (C,D), (D,D)$ treten mit gleicher W'keit $1/16$ auf.*
- *Mögliche* **"Stichprobenrealisationen"** (x_1, x_2):

Stichprobenraum →

1. \ 2. K.	A	B	C	D
A	(15,15)	(15,20)	(15,25)	(15,20)
B	(20,15)	(20,20)	(20,25)	(20,20)
C	(25,15)	(25,20)	(25,25)	(25,20)
D	(20,15)	(20,20)	(20,25)	(20,20)

Alle möglichen Ergebnisse der Umfrage

- *Resultierende gemeinsame Verteilung von (X_1, X_2):*

$x_1 \setminus x_2$	15	20	25	Σ
15	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{4}$
20	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{2}$
25	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{4}$
Σ	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

Verteilung von X_1

Verteilung von X_2

Ø	A	B	C	D
A	15	17,5	20	17,5
B	17,5	20	22,5	20
C	20	22,5	25	22,5
D	17,5	20	22,5	20

-
  - *X_1 und X_2 haben dieselbe Verteilung wie X.*
  - *X_1 und X_2 sind stochastisch unabhängig.*
- *Schätzung des Erwartungswertes $\mathbb{E}X$ durch Mittelwert der Stichprobe.*
- **Wichtig**: **Nach** *Auswahl der Kunden ist der Mittelwert eine Zahl;* **vor** *Auswahl der Kunden ist Mittelwert eine Zufallsvariable.*
- **Verteilung** *der Zufallsvariable $\overline{X} = \frac{1}{2}(X_1 + X_2)$:* ← Schätzer

$$E(\overline{X}) = \sum_{i=1}^{5} \overline{x}_i \cdot p(\overline{x}_i)$$

$\overline{x}_i$	15	17,5	20	22,5	25	Σ
$p(\overline{x}_i)$	$\frac{1}{16}$	$\frac{1}{4}$	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{16}$	1

Verteilung des Schätzers $\overline{X}$

mit Erwartungswert $\boxed{\mathbb{E}\overline{X} = 20}$ und Standardabweichung $\boxed{\sqrt{Var(\overline{X})} = 2{,}5}$.

- *Verteilung von X*

$$E(X) = \sum_{i=1}^{3} y_i \, p(y_i)$$

y_i	15	20	25	Σ
$p(y_i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

← Ursprüngliche Verteilung der GG

☺ mit meiner Schätzung werde ich tendenziell richtig liegen ($\mathbb{E}(\bar{X}) = 20$)

hat Erwartungswert $\boxed{\mathbb{E}X = 20}$ *und Standardabweichung* $\sqrt{Var(X)} = 3{,}5355$.

2.1.1 Zufallsstichprobe

Seien $X_1, \dots, X_n$ Zufallsvariablen einer Stichprobe zu X. Dann ist $(X_1, \dots, X_n)$ eine **Zufallsstichprobe** (**Stichprobenvariable**) vom Umfang n zu X, falls die Verteilungen von X und X_i, $i = 1, 2, \dots, n$, übereinstimmen und $X_1, \dots, X_n$ stochastisch unabhängig sind.

Sei $(X_1, \dots, X_n)$ eine Zufallsstichprobe zu X.

- Die beobachteten Realisationen $(x_1, \dots, x_n)$ der Zufallsvariablen $(X_1, \dots, X_n)$ heißen **Stichprobenrealisation**.
- Die Menge $\mathcal{X}$ aller möglichen Stichprobenrealisationen heißt **Stichprobenraum**.
- Bemerkung; $\mathcal{X} \subseteq \mathbb{R}^n$ ← Stichprobenumfang

Sie wollen Ihre App weiterentwickeln und interessieren sich für den Anteil von App-Nutzer in Ihrer gesamten Kundschaft sowie für das mittlere Alter Ihrer Kunden.

So führen Sie eine Kundenumfrage durch. Der Umfrageumfang n ist:

$n =$ 20

neue Stichprobe

Stichprobenvariablen

X_1 X_2 ... X_{20}

x_1 x_2 ... x_{20}

Die Umfrageergebnisse sehen so aus:

Stichproben-realisation

Kunde	1	2	3	4	5	6	7	8	9	10	... 20
Alter	31	10	40	24	28	33	31	35	27	10	... 27
App_Nutzung	nein	ja	nein	ja	ja	ja	ja	ja	nein	ja	... nein
	0	1	0	1	1						
	y_1	y_2	y_3	...							

$$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

↳ Anteil von App-Nutzer $\mathbb{P}(Y = 1)$

2.2 Parameterschätzung

Beispielfragestellung
Sie wollen Ihre App weiterentwickeln und brauchen dafür:

- den **Anteil an App-Nutzern** in Ihrer gesamten Kundeschaft und
- das **mittlere Alter** Ihrer Kunden.

Leider sind diese Infos nicht in Ihrer Kundendatenbank vorhanden.
Wie gehen Sie vor? $\rightsquigarrow$ **Parameterschätzung**.

- Eine **Stichprobe** dient der Informationsgewinnung über das Verhalten eines **Merkmals in der Grundgesamtheit**.
- Dies erfordert ein **Modell**, das die **Verteilung** des interessierenden Merkmals in der Grundgesamtheit beschreibt.
- Eine **Schätzung** hängt dabei stets von der **konkreten Stichprobe** ab, und **variiert**, falls eine erneute Stichprobe gezogen wird.
- Wichtige Fragen:
  - **Wie wähle ich einen geeigneten Schätzer?**
  - **Wie gut ist mein Schätzer**, bzw. wie nah kommt er an den wahren Parameter heran?
  - **Wie stabil ist mein Schätzer**, d.h. wie stark schwankt er von Stichprobe zu Stichprobe?

Schätzergebnis variiert je nach Stichprobenrealisation

Schätzwerte: der Anteil von Appnutzern und das mittlere Kundenalter in der vorliegenden Stichprobe sind 0.45 und 26.65

neue Stichprobe

die wahren Parameter

0.6 und 30

das Schätzergebnis entspricht nicht genau den wahren Parametern

1. Erwartungstreue

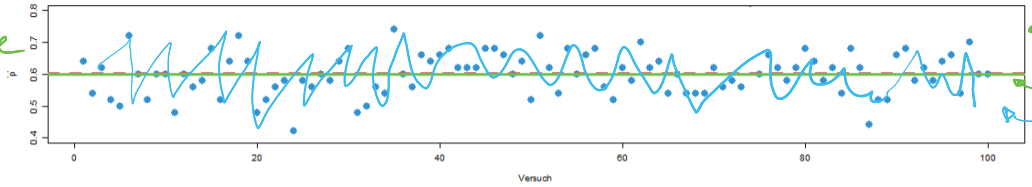

- richtige Tendenz
- Variabilität: möglichst wenige Schwankungen mit steigendem n

2. Konsistenz

3. Effizienz

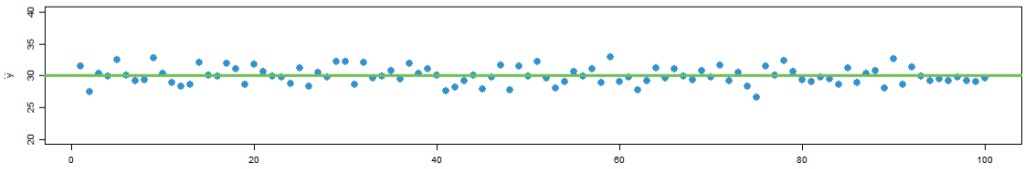

- wähle den Schätzer mit der kleinsten Varianz.

2.2.1 Punktschätzung

- Ziel der **Punktschätzung** ist es, einen möglichst genauen Näherungswert für einen unbekannten Grundgesamtheitsparameter anzugeben.
- Parameter treten in zwei Formen auf:
  - **Kennwerte einer beliebigen, unbekannten Verteilung**, z.B.
    - Erwartungswert und Varianz einer Zufallsvariable;
    - Median oder p-Quantil einer Zufallsvariable; Korrelation zweier Zufallsvariablen.
  - **Parameter eines angenommenen Verteilungsmodells**, z.B.
    - (μ, σ^2), wenn von einer Normalverteilung auszugehen ist;
    - λ, wenn von einer Exponentialverteilung auszugehen ist.

Schätzfunktion / Schätzer

"theta"

- Aus den Realisierungen soll auf einen Parameter θ geschlossen werden (z.B. Kennzahl oder Verteilungsparameter).
- Eine **Punktschätzung** für θ ist eine Funktion der Realisierungen der Form $t = g(x_1, \dots, x_n)$. ← eine Funktion der Stichprobenwerte
- Beispiel: $\boxed{g(x_1, \dots, x_n) = \frac{1}{n} \sum_i x_i}$ ist Schätzwert für Erwartungswert $\boxed{\theta = \mathbb{E}X}$.

  Sei $(X_1, \dots, X_n)$ eine Zufallsstichprobe.
- Eine **Schätzfunktion** oder **Schätzstatistik** (kurz: **Statistik**) ist eine Funktion

  Schätzer sind selber ZV →

  $$\boxed{T = g(X_1, \dots, X_n)}$$

  der Zufallsstichprobe $(X_1, \dots, X_n)$.

  Stichprobenvariablen — ZV bevor eine Realisierung der Stichprobe vorliegt.
- Der resultierende numerische Wert $g(x_1, \dots, x_n)$ heißt **Schätzwert**.
- Als Funktion von Zufallsvariablen ist T selbst eine Zufallsvariable.
- Die Schätzfunktion heißt auch
  - **Schätzer**, falls es sich um die Schätzung eines Verteilungsparameters oder einer Kennzahl handelt;
  - **Teststatistik**, falls Entscheidungen zur Annahme oder Ablehnung von Hypothesen getroffen werden.

Beispiel 2.2.1. *Schätzfunktionen*

- $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *ist Schätzfunktion für* **Erwartungswert** $\mu = \mathbb{E}(X)$.

- $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, *mit* $X_i \in \{0,1\}$ *ist Schätzfunktion für die* **Auftretenswahrscheinlichkeit** $\mathbb{P}(X = 1)$.

Stichprobenvarianz

- $S^2 = g(X_1, \dots, X_n) = \boxed{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2}$ *ist Schätzfunktion für die* **Varianz** $\sigma^2 = Var(X)$.

2.2.2 Eigenschaften von Schätzstatistiken

- Was charakterisiert einen **"guten" Schätzer**?
- Welche Eigenschaften rechtfertigen beispielsweise die Schätzfunktion $\overline{X}$ als Schätzer für den Erwartungswert?
- Die folgenden Eigenschaften liefern klare Kriterien für die Güte einer Schätzfunktion:
  - **Erwartungstreue**
  - **Konsistenz**
  - **Effizienz** / **Wirksamkeit**

1. **Erwartungstreue**

- Eine Schätzung soll **tendenziell** den richtigen Wert liefern, d.h. weder systematisch über- noch unterschätzen.

Eine Schätzfunktion $T = g(X_1, \dots, X_n)$ für den Parameter θ heißt **erwartungstreu** oder **unverzerrt**, wenn gilt

$$\boxed{\mathbb{E}(T) = \theta.}$$

← Der Erwartungswert des Schätzers ($\mathbb{E}(T)$) entspricht dem wahren Parameter (θ)

Verzerrung / **Bias**

Der **Bias** bezeichnet die systematische Über- oder Unterschätzung einer Schätzfunktion:

$$\text{Bias}(T) = \mathbb{E}(T) - \theta.$$

Beispiel 2.2.2. *Erwartungstreue Schätzfunktionen*

- *Das* **Stichprobenmittel** $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *ist eine erwartungstreue Schätzstatistik für den* **Erwartungswert** $\mu = \mathbb{E}(X)$, *denn*

$$\mathbb{E}(\overline{X}) = \frac{1}{n}\sum_{i=1}^{n} \underbrace{\mathbb{E}(X_i)}_{\mu} = \frac{1}{n} n \cdot \mu = \boxed{\mu.}$$

- *Die* **relative Häufigkeit** $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, *mit* $X_i \in \{0;1\}$, *ist erwartungstreuer Schätzer für die* **Auftretenswahrscheinlichkeit** $\mathbb{P}(X = 1)$.
- *Eine i.a. nicht erwartungstreue Schätzstatistik für* μ *is* $T = 110$, *d.h.* T *nimmt unabhängig von* $X_1, \dots, X_n$ *den Wert* 110 *an.*

Beispiel 2.2.3. *Erwartungstreue Schätzfunktionen*

- *Die* **Stichprobenvarianz**

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

ist eine erwartungstreue Schätzstatistik für die **Varianz** $\sigma^2 = Var(X)$, *d.h.* $\mathbb{E}(S^2) = \sigma^2$.

- *Für die* **mittlere quadratische Abweichung** $\tilde{S}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$ *gilt:*

$$\mathbb{E}(\tilde{S}^2) = \frac{n-1}{n}\sigma^2.$$

$\mathbb{E}(\tilde{S}^2) \neq \sigma^2 \rightarrow$ nicht erwartungstreu

- *Also:* $\tilde{S}^2$ *nicht erwartungstreu; aber* **asymptotisch erwartungstreu**, *d.h. Verzerrung verschwindet für wachsendes* n.

- *Die Verzerrung ist*

$$Bias(\tilde{S}^2) = \mathbb{E}(\tilde{S}^2) - \sigma^2 = \boxed{-\frac{1}{n}\sigma^2}.$$

Nachweis: Bias der mittleren quadratischen Abweichung*

- *Es gilt:* $\mathbb{E}((X_i - \mu)(X_j - \mu)) = 0$, *falls* $i \neq j$.

- *Ferner:*

$$\mathbb{E}((\overline{X} - \mu)^2) = Var(\overline{X}) = \frac{1}{n^2}Var(X_1 + \cdots + X_n) = \frac{1}{n}\sigma^2.$$

- *Damit ergibt sich:*

$$\begin{aligned}
\mathbb{E}((X_i - \overline{X})^2) &= \mathbb{E}(((X_i - \mu) - (\overline{X} - \mu))^2) \\
&= \sigma^2 - 2\mathbb{E}\left((X_i - \mu)\left(\frac{1}{n}\sum_{j=1}^{n}X_j - \mu\right)\right) + \frac{\sigma^2}{n} \\
&= \sigma^2 - \frac{2}{n}\sum_{i=1}^{n}\mathbb{E}((X_i - \mu)(X_j - \mu)) + \frac{\sigma^2}{n} \\
&= \sigma^2 - \frac{2\sigma^2}{n} + \frac{\sigma^2}{n} = \sigma^2 - \frac{\sigma^2}{n}.
\end{aligned}$$

2. **Konsistenz**

- Eine weitere wichtige Eigenschaft eines Schätzers ist die **Konsistenz**, die besagt, dass die Schätzfunktion gegen die zu schätzende Größe konvergiert. (Mit zunehmendem n sollen die Abweichungen kleiner werden)
- Formal wird Konsistenz über die Konvergenz der erwarteten mittleren quadratischen Abweichung definiert.

Die **erwartete mittlere quadratische Abweichung (mean square error)** ist bestimmt durch

$$\mathrm{MSE} = \mathbb{E}((T-\theta)^2).$$

Sie lässt sich ausdrücken als

$$\mathrm{MSE} = \mathrm{Var}(T) + \mathrm{Bias}(T)^2.$$

Konsistenz
Eine Schätzstatistik heißt **konsistent**, wenn gilt:

$$\boxed{\mathrm{MSE} \to 0 \text{ für } n \to \infty.}$$

Beispiel 2.2.4. *Konsistenz*

- *Aus unabhängigen, identisch verteilten Beobachtungen $X_1, \dots, X_n$ mit $\mathbb{E}(X_1) = \mu$ und $Var(X_1) = \sigma^2$ wird der Erwartungswert durch* $\boxed{\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i}$ *geschätzt.*
- *Es gilt:* $\to \mathbb{E}(\overline{X}) = \mu$ *(Erwartungstreue)* $\to$ Bias $(\overline{X}) = 0$

$$MSE = Var(\overline{X}) + \underbrace{Bias(\overline{X})}_{=0}{}^2 = Var(\overline{X}) = \frac{1}{n^2}\sum_{i=1}^{n}\sigma^2 = \boxed{\frac{\sigma^2}{n}} \text{ (Konsistenz)} \qquad MSE = \frac{\sigma^2}{n} \xrightarrow{n\to\infty} 0$$

3. **Effizienz**

- Ein unverzerrter Schätzer für θ ist effizienter als ein anderer unverzerrter Schätzer, wenn er die kleinere Varianz hat.

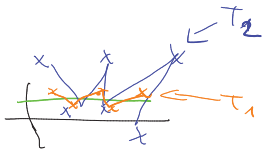

Effizienz (Wirksamkeit)
Von zwei erwartungstreuen Schätzern T_1 und T_2 für θ heißt T_1 **effizienter (wirksamer)** falls

$$\boxed{\mathrm{Var}(T_1) \le \mathrm{Var}(T_2)}$$

Der **effizienteste** oder **beste Schätzer** ist derjenige unverzerrte Schätzer, der die kleinste Varianz hat.

- Der Begriff der Effizienz kann auf verzerrte Schätzer mittels der mittleren quadratischen Abweichung erweitert werden.
- $\overline{X}$ ist effizient für den Erwartungswert;
- $\overline{X}$, mit $X_i \in \{0,1\}$ ist effizient für $\mathbb{P}(X = 1)$;
- $\overline{X}$ ist effizient für den Parameter λ der Poisson-Verteilung.