2.3 Konstruktion von Schätzfunktionen

- Bislang haben wir bereits bekannte spezielle Schätzfunktionen betrachtet.
- In diesem Abschnitt entwickeln wir allgemeine Methoden, Schätzfunktionen für unbekannte Parameter zu finden.
- Wir befassen uns mit folgenden Methoden:

I. – **Momenten-Methode**

II. – **Maximum-Likelihood-Schätzung**

2.3.1 Momenten-Methode

- Grundlegende Idee: Schätze Parameter der Verteilung so, dass zugehörige **Momente** $\mathbb{E}(X), \mathbb{E}(X^2), \ldots$ mit den entsprechenden empirischen Momenten der Stichprobenvariablen übereinstimmen:

(theoretisch) (empirisch)

	Verteilung	Stichprobe
1. Moment →	$\mathbb{E}(X) = \mu$	$\frac{1}{n}\sum_{i=1}^{n} x_i = \overline{x}$
2. Moment →	$\mathbb{E}(X^2) = \mu^2 + \sigma^2$	$\frac{1}{n}\sum_{i=1}^{n} x_i^2 = \overline{x^2}$
	$\vdots$	$\vdots$
m. Moment →	$\mathbb{E}(X^m)$	$\frac{1}{n}\sum_{i=1}^{n} x_i^m = \overline{x^m}$

$\underbrace{Var(X)}_{\sigma^2} = \mathbb{E}(X^2) - (\underbrace{\mathbb{E}(X)}_{\mu})^2$

Idee:
- setze die theor. Momente gleich den empir. Momenten
- stelle um und rechne die Schätzwerte aus.

- Es werden dabei – beginnend mit dem ersten Moment – gerade so viele Momente einbezogen, dass alle zu schätzenden Parameter eindeutig geschätzt werden können.

Beispiel 2.3.1. *Momenten-Methode*

- *Schätzung des Parameters p einer* **Bernoulli-Verteilung**: $X \sim Bern(p)$

  Stichprobe: $x_1, x_2, \ldots x_n$ → 0, 1, 0, 1, 0, 1

  - *Verteilungsannahme:* $\mathbb{P} \in \{B(1,p) | p \in \Theta = [0,1]\}$
  - *Erstes Moment:* $\mathbb{E}(X) = p$ ← für Bern(p)
  - *Schätzer:* $\mathbb{E}(X) = \overline{x}$ → $\boxed{\hat{p}_{MM} = \overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i}$ ← Schätzer

  Beispiel: Schätzung des Appnutzeranteils anhand einer Kundenbefragung.

- *Schätzung des Parameters λ einer* **Exponentialverteilung**:

  nur ein Parameter (nehme nur das 1. Moment)

  - *Verteilungsannahme:* $\mathbb{P} \in \{E(\lambda) | \lambda > 0\}$ $X \sim Exp(\lambda)$
  - *Erstes Moment:* $\mathbb{E}(X) = \frac{1}{\lambda}$
  - *Schätzer:* $\mathbb{E}(X) = \overline{x}$ → $\frac{1}{\lambda} = \overline{x}$

$$\boxed{\hat{\lambda}_{MM} = \frac{1}{\overline{x}} = \frac{n}{\sum_{i=1}^{n} x_i}}$$ ← Schätzer

Beispiel: Schätzung von λ für die Verteilung der relativen Bewertungslängen.

- *Schätzung der Parameter (μ,σ^2) einer* **Normalverteilung**:
  - *Verteilungsannahme:* $\mathbb{P} \in \{\mathsf{N}(\mu,\sigma^2) | \mu \in \mathbb{R}, \sigma^2 > 0\}$
  - *Erstes Moment:* $\mathbb{E}(X) = \mu$ $\quad \mathbb{E}(X) = \bar{x} \rightarrow \boxed{\hat{\mu}_{MM} = \bar{x}}$ ← Schätzer für μ
  - *Zweites Moment:* $\mathbb{E}(X^2) = \mu^2 + \sigma^2$ $\quad \mathbb{E}(X^2) = \overline{x^2} = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \rightarrow \mu^2 + \sigma^2 = \overline{x^2}$
  - *Einsetzen der empirischen Momente gibt:* $\hat{\sigma}^2 = \overline{x^2} - (\hat{\mu}_{MM})^2$

Beispiel: Verteilungsparameter für die durchschnittliche Temperatur im Juli.

Schätzer für σ^2 → $\boxed{\hat{\sigma}^2_{MM} = \overline{x^2} - (\bar{x})^2}$

2.3.2 Maximum-Likelihood-Methode

Maximum-Likelihood-Schätzung

- Seien $X_1, \dots, X_n$ unabhängige, identisch verteilte Zufallsvariablen.
- Die Verteilung der X_i, $i = 1, \dots, n$ ist unbekannt, aber wir nehmen an, die Verteilung gehöre zu einer **Verteilungsklasse**, die durch eine geeignete **Parametrisierung** charakterisiert ist.

  Verteilungsparameter
- Formal: X_i hat Wahrscheinlichkeitsfunktion oder Dichte $f(x|\theta)$, $\theta \in \Theta$, wobei θ ein Vektor von Parametern aus der Menge Θ ist.
- Das **Maximum-Likelihood-Prinzip** besagt: Stichprobe soll max Wkt haben bei dem

  > Man wähle zum Stichprobenergebnis $(x_1, \dots, x_n)$ denjenigen Wert θ als Schätzwert für θ, unter dem die Wahrscheinlichkeit für das Eintreten des Stichprobenergebnisses am größten ist.
- "unter dem die Wahrscheinlichkeit für das Eintreten des Ergebnisses am größten ist" kann ersetzt werden durch: "unter dem die entsprechende Wahrscheinlichkeitsfunktion oder Dichte maximal ist".

Beispiel 2.3.2. *Maximum-Likelihood-Schätzung: Wahrscheinlichkeit*

- *Die* **Bernoulli-Verteilung** *hat Wahrscheinlichkeitsfunktion*

$$\boxed{f(x|p) = \mathbb{P}(X = x|p) = p^x \cdot (1-p)^{1-x},} \quad x \in \{0,1\}, \qquad \rightarrow \begin{cases} p, & x = 1 \\ 1-p, & x = 0 \end{cases}$$

  mit $p \in [0,1]$ (also $\theta = p$, $\Theta = [0,1]$).

- *Die* **Normalverteilung** *hat Dichte*

$$\boxed{f(x|\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),}$$

  mit $\mu \in \mathbb{R}$ und $\sigma^2 \in \mathbb{R}_+$ (also $\theta = (\mu,\sigma^2)$ und $\Theta = \mathbb{R} \times \mathbb{R}_+$).

- Wegen der **Unabhängigkeit** der Zufallsstichprobe gilt für die gemeinsame Wahrscheinlichkeitsfunktion / Dichte:

Dichte / Wktsfunktion der Stichprobe $\rightarrow$

$$f(x_1, \dots, x_n|\theta) = \underbrace{f(x_1|\theta)}_{\text{... von } x_1} \cdot \underbrace{f(x_2|\theta)}_{\text{... von } x_2} \cdot \dots \cdot \underbrace{f(x_n|\theta)}_{\text{... von } x_n}. \qquad (*)$$

- Ist eine Realisierung $(x_1, \dots, x_n)$ gegeben, so lässt sich die Dichte als Funktion der unbekannten Parameter θ auffassen, der sogenannten **Likelihood-Funktion**

Likelihood-Funktion $\rightarrow$

$$L(\theta) = f(x_1, \dots, x_n|\theta). \overset{(*)}{=} f(x_1|\theta) \cdot f(x_2|\theta) \cdot \dots \cdot f(x_n|\theta)$$

Das **Maximum Likelihood-Prinzip** besagt: Wähle zu $x_1, \dots, x_n$ als Parameterschätzung denjenigen Parameter $\hat{\theta}$, für den die **Likelihood maximal** ist, d.h.

$$\boxed{L(\hat{\theta}) = \max_{\theta} L(\theta),}$$

bzw.

$$f(x_1, \dots, x_n|\hat{\theta}) = \max_{\theta} f(x_1, \dots, x_n|\theta).$$

- Man wählt zu den gegebenen Realisationen $x_1, \dots, x_n$ denjenigen Parameter $\hat{\theta}$, für den die Wahrscheinlichkeit bzw. Dichte, dass gerade diese Werte auftreten, maximal ist.
- Anders ausgedrückt: es handelt sich um diejenigen Parameter θ, die die **plausibelste Erklärung** für das Zustandekommen dieser Werte liefern.
- Die Schätzung hängt insbesondere von der Stichprobe ab: $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$.
- Die Schätzfunktion $g(x_1, \dots, x_n) = \hat{\theta}(x_1, \dots, x_n)$ heißt **Maximum-Likelihood-Schätzer**.
- Zur praktischen Bestimmung des Maximums wählt man häufig den Logarithmus der Likelihood-Funktion, die **Log-Likelihood**, da diese das Produkt der Dichten in eine Summe überführt:

$$\boxed{\mathcal{L}(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln f(x_i|\theta).}$$

- Wegen der strengen Monotonie des Logarithmus liefern das Maximieren von $L(\theta)$ und $\ln L(\theta)$ denselben Wert $\hat{\theta}$.

Beispiel 2.3.3. *Maximum-Likelihood-Schätzung*

- *Ziehe* $n = 4$ *Kugeln aus Urne mit* r *roten und* s *schwarzen Kugeln (mit Zurücklegen); Mischungsverhältnis* $\boxed{p = \frac{r}{r+s}}$ *unbekannt.*
- *Also:* 4 *unabhängige Wiederholungen des Bernoulli-Experiments "Ziehen einer roten Kugel".* $X \sim \text{Bern}(p)$

$X = \begin{cases} 1, & \text{wenn rot} \\ 0, & \text{sonst} \end{cases}$

$f_X(x) = \begin{cases} p, & \text{wenn } x=1 \\ 1-p, & x=0 \end{cases}$

- *Die Stichprobe ist* $x_1 = 1$, $x_2 = 1$, $x_3 = 0$, $x_4 = 1$. ← Stichprobe
- *Likelihood-Funktion (s. nächste Folie):*

$$\boxed{L(p)} = f(x_1|p) \cdots f(x_4|p) = f(x_1) \cdot f(x_2) \cdot f(x_3) \cdot f(x_4) = p \cdot p \cdot (1-p) \cdot p = \boxed{p^3 \cdot (1-p)} = p^3 - p^4$$

- *Ableiten und Nullsetzen ergibt:*

$$L'(p) = 3p^2 - 4p^3 \overset{!}{=} 0 \iff p^2(3-4p) \overset{!}{=} 0 \iff 3-4p = 0$$

- *Maximum bei* $\boxed{p^* = \frac{3}{4}}$ ML
- *Darstellung der Likelihood-Funktion:*

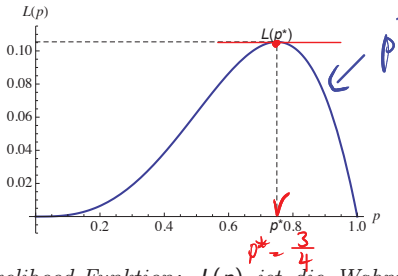

$p^3 - p^4 = L(p)$

- *Interpretation der Likelihood-Funktion:* $L(p)$ *ist die Wahrscheinlichkeit für das gemeinsame Auftreten der Beobachtungen* $x_1 = 1, x_2 = 1, x_3 = 0$ *und* $x_4 = 1$ *unter der Annahme das* $\mathbb{P}(X = 1) = p$.

Dichte: $f(x) = \lambda \cdot e^{-\lambda \cdot x}$

Beispiel 2.3.4. *Maximum-Likelihood-Schätzung: Exponentialverteilung*

- *Seien* $X_1, \dots, X_4$ *unabhängige Wiederholungen einer exponentell-verteilten Größe mit zu schätzendem Wert* λ.
- *Stichprobe:* $x_1 = 0{,}95$, $x_2 = 1{,}81$, $x_3 = 1$, $x_4 = 0{,}67$
- *Likelihood-Funktion:*

$$L(\lambda) = f(x_1|\lambda) \cdots f(x_4|\lambda) = \underbrace{f(x_1|\lambda)}_{\lambda \cdot e^{-\lambda \cdot 0{,}95}} \cdot \underbrace{f(x_2|\lambda)}_{\lambda \cdot e^{-\lambda \cdot 1{,}81}} \cdot \underbrace{f(x_3|\lambda)}_{\lambda \cdot e^{-\lambda \cdot 1}} \cdot \underbrace{f(x_4|\lambda)}_{\lambda \cdot e^{-\lambda \cdot 0{,}67}} = \lambda^4 \cdot e^{-\lambda(0{,}95+1{,}81+1+0{,}67)} = \boxed{\lambda^4 \cdot e^{-4{,}43\lambda}}$$

- *Log-Likelihood-Funktion:* $\mathcal{L}(\lambda) = \ln L(\lambda) = \ln(\lambda^4 \cdot e^{-4{,}43\lambda}) = \ln \lambda^4 + \ln(e^{-4{,}43\lambda}) = 4 \ln \lambda - 4{,}43\lambda$
- *Ableiten und Nullsetzen:*

$$\mathcal{L}'(\lambda) = \frac{4}{\lambda} - 4{,}43 \overset{!}{=} 0 \rightarrow \boxed{\hat{\lambda}_{ML} = \frac{4}{4{,}43} = 0{,}9029}$$

- *Zweite Ableitung:* $\mathcal{L}''(\lambda) = -\frac{4}{\lambda^2} < 0$

Ableitung $\ln(x)$: $(\ln(x))' = \frac{1}{x}$

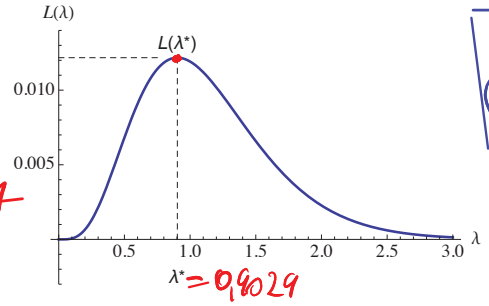

So gesetzt, dass Wkt der Stichprobe maximal ist

- *Beachte:* $\boxed{\hat{\lambda}_{ML} = 0{,}9029}$
- *Interpretation der Likelihood-Funktion:* $L(\lambda)$ *ist die Dichte für das gemeinsame Auftreten der Beobachtungen* $x_1 = 0{,}95$, $x_2 = 1{,}81$, $x_3 = 1$ *und* $x_4 = 0{,}67$ *unter der Annahme, dass eine Exponentialverteilung mit Parameter* λ *vorliegt.*
- *Ein hoher Dichtewert* $f(x)$ *an der Stelle* x *impliziert eine hohe Auftretenswahrscheinlichkeit in einem kleinen Intervall um* x.

Beispiel 2.3.5. *Maximum-Likelihood-Schätzung: Normalverteilung**

- *Seien* $X_1, \dots, X_n$ *unabhängige Wiederholungen einer Normalverteilung* (μ,σ^2).
- *Zu schätzen sind* $\theta = (\mu,\sigma^2)$.
- *Likelihood-Funktion:* $L(\mu,\sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_1-\mu)^2}{2\sigma^2}} \cdot \ldots \cdot \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_n-\mu)^2}{2\sigma^2}}$.
- *Log-Likelihood-Funktion:*

$$\ln L(\mu,\sigma) = \sum_{i=1}^{n} \left[\ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(x_i-\mu)^2}{2\sigma^2} \right] = -\frac{n}{2}\ln(2\pi) - n\ln\sigma - \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2}.$$

- *Partielles Ableiten und Nullsetzen ergibt:*

$$\frac{\partial \ln L(\mu,\sigma^2)}{\partial \mu} = \boxed{\sum_{i=1}^{n} \frac{x_i-\mu}{\sigma^2} = 0}$$

$$\frac{\partial \ln L(\mu,\sigma^2)}{\partial \sigma^2} = \boxed{-\frac{n}{2\sigma^2} + \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^4} = 0}$$

- *Aus der ersten Gleichung ergibt sich* $\boxed{\sum_{i=1}^{n} x_i - n\hat{\mu} = 0}$ *und damit* $\boxed{\hat{\mu} = \overline{x}}$.
- *Aus der zweiten Gleichung ergibt sich* $\boxed{\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2}$, *also die mittlere quadratische Abweichung.*
- *Die ML-Schätzstatistiken der Normalverteilung sind also* $\overline{X}$ *und* $\tilde{S}^2$.