2.7 Regressionsanalyse

- **Lineares Regressionsmodell** aus der **deskriptiven Statistik**:
- Für zwei metrische Merkmale, Y und X, postuliert das **lineare Regressionsmodell** folgenden Zusammenhang:

$$Y = \alpha + \beta X.$$

- Gegeben n Beobachtungen (y_i, x_i), $i = 1, \dots, n$, (zu den Merkmalen Y und X) wird folgendes Gleichungssystem aufgestellt:

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

  wobei $\varepsilon_1, \dots, \varepsilon_n$ **Fehlerterme** sind, die so gewählt werden, dass Gleichheit gilt.
- Die Koeffizienten α und β werden mit der Methode der kleinsten Quadrate bestimmt:

$$\sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - (\alpha + \beta x_i))^2 \quad \to \quad \text{Minimum.}$$

- Im folgenden erweitern wir diesen Ansatz, indem der Fehler ε als Zufallsvariable mit bestimmten Eigenschaften angenommen wird.

2.7.1 Lineare Einfachregression

- In der linearen empirischen Beziehung

$$\boxed{y_i = \alpha + \beta x_i + \varepsilon_i,} \quad i = 1, \dots, n,$$

  seien die Fehlerterme ε_i
  - unbeobachtbare, unabhängige Realisierungen einer Zufallsvariablen,
  - identisch verteilt mit $\mathbb{E}(\varepsilon_i) = 0$ und $\mathrm{Var}(\varepsilon_i) = \sigma^2$. ← unbekannt (immer!)
    direkte Konsequenz:
    - Konfidenzintervalle für σ unbekannt
    - T-Test
- Die Werte x_i, $i = 1, \dots, n$, können
  - deterministisch sein (z.B. Dosis eines Medikaments bei einem Versuch),
  - Realisierungen von Zufallsvariablen X_i sein (**stochastischer Regressor**).
- Im Fall eines stochastischen Regressors gelten die Annahmen über ε_i dann nur bedingt, also $\mathbb{E}(\varepsilon_i | X_i = x_i) = 0$, etc.
- Im folgenden nehmen wir der Einfachheit halber an, der Regressor sei deterministisch.

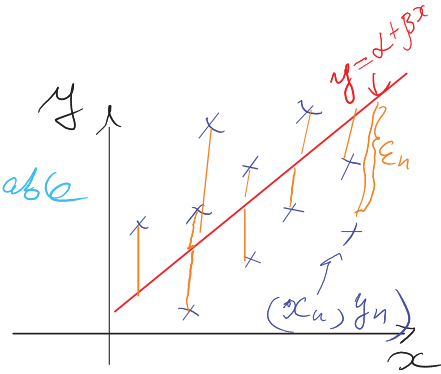

Standardmodell der linearen Einfachregression

Es gilt:

abhängige/erklärte Variable (ZV) → $Y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n.$ ← weite/unabh. Variable

Dabei sind:

- $Y_1, \dots, Y_n$: beobachtbare metrische Zufallsvariable;
- $x_1, \dots, x_n$: gegebene deterministische Werte;
- $\varepsilon_1, \dots, \varepsilon_n$: unbeobachtbare ZV'en, die unabhängig und identisch verteilt sind mit $\mathbb{E}(\varepsilon_i) = 0$, $\mathrm{Var}(\varepsilon_i) = \sigma^2$.

Die Regressionskoeffizienten α,β und die Varianz σ^2 sind unbekannte Parameter, die aus den Daten (y_i,x_i), $i = 1, \dots, n$ zu schätzen sind. $\mathbb{E}(\varepsilon_i) = 0$

- Es gilt:

$$\mathbb{E}(Y_i) = \mathbb{E}(\alpha + \beta x_i + \varepsilon_i) = \alpha + \beta x_i$$
$$\mathrm{Var}(Y_i) = \mathrm{Var}(\alpha + \beta x_i + \varepsilon) = \mathrm{Var}(\varepsilon) = \sigma^2$$

- Die Verteilungen der Y_i sind, bis auf die Verschiebung der Erwartungswerte, gleich:

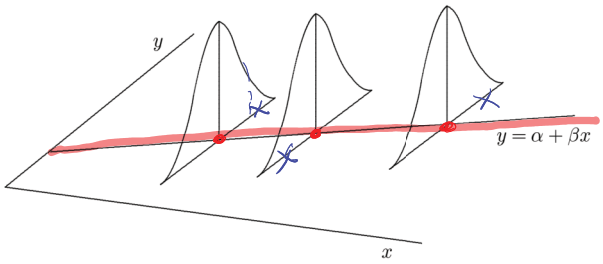

Quelle: Fahrmeir et al.

- Die Eigenschaft gleicher Varianz σ^2 der Fehlerterme heißt **Homoskedastizität**.
- Aussagen zu Verteilungen von Schätzern und Testatistiken, auch für kleine n, erhält man durch folgende – stärkere – Annahme.

Normalverteilungsannahme

Es sei

$$\varepsilon_i \sim \mathsf{N}(0,\sigma^2), \quad i = 1, \dots, n,$$

bzw.

$$Y_i \sim \mathsf{N}(\alpha + \beta x_i, \sigma^2), \quad i = 1, \dots, n.$$

Schätzen, Testen und Prognose

- Im folgenden befassen wir uns mit folgenden Aspekten des linearen Regressionsmodells:
  - Punkt- und Intervallschätzung der unbekannten Parameter α, β, σ^2
  - Testen von Hypothesen über die Regressionskoeffizienten α, β
  - Prognose der Zielvariablen Y für neuen Wert x

2.7.2 Schätzen im linearen Regressionsmodell

Kleinste-Quadrate-Schätzer

- **Kleinste-Quadrate-Methode**: Bestimme $\hat{\alpha}$ und $\hat{\beta}$, so dass

$$\sum_{i=1}^{n}(\overset{\varepsilon^2}{Y_i - \alpha - \beta x_i})^2 \quad \to \quad \min_{\alpha,\beta}$$

- Minimieren ergibt:

Schätzung für β

$$\boxed{\hat{\beta} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(Y_i - \overline{Y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \hat{\rho}_{XY}\frac{\hat{\sigma}_Y}{\hat{\sigma}_X},}$$

$$\boxed{\hat{\alpha} = \overline{Y} - \hat{\beta}\overline{x},}$$

$$\boxed{\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\hat{\varepsilon}_i^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{\alpha} - \hat{\beta}x_i)^2,}$$

mit **Residuen** $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$ und **gefitteten Werten** $\hat{Y}_i = \hat{\alpha} + \hat{\beta}x_i$, $i = 1, \dots, n$.

- Man beachte, dass $\hat{\alpha}$, $\hat{\beta}$ und $\hat{\sigma}^2$ von den Zufallsvariablen $Y_1, \dots, Y_n$ abhängen, und es sich um Schätzfunktionen handelt.

- Diese sind erwartungstreu:

$$\mathbb{E}(\hat{\alpha}) = \alpha, \quad \mathbb{E}(\hat{\beta}) = \beta, \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2,$$

- Es gilt:

$$\boxed{\mathrm{Var}(\hat{\alpha}) = \sigma_{\hat{\alpha}}^2 = \sigma^2\frac{\sum x_i^2}{n\left(\sum x_i^2 - n\overline{x}^2\right)}}$$

$$\boxed{\mathrm{Var}(\hat{\beta}) = \sigma_{\hat{\beta}}^2 = \frac{\sigma^2}{\sum x_i^2 - n\overline{x}^2}}$$

- Unter der Normalverteilungsannahme gilt:

$$\varepsilon_i \sim \mathsf{N}(0,\sigma^2), \quad Y_i \sim \mathsf{N}(\alpha + \beta_i, \sigma^2), \quad \boxed{\hat{\alpha} \sim \mathsf{N}(\alpha, \sigma_{\hat{\alpha}}^2),} \quad \boxed{\hat{\beta} \sim \mathsf{N}(\beta, \sigma_{\hat{\beta}}^2).}$$

weil wir hier zwei parameter schätzen

Verteilung der standardisierten Schätzfunktionen

Unter der Normalverteilungsannahme gilt:

Standardisierte Schätzer

$$\boxed{\frac{\hat{\alpha} - \alpha}{\hat{\sigma}_{\hat{\alpha}}} \sim t(n-2), \quad \frac{\hat{\beta} - \beta}{\hat{\sigma}_{\hat{\beta}}} \sim t(n-2).}$$

Konfidenzintervalle für α und β

Ausgabe von gretl und co.

$$\boxed{\hat{\alpha} \pm \hat{\sigma}_{\hat{\alpha}}\, t_{1-\alpha/2}(n-2), \quad \hat{\beta} \pm \hat{\sigma}_{\hat{\beta}}\, t_{1-\alpha/2}(n-2).}$$

Für $n > 30$ können die t-Quantile durch $\mathsf{N}(0,1)$-Quantile ersetzt werden.

- Falls die Normalverteilungsannahme nicht erfüllt ist, so gilt sie asymptotisch, also gelten obige Ergebnisse approximativ für genügend großes n.

- `gretl` Output:

Werte der Koeff.

Stabw von Koeff.

gretl: Modell 2

Datei Bearbeiten Tests Speichern Graphen Analyse LaTeX

```
Modell 2: KQ, benutze die Beobachtungen 1-67
Abhängige Variable: BMWRenditen

                 Koeffizient   Std.-fehler   t-Quotient   p-Wert
  ---------------------------------------------------------------
  const         -0,00233527   0,000853383     -2,736     0,0080    ***
  DAXRenditen    1,12248      0,0933891       12,02      3,59e-18  ***

Mittel d. abh. Var.    -0,000501   Stdabw. d. abh. Var.    0,012244
Summe d. quad. Res.     0,003070   Stdfehler d. Regress.   0,006873
R-Quadrat               0,689686   Korrigiertes R-Quadrat  0,684912
F(1, 65)                144,4654   P-Wert(F)               3,59e-18
Log-Likelihood          239,6197   Akaike-Kriterium       -475,2394
Schwarz-Kriterium      -470,8300   Hannan-Quinn-Kriterium -473,4946
rho                     0,040822   Durbin-Watson-Stat      1,912029
```

$\hat{\alpha}$ $\hat{\beta}$

p-Wert

t-Test Statistik

2.7.3 Testen im linearen Regressionsmodell

Steigung = 0 ?

- Von besonderer Bedeutung ist das Hypothesenpaar

$$\boxed{H_0 : \beta = 0, \quad H_1 : \beta \neq 0.}$$

- Dabei bedeutet $H_0 : \beta = 0$, dass tatsächlich $Y_i = \alpha + \varepsilon_i$, $i = 1, \dots, n$, gilt, und somit X keinen Erklärungswert für Y besitzt.
- Der ~~t-Test~~ im Ein-Stichproben-Fall kann zum Testen von Hypothesen bzgl. α und α_0, bzw. β und β_0 eingesetzt werden.
- Die Teststatistiken lauten:

$$\boxed{T_{\alpha_0} = \frac{\hat{\alpha} - \alpha_0}{\hat{\sigma}_{\hat{\alpha}}}, \quad T_{\beta_0} = \frac{\hat{\beta} - \beta_0}{\hat{\sigma}_{\hat{\beta}}}.} \quad \sim t(n-2)$$

- Der F-**Test** ist ein weiterer Test zur Prüfung von $H_0 : \beta = 0$.
- **Statistische Programmpakete** liefern typischerweise die T-**Werte** und p-**Werte** zu den Hypothesen $H_0 : \alpha = \alpha_0$ bzw. $H_0 : \beta = \beta_0$ mit $\alpha_0 = 0$ und $\beta_0 = 0$.
- Daraus lässt sich erkennen, ob das Einbeziehen von α, bzw. β in der Regressionsgleichung sinnvoll ist.

2.7.4 Prognose im linearen Regressionsmodell

- Punktschätzer zu einem neuen Wert x_0 ist

  neuer Wert

  Prognose für Y $\longrightarrow$ $\hat{Y}_0 = \hat{\alpha} + \hat{\beta} x_0.$

- Über die Varianzeigenschaften von $\hat{\alpha}$ und $\hat{\beta}$ lässt sich ein Konfidenzintervall für Y_0 bestimmen.

Bestimmtheitsmaß R^2

- Das **Bestimmtheitsmaß** R^2 gibt den relativen Anteil der Varianz der Stichprobe $(y_1, \ldots, y_n)$, der durch die Regressionsgerade erklärt wird.
- Im Fall der linearen Regression ist es definiert als

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{\alpha} + \hat{\beta} x_i - Y_i)^2}{\sum_{i=1}^n (Y_i - \overline{Y})^2}.$$

- Man kann zeigen, dass

$$R^2 = \frac{\hat{\beta}^2 \hat{\sigma}_x^2}{\hat{\sigma}_y^2} = \frac{\hat{\rho}_{xy}^2 \, \hat{\sigma}_y^2}{\hat{\sigma}_y^2} = \hat{\rho}_{xy}^2.$$

  so viel habe ich anteilig in der Stichprobenvarianz von Y erklärt

- Es ist stets $0 \leq R^2 \leq 1$, wobei
  - $R^2 = 0$ den unkorrelierten Fall, und
  - $R^2 = 1$ den Fall eines perfekten linearen Zusammenhangs

  zwischen den Merkmalen X und Y widerspiegelt.