Lektion 5

Montag, 30. November 2020 12:00

Grundgesamtheit — Stichprobe → Schlüsse aus den Daten
- Wkt, ZV
- Verteilungen
- Verteilungstypen
- Grenzwertsätze → ZGS.

- Wkt schätzen
- Parameter der Verteilung $E(\cdot)$; $V(\cdot)$ schätzen
- Verteilungstyp: Parameter schätzen
- Ist meine Schätzung gut?

Einführendes Beispiel und Grundbegriffe

- Ziel der schließenden Statistik / induktiven Statistik:
  - Ziehen von Rückschlüssen auf die Verteilung einer (größeren) Grundgesamtheit auf Grundlage der Beobachtung einer (kleineren) Stichprobe.
- Rückschlüsse können sich auch auf spezielle Eigenschaften der Verteilung beschränken, z.B. Erwartungswert.
- Wir betrachten zunächst ein elementares Beispiel.

Beispiel:

- Grundgesamtheit: $N = 4$ Kinder (Anna, Beatrice, Christian, Daniel) gleichen Alters: $\Omega = \{A, B, C, D\}$
- Interessierende Variable: monatl. Taschengeld X (in EUR) bzw. Erwartungswert $\mathbb{E}(X)$
- Verteilungsannahme: Verteilung von X unbekannt, aber sicher in der Menge der diskreten Verteilungen mit Wertemenge höchstens der Größe $N = 4$ und Punktwahrscheinlichkeiten, die Vielfaches von $1/N = 1/4$ sind.
- Z.B.: Zufallsvariable X nehme die folgenden Werte an:

ω	A	B	C	D
$X(\omega)$	15	20	25	20

- Zugehörige Verteilung:

x_i	15	20	25	Σ
$p(x_i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

Ursprüngliche ZV. X

Vollerhebung

ABER: 4 Mio Kinder "Zahlungsbereitschaft"

- In der Praxis: Verteilung von X unbekannt.
- Einfachste Möglichkeit, um Verteilung / Erwartungswert von X zu ermitteln: alle vier Kinder befragen.
- Typische Situation: nicht alle Kinder können befragt werden, sondern nur eine kleinere Anzahl $n < N$, z.B. $n = 2$.
- Erwartungswert kann nur **geschätzt** werden.
- Ziel: Rückschluss aus der Erhebung von $n = 2$ Taschengeldhöhen auf die größere Grundgesamtheit von $N = 4$ Kindern.

Teilerhebung — Stichprobenumfang

- Neben Schätzung von $\mathbb{E}X$ auch Beurteilung der Qualität der Schätzung gewünscht (mit welchem "Fehler" ist zu rechnen).
- Erhebung von 2 Taschengeldhöhen: Stichprobenzufallsvariablen X_1 und X_2.
- **Wichtig**: X_1 und X_2 sind **Zufallsvariablen**, denn **Realisationen** x_1, x_2 hängen davon ab, welche Kinder zufällig ausgewählt werden!
- Auswahlverfahren: 2-fache rein zufällige und voneinander unabhängige Auswahl eines der vier Kinder, d.h. zufälliges Ziehen mit Zurücklegen und Berücksichtigung der Reihenfolge.

- Mögliche **"Stichprobenrealisationen"** (x_1, x_2):

Stichprobenraum →

1. \ 2. K.	A	B	C	D
A	$(15, 15)$	$(15, 20)$	$(15, 25)$	$(15, 20)$
B	$(20, 15)$	$(20, 20)$	$(20, 25)$	$(20, 20)$
C	$(25, 15)$	$(25, 20)$	$(25, 25)$	$(25, 20)$
D	$(20, 15)$	$(20, 20)$	$(20, 25)$	$(20, 20)$

alle mögliche Stichprobenkonstellationen

16.

	A	B	C	D
A	15	17,5	20	17,5
B	17,5	20	22,5	20
C	20	22,5	25	22,5

- Resultierende gemeinsame Verteilung von (X_1, X_2):

Werte von X_2

$x_1 \backslash x_2$	15	20	25	Σ
15	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{4}$
20	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{2}$

Werte von →

Verteilung

Werte von X_1 →

$x_1 \setminus x_2$	15	20	25	Σ
15	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{4}$
20	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{2}$
25	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{4}$
Σ	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

Verteilung von X_1

gleich

Verteilung von X_2

B	17,5	20	22,5	20
C	20	22,5	25	22,5
D	17,5	20	22,5	20

Werte für $\overline{X}$ bei verschiedenen Stichproben

- Klar:
  - X_1 und X_2 haben dieselbe Verteilung wie X. ✓
  - X_1 und X_2 sind stochastisch unabhängig. ✓
- Schätzung des Erwartungswertes $\mathbb{E}X$ durch Mittelwert der Stichprobe.

$$\boxed{\overline{X} = \frac{1}{2}(X_1 + X_2)}$$

Mittel der Stichprobe mit Umfang 2 Kinder.

- **Wichtig**: **Nach** Auswahl der Kinder ist der Mittelwert eine Zahl; **vor** Auswahl der Kinder ist Mittelwert eine Zufallsvariable.
- **Verteilung** der Zufallsvariable $\overline{X} = \frac{1}{2}(X_1 + X_2)$:

diskrete ZV.

Stichprobe

Verteilung

$\overline{x}_i$	15	17,5	20	22,5	25	Σ
$p(\overline{x}_i)$	$\frac{1}{16}$	$\frac{1}{4}$	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{16}$	1

$$\boxed{E(\overline{X}) = \sum_{i=1}^{5} \overline{x}_i \cdot p(\overline{x}_i)}$$

mit Erwartungswert $\mathbb{E}\overline{X} = 20$ und Standardabweichung $\sqrt{\mathrm{Var}(\overline{X})} = 2,5$.

d.h. mit meiner Schätzung werde ich tendenziell richtig liegen

- Verteilung von X (Taschengeld)

y_i	15	20	25	Σ
$p(y_i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

$$E(X) = \sum_{i=1}^{3} y_i \cdot p(y_i)$$

Grundgesamtheit

hat Erwartungswert $\mathbb{E}X = 20$ und Standardabweichung $\sqrt{\mathrm{Var}(X)} = 3.5355$.

Zufallsstichprobe (Definition):

Seien $X_1, \ldots, X_n$ Zufallsvariablen einer Stichprobe zu X. Dann ist $(X_1, \ldots, X_n)$ eine **Zufallsstichprobe** (**Stichprobenvariable**) vom Umfang n zu X, falls die Verteilungen von X und X_i, $i = 1, 2, \ldots, n$, übereinstimmen und $X_1, \ldots, X_n$ stochastisch unabhängig sind.

Verteilung von Merkmal von Interesse (X) übereinstimmt mit den Verteilungen von Stichprobenvariablen $(X_1, X_2, \ldots X_n)$

Stichprobenrealisation / Stichprobenraum (Definition):

Sei $(X_1, \ldots, X_n)$ eine Zufallsstichprobe zu X.

- Die beobachteten Realisationen $(x_1, \ldots, x_n)$ der Zufallsvariablen $(X_1, \ldots, X_n)$ heißen **Stichprobenrealisation**. → Daten
- Die Menge $\mathcal{X}$ aller möglichen Stichprobenrealisationen heißt **Stichprobenraum**.

- Bemerkung: $\mathcal{X} \subseteq \mathbb{R}^n$.

Beispiel: Kundenumfrage

p - ?

Sie wollen Ihre App weiterentwickeln und interessieren sich für den **Anteil von App-Nutzer** in Ihrer gesamten Kundschaft sowie für das **mittlere Alter Ihrer Kunden**. E(X) - ?

So führen Sie eine Kundenumfrage durch. Der Umfrageumfang n ist:

n = 20

neue Stichprob

Die Umfrageergebnisse sehen so aus:

Die ersten 10 Kunde

Kunde	1	2	3	4	5	6	7	8	9	10
Alter	26	40	26	41	20	17	62	26	33	36
App_Nutzung	nein	nein	nein	ja	ja	nein	nein	ja	nein	nein

nur eine von vielen möglichen Stichprobenrealisationen

- Eine **Stichprobe** dient der Informationsgewinnung über das Verhalten eines **Merkmals in der Grundgesamtheit**.
- Dies erfordert ein **Modell**, das die **Verteilung** des interessierenden Merkmals in der Grundgesamtheit beschreibt.
- Eine **Schätzung** hängt dabei stets von der **konkreten Stichprobe** ab, und **variiert**, falls eine erneute Stichprobe gezogen wird.
- Wichtige Fragen:
  - **Wie wähle ich einen geeigneten Schätzer?** Tendenz
  - **Wie gut ist mein Schätzer**, bzw. wie nah kommt er an den wahren Parameter heran? Varianz / Streuung möglich klein ist
  - **Wie stabil ist mein Schätzer**, d.h. wie stark schwankt er von Stichprobe zu Stichprobe?

Schätzung

wahre Parameter

Schätzwerte: der Anteil von Appnutzern und das mittlere Kundenalter in der vorliegenden Stichprobe sind **0.55 und 31.65**

Schätzwerte

die wahren Parameter

0.6 und 30 → wahre Parameter

Schätzwerte bei wiederholten Erhebungen (100 Mal):

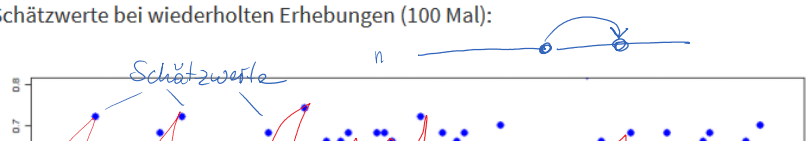

erstrebenswerte Eigenschaften:

- richtige Tendenz → Erwartungstreu
- will dass die Schwankungen möglichst klein sind → Konsistenz ($n \to \infty$ - konvergiert)

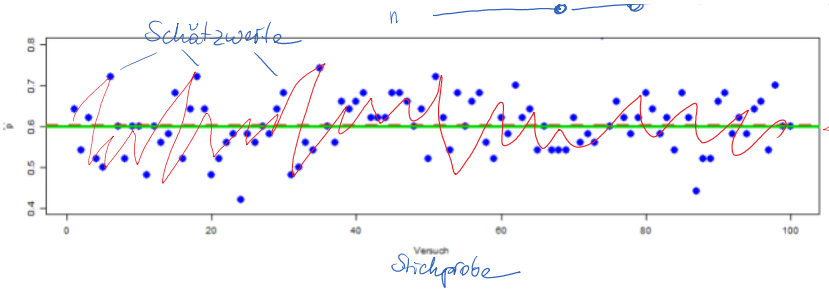

- richtige Tendenz → Erwartungstreu
- will dass die Schwankungen möglichst klein sind (mit wachsendem n) → Konsistenz ($n \to \infty$ – konvergiert unser Schätzer)
- wähle den Schätzer mit der kleinsten Varianz → Effizienz.

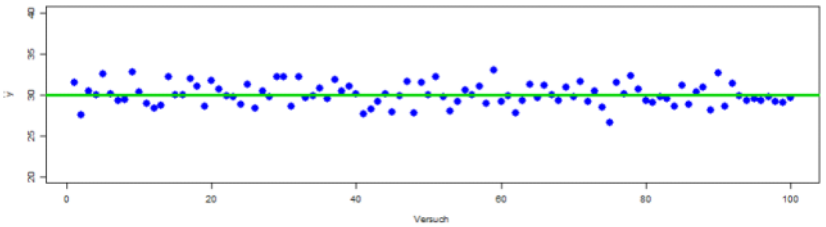

Geforderte Genauigkeit für Anteil von Appnutzern:

Genauigkeit

0.01 0.05 0.1

Sicherheitsniveau: mit welcher Wahrscheinlichkeit wird die Genauigkeit gefordert?

Wahrscheinlichkeit

0,95

Benötigter Stichprobenumfang 385

→ Verteilungseigenschaften des Schätzers nutzen um den "optimalen" Stichprobenumfang zu finden.