Lektion 9

Montag, 25. Januar 2021 12:30

Hypothesentests

(p) Approximativer Binomialtest

1) $H_0: p = p_0$ gegen $H_1: p \neq p_0$
$H_0: p = p_0$ gegen $H_1: p < p_0$
$H_0: p = p_0$ gegen $H_1: p > p_0$.

2) Signifikanzniveau α, $0 < \alpha < 1$

3) $Z = \frac{X - n p_0}{\sqrt{n p_0 (1-p_0)}} \overset{\text{approx.}}{\sim} N(0,1)$ für $n > 30$ (X: Anzahl von Erfolge)

4) Ablehnungsbereich
falls $|z| > N_{1-\alpha/2}$
falls $z < -N_{1-\alpha}$
falls $z > N_{1-\alpha}$.

5) Stichprobe → Wert der Teststatistik

p-Wert
P-Wert Kalkulation
Nullhypothese wird abgelehnt, wenn
H₁ "≠": $2 \cdot \min(P(Z \le z), P(Z \ge z))$
H₁ "<": $P(Z \le z \mid H_0)$
H₁ ">": $P(Z \ge z \mid H_0)$

unter der Standardnormalverteilung
α im Ablehnungsbereich

6) Testentscheidung (Ablehnung falls) → p-Wert < α

(μ) σ^2-bekannt

Gauß-Test

(a) $H_0: \mu = \mu_0$ gegen $H_1: \mu \neq \mu_0$
(b) "≥" $H_0: \mu = \mu_0$ gegen $H_1: \mu < \mu_0$
(c) "≤" $H_0: \mu = \mu_0$ gegen $H_1: \mu > \mu_0$.

$$Z = \sqrt{n}\,\frac{\overline{X} - \mu_0}{\sigma} = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \overset{\text{approx.}}{\sim} N(0,1).$$

(a) falls $|z| > N_{1-\alpha/2}$
(b) falls $z < -N_{1-\alpha}$
(c) falls $z > N_{1-\alpha}$.

(μ) σ^2-unbekannt

t-Test

(a) $H_0: \mu = \mu_0$ gegen $H_1: \mu \neq \mu_0$
(b) $H_0: \mu = \mu_0$ gegen $H_1: \mu < \mu_0$
(c) $H_0: \mu = \mu_0$ gegen $H_1: \mu > \mu_0$.

$$T = \frac{\overline{X} - \mu_0}{S}\sqrt{n} \sim t(n-1), \text{ mit } S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

(n-1) übernehmen aus χ^2-Verteilung

Stichprobenvarianz

ein Parameter schon geschätzt

(a) $|T| > t_{1-\alpha/2}(n-1)$
(b) $T < t_\alpha(n-1) = -t_{1-\alpha}(n-1)$
(c) $T > t_{1-\alpha}(n-1)$

← t-Quantile

p-Wert unter der t-Verteilung mit (n-1) Freiheitsgraden

Regressionsanalyse

Exkurs: χ^2-Verteilung

$Y = X_1^2 + X_2^2 + \dots + X_n^2$, wo $X_i \sim N(0,1)$

$Y \sim \chi^2(n)$

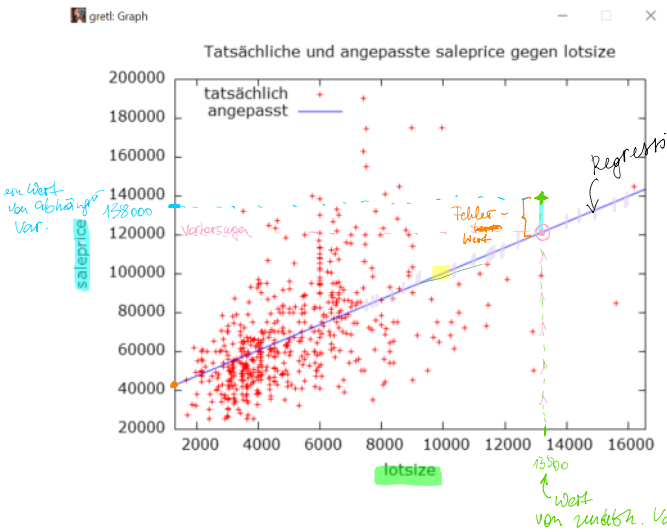

Regressionsgerade mit Steigung $\hat{\beta}$ (geschätzt) und Intercept $\hat{\alpha}$ (geschätzt)

$$\text{Salesprice}_i = \alpha + \beta \cdot \text{Lotsize}_i + \varepsilon_i$$

erklärte Variable
abhängige Var./Regressand

erklärende Variable
unabhängige Var./Regressor

Fehlerterm
Residuum

Standardmodell der linearen Einfachregression: Es gilt:

ZV ZV

$$Y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n.$$

deterministisch

Dabei sind:

- $Y_1, \dots, Y_n$: beobachtbare metrische Zufallsvariable;
- $x_1, \dots, x_n$: gegebene deterministische Werte;
- $\varepsilon_1, \dots, \varepsilon_n$: unbeobachtbare ZV'en, die unabhängig und identisch verteilt sind mit $\mathbb{E}(\varepsilon_i) = 0$, $\mathrm{Var}(\varepsilon_i) = \sigma^2$.

Die Regressionskoeffizienten α, β und die Varianz σ^2 sind unbekannte Parameter, die aus den Daten (y_i, x_i), $i = 1, \dots, n$ zu schätzen sind.

- Es gilt:

$$\begin{aligned} \mathbb{E}(Y_i) &= \mathbb{E}(\alpha + \beta x_i + \varepsilon_i) = \alpha + \beta x_i \\ \mathrm{Var}(Y_i) &= \mathrm{Var}(\alpha + \beta x_i + \varepsilon_i) = \sigma^2. \end{aligned}$$

Schätzen, Testen und Prognose:

- Im folgenden befassen wir uns mit folgenden Aspekten des linearen Regressionsmodells:
  - Punkt- und Intervallschätzung der unbekannten Parameter α, β, σ^2
  - Testen von Hypothesen über die Regressionskoeffizienten α, β
  - Prognose der Zielvariablen Y für neuen Wert x

- Punkt- und Intervallschätzung der unbekannten Parameter α, β, σ^2
- Testen von Hypothesen über die Regressionskoeffizienten α, β
- Prognose der Zielvariablen Y für neuen Wert x

Normalverteilungsannahme:

Es sei

$$\varepsilon_i \sim \mathrm{N}(0, \sigma^2), \quad i = 1, \ldots, n,$$

bzw.

$$Y_i \sim \mathrm{N}(\alpha + \beta x_i, \sigma^2), \quad i = 1, \ldots, n.$$

Kleinste-Quadrate-Schätzer:

was ich beobachte

modell

- **Kleinste-Quadrate-Methode**: Bestimme $\hat{\alpha}$ und $\hat{\beta}$, so dass

$$\sum_{i=1}^n (Y_i - (\alpha + \beta x_i))^2 \quad \to \quad \min_{\alpha,\beta}$$

- Minimieren ergibt:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \hat{\rho}_{XY} \frac{\hat{\sigma}_Y}{\hat{\sigma}_X},$$

Standardabweichung von y

Standardabweichung von X

Korelation X,y

$$\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{x},$$

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} x_i)^2,$$

← Stichproben basierte geschätzte Fehlervarianz

mit **Residuen** $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$ und **gefitteten Werten** $\hat{Y}_i = \hat{\alpha} + \hat{\beta} x_i, i = 1, \ldots, n$.

gretl: Modell 1

Datei Bearbeiten Tests Speichern Graphen Analyse LaTeX

```
Modell 1: KQ, benutze die Beobachtungen 1-546   n=546
Abhängige Variable: saleprice

             Koeffizient   Std.-fehler   t-Quotient    p-Wert
  ---------------------------------------------------------------
  const      34136,2       2491,06         13,70       6,28e-037 ***
  lotsize        6,59877     0,445847      14,80       6,77e-042 ***

Mittel d. abh. Var.      68121,60   Stdabw. d. abh. Var.     26702,67
Summe d. quad. Res.      2,77e+11   Stdfehler d. Regress.    22567,05
R-Quadrat                0,287077   Korrigiertes R-Quadrat   0,285766
F(1, 544)                219,0558   P-Wert(F)                6,77e-42
Log-Likelihood          -6246,977   Akaike-Kriterium         12497,95
Schwarz-Kriterium        12506,56   Hannan-Quinn-Kriterium   12501,32
```

Geschätzte Regressionsgerade:

$\text{Salesprice}_i = 34136{,}2 + 6{,}59877 \cdot \text{Lotsize}_i$

Interpretation:

Salesprice steigt im Mittel um 6,59877 pro zusätzliche Einheit von Lotsize.

Schätzen im linearen Regressionsmodell:

- Man beachte, dass $\hat{\alpha}$, $\hat{\beta}$ und $\hat{\sigma}^2$ von den Zufallsvariablen $Y_1, \ldots, Y_n$ abhängen, und es sich um Schätzfunktionen handelt.
- Diese sind erwartungstreu:

$$\mathbb{E}(\hat{\alpha}) = \alpha, \quad \mathbb{E}(\hat{\beta}) = \beta, \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2,$$

- Es gilt:

$$\mathrm{Var}(\hat{\alpha}) = \sigma^2_{\hat{\alpha}} = \sigma^2 \frac{\sum x_i^2}{n\left(\sum x_i^2 - n\bar{x}^2\right)}$$

Gretl → $\hat{\sigma}_{\hat{\alpha}} = \sqrt{Var(\hat{\alpha})}$

$$\mathrm{Var}(\hat{\beta}) = \sigma^2_{\hat{\beta}} = \frac{\sigma^2}{\sum x_i^2 - n\bar{x}^2}$$

Gretl → $\hat{\sigma}_{\hat{\beta}} = \sqrt{Var(\hat{\beta})}$

- Unter der Normalverteilungsannahme gilt:

$$\varepsilon_i \sim \mathrm{N}(0, \sigma^2), \quad Y_i \sim \mathrm{N}(\alpha + \beta_i, \sigma^2), \quad \hat{\alpha} \sim \mathrm{N}(\alpha, \sigma^2_{\hat{\alpha}}), \quad \hat{\beta} \sim \mathrm{N}(\beta, \sigma^2_{\hat{\beta}}).$$

Quiz

Anhand der Daten $(x_1, y_1), \ldots, (x_N, y_N)$ haben Sie das folgende Modell geschätzt $y = b_0 + b_1 \cdot x$. Die folgende Tabelle wurde als Ausgabe erzeugt:

Steigung

Intercept

	Estimate	Standard Error	t-Statistic	p--Value
1	-0.0549913 (b_0)	0.0614995	-0.894174	0.373419
x	-0.911991 (b_1)	0.0660768	-13.802	$1.03856 \cdot 10^{-24}$

Welche der folgenden Aussagen treffen zu?

Wählen Sie eine Antwort:

A a. Die geschätzten Koeffizienten sind nicht in der Tabelle enthalten

B b. Die geschätzten Koeffizienten sind $\hat{b}_0 = -0,911991$ und $\hat{b}_1 = -0,0549913$.

C c. Die geschätzten Koeffizienten sind $\hat{b}_0 = -0,0549913$ und $\hat{b}_1 = -0,911991$.

D d. Die geschätzten Koeffizienten sind $b_0 = -0,894174$ und $b_1 = -13,802$.

A		1	5%
B		1	5%
C		5	26%
D		0	0%

Früher: nur ein Parameter geschätzt $E(Y) = \text{const}$
Jetzt: werden zwei Parameter geschätzt: $E(Y) = \alpha + \beta x$

Verteilung der standardisierten Schätzfunktionen:

Unter der Normalverteilungsannahme gilt:

$$\boxed{\frac{\hat{\alpha}-\alpha}{\hat{\sigma}_{\hat{\alpha}}} \sim t(n-2)}, \quad \boxed{\frac{\hat{\beta}-\beta}{\hat{\sigma}_{\hat{\beta}}} \sim t(n-2)}.$$

geschätzt

Konfidenzintervalle für α und β:

$$\boxed{\hat{\alpha} \pm \hat{\sigma}_{\hat{\alpha}}\, t_{1-\alpha/2}(n-2)}, \quad \boxed{\hat{\beta} \pm \hat{\sigma}_{\hat{\beta}}\, t_{1-\alpha/2}(n-2)}.$$

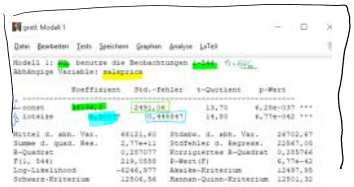

n-2
546-2=544
Freiheitsgrade
die unteren Grenzen
die oberen Grenzen

Berechnen ($\hat{\beta}$) $\alpha = 5\%$

$$\left[\hat{\beta} - \hat{\sigma}_{\hat{\beta}} \cdot t_{1-\alpha/2}(n-2) \; ; \; \hat{\beta} + \hat{\sigma}_{\hat{\beta}}\, t_{1-\alpha/2}(n-2)\right] =$$

$$\left[6{,}59877 - 0{,}4458 \cdot 1{,}964 \; ; \; 6{,}59877 + 0{,}4458 \cdot 1{,}964\right] =$$

$$\left[5{,}7232 \; ; \; 7{,}4743\right].$$

Testen im linearen Regressionsmodell

- Von besonderer Bedeutung ist das Hypothesenpaar

$$\boxed{H_0: \beta = 0, \quad H_1: \beta \neq 0.}$$

← Prüfe Signifikanz von β (ob β von Null verschieden ist)

- Dabei bedeutet $H_0: \beta = 0$, dass tatsächlich $Y_i = \alpha + \varepsilon_i$, $i = 1, \ldots, n$, gilt, und somit X keinen Erklärungswert für Y besitzt.
- Der t-Test im Ein-Stichproben-Fall kann zum Testen von Hypothesen bzgl. α und α_0, bzw. β und β_0 eingesetzt werden.
- Die Teststatistiken lauten:

(t-Test, da die Fehlervarianz σ^2 immer geschätzt wird)

$$\boxed{T_{\alpha_0} = \frac{\hat{\alpha}-\alpha_0}{\hat{\sigma}_{\hat{\alpha}}}}, \quad \boxed{T_{\beta_0} = \frac{\hat{\beta}-\beta_0}{\hat{\sigma}_{\hat{\beta}}}}.$$

$$\boxed{T_0 = \frac{\hat{\alpha}}{\hat{\sigma}_{\hat{\alpha}}}}; \quad \boxed{T_0 = \frac{\hat{\beta}}{\hat{\sigma}_{\hat{\beta}}}}$$

Beispiel:

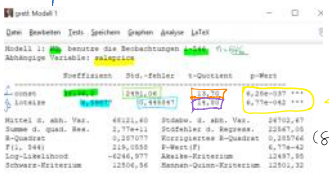

$< \alpha$ 0,01 (Signifikanz)

Testentscheidung:
- Vergleiche die Werte der Teststatistiken mit den kritischen Werten (Ablehnungsbereiche)
- p-Werte Vergleich mit α:
  - H_0 von $\alpha = 0$ bzw. H_0 von $\beta = 0$ ablehnen.

Beispiel:

- $H_0: \beta \leq 6$ $\qquad H_1: \beta > 6$
- Signifikanz $= 5\%$
- $T = \dfrac{\hat{\beta} - 6}{\hat{\sigma}_{\hat{\beta}}} \sim t(n-2) = t(544)$
- $t = \dfrac{6{,}59877 - 6}{0{,}4458} = \underline{1{,}3431}$
- $t \not> t_{0{,}95}(544) = 1{,}6477 \rightarrow H_0$ nicht ablehnen.

Prognose im linearen Regressionsmodell

- Punktschätzer zu einem neuen Wert x_0 ist

$$\hat{Y}_0 = \hat{\alpha} + \hat{\beta} x_0.$$

- Über die Varianzeigenschaften von $\hat{\alpha}$ und $\hat{\beta}$ lässt sich ein Konfidenzintervall für Y_0 bestimmen.

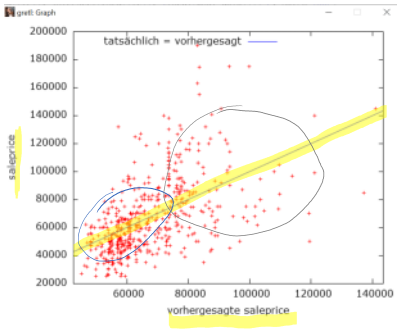

Beispiel: $x_0 = 10'000$

$$\hat{y}_0 = 34136{,}2 + 6{,}59877 \cdot 10'000 = \underline{100\,123{,}9}$$

Preisvorhersage für Grundstücksgröße x_0 von 10'000

Bestimmtheitsmaß R^2

- Das **Bestimmtheitsmaß** R^2 gibt den relativen Anteil der Varianz der Stichprobe $(y_1, \ldots, y_n)$, der durch die Regressionsgerade erklärt wird.
- Im Fall der linearen Regression ist es definiert als

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(\hat{\alpha}+\hat{\beta}x_i - Y_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}$$

unerklärter Anteil an Varianz

- Man kann zeigen, dass

$$\boxed{R^2 = \frac{\hat{\beta}^2 \hat{\sigma}_x^2}{\hat{\sigma}_y^2} = \frac{\rho_{xy}^2 \sigma_y^2}{\hat{\sigma}_y^2} = \hat{\rho}_{xy}^2}$$

- Es ist stets $0 \leq R^2 \leq 1$, wobei
  - $R^2 = 0$ den unkorrelierten Fall, und
  - $R^2 = 1$ den Fall eines perfekten linearen Zusammenhangs

  zwischen den Merkmalen X und Y widerspiegelt.

gretl: Modell 1

Datei Bearbeiten Tests Speichern Graphen Analyse LaTeX

```
Modell 1: KQ, benutze die Beobachtungen 1-546
Abhängige Variable: saleprice

             Koeffizient   Std.-fehler   t-Quotient    p-Wert
  ---------------------------------------------------------------
  const      34136,2       2491,06         13,70       6,28e-037 ***
  lotsize        6,59877      0,445847     14,80       6,77e-042 ***

Mittel d. abh. Var.      68121,60   Stdabw. d. abh. Var.    26702,67
Summe d. quad. Res.      2,77e+11   Stdfehler d. Regress.   22567,05
R-Quadrat                0,287077   Korrigiertes R-Quadrat  0,285766
F(1, 544)                219,0558   P-Wert(F)               6,77e-42
Log-Likelihood          -6246,977   Akaike-Kriterium        12497,95
Schwarz-Kriterium        12506,56   Hannan-Quinn-Kriterium  12501,32
```

Quiz

Das nachfolgende Diagramm zeigt eine Stichprobe zu zwei Merkmalen X und Y zusammen mit der berechneten Regressionsgeraden:

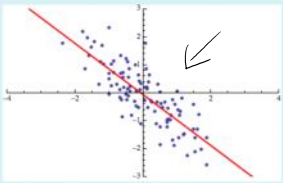

$\hat{\rho}_{xy} < 0$

Welche der folgenden Aussage passt am besten zu den Eigenschaften der Daten und der Regressionsgerade?

Wählen Sie eine Antwort:

A a. Die Korrelation ist $0,81$ und der R^2 ist $0,66$.

B b. Die Korrelation ist $-0,81$ und der R^2 ist $-0,66$.

C c. Die Korrelation ist $0,81$ und der R^2 ist $-0,66$.

D d. Die Korrelation ist $-0,81$ und der R^2 ist $0,66$. ← $R^2 = \hat{\rho}_{xy}^2 = (-0{,}81)^2 \cong \underline{0{,}66}$.

A		0	0%
B		0	0%
C		0	0%
D		5	29%

Ende