2.3 Konstruktion von Schätzfunktionen

- Bislang haben wir bereits bekannte spezielle Schätzfunktionen betrachtet.
- In diesem Abschnitt entwickeln wir allgemeine Methoden, Schätzfunktionen für unbekannte Parameter zu finden.
- Wir befassen uns mit folgenden Methoden:

  I **Momenten-Methode** (MM)

  II **Maximum-Likelihood-Schätzung** (ML)

2.3.1 Momenten-Methode

$Var(X) = \sigma^2$

$Var(X) = E(X^2) - (E(X))^2$

$E(X^2) = Var(X) + (E(X))^2$

$\sigma^2 + \mu^2$

- Grundlegende Idee: Schätze Parameter der Verteilung so, dass zugehörige **Momente** $\mathbb{E}(X), \mathbb{E}(X^2), \ldots$ mit den entsprechenden empirischen Momenten der Stichprobenvariablen übereinstimmen:

(theoretisch)	Verteilung	Stichprobe	(empirisch)
1. Moment	$\mathbb{E}(X) = \mu$	$\frac{1}{n}\sum_{i=1}^{n} x_i$	$= \boxed{\overline{x}}$
2. Moment	$\mathbb{E}(X^2) = \mu^2 + \sigma^2$	$\frac{1}{n}\sum_{i=1}^{n} x_i^2$	$= \boxed{\overline{x^2}}$
$\vdots$	$\vdots$	$\vdots$	
m. Moment	$\mathbb{E}(X^m)$	$\frac{1}{n}\sum_{i=1}^{n} x_i^m$	$= \overline{x^m}$

Idee:
→ Setze die theor. Momente gleich den empirischen
→ Stelle um und rechne die Schätzwerte aus

- Es werden dabei – beginnend mit dem ersten Moment – gerade so viele Momente einbezogen, dass alle zu schätzenden Parameter eindeutig geschätzt werden können.

Beispiel 2.3.1. *Momenten-Methode*

- *Schätzung des Parameters* p *einer* **Bernoulli-Verteilung**:
  - *Verteilungsannahme:* $\mathbb{P} \in \{B(1,p) | p \in \Theta = [0,1]\}$
  - *Erstes Moment:* $\boxed{\mathbb{E}(X) = p}$ ← Erwartungswert der Bernoulli-Vert mit p.
  - *Schätzer:* $\mathbb{E}(X) = \overline{x} \rightarrow \boxed{\hat{p}_{MM} = \overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i}$ ← Schätzer für p

  Beispiel: Schätzung des Appnutzeranteils anhand einer Kundenbefragung.

Stichprobe:
1; 1; 0; 1

Schätzwert für p:
$\hat{p}_{MM} = \frac{1}{4}(1+1+0+1) = \underline{0{,}75}$

- *Schätzung des Parameters* λ *einer* **Exponentialverteilung**:
  - *Verteilungsannahme:* $\mathbb{P} \in \{E(\lambda) | \lambda > 0\}$ $X \sim E(\lambda)$
  - *Erstes Moment:* $\boxed{\mathbb{E}(X) = \frac{1}{\lambda}}$ ← Erwartungswert der Exponentialverteilung
  - *Schätzer:* $\mathbb{E}(X) = \overline{x} \rightarrow \frac{1}{\lambda} = \overline{x} \rightarrow \boxed{\hat{\lambda}_{MM} = \frac{1}{\overline{x}}}$ ← Schätzer für λ.

nur ein Parameter
↝ brauche nur den 1. Moment

Stichprobe:
0,95; 1,81; 1; 0,67

Schätzwert für λ:
$\hat{\lambda}_{MM} = \frac{1}{\overline{x}}$

$\overline{x} = \frac{1}{4}(0{,}95 + 1{,}81 + 1 + 0{,}67) = \underline{1{,}1075}$

$\hat{\lambda}_{MM} = \frac{1}{1{,}1075} = \underline{0{,}9029}$

Beispiel: Schätzung von λ für die Verteilung der relativen Bewertungslängen.

- *Schätzung der Parameter (μ,σ^2) einer* **Normalverteilung**:
  - *Verteilungsannahme:* $\mathbb{P} \in \{\mathsf{N}(\mu,\sigma^2) | \mu \in \mathbb{R}, \sigma^2 > 0\}$
  - *Erstes Moment:* $\mathbb{E}(X) = \mu$ $\longrightarrow$ $E(X) = \bar{x} \longrightarrow \boxed{\hat{\mu}_{ML} = \bar{x}}$ Schätzer für μ
  - *Zweites Moment:* $\mathbb{E}(X^2) = \mu^2 + \sigma^2$ $\longrightarrow$ $E(X^2) = \overline{x^2} \longrightarrow \mu^2 + \sigma^2 = \overline{x^2}$
  - *Einsetzen der empirischen Momente gibt:* $\sigma^2 = \overline{x^2} - \mu^2$ Schätzer für σ^2

    $\boxed{\hat{\sigma}^2_{ML} = \overline{x^2} - (\bar{x})^2}$

Beispiel: Verteilungsparameter für die durchschnittliche Temperatur im Juli.

2.3.2 Maximum-Likelihood-Methode

Maximum-Likelihood-Schätzung

- Seien $X_1, \dots, X_n$ unabhängige, identisch verteilte Zufallsvariablen.
- Die Verteilung der X_i, $i = 1, \dots, n$ ist unbekannt, aber wir nehmen an, die Verteilung gehöre zu einer **Verteilungsklasse**, die durch eine geeignete **Parametrisierung** charakterisiert ist.
- Formal: X_i hat Wahrscheinlichkeitsfunktion oder Dichte $f(x|\theta)$, $\theta \in \Theta$, wobei θ ein Vektor von Parametern aus der Menge Θ ist.
- Das **Maximum-Likelihood-Prinzip** besagt: maximiere die Wkt der Stichprobe unter der angenommenen Verteilung

  Man wähle zum Stichprobenergebnis $(x_1, \dots, x_n)$ denjenigen Wert $\hat{\theta}$ als Schätzwert für θ, unter dem die Wahrscheinlichkeit für das Eintreten des Stichprobenergebnisses am größten ist.
- "unter dem die Wahrscheinlichkeit für das Eintreten des Ergebnisses am größten ist" kann ersetzt werden durch: "unter dem die entsprechende Wahrscheinlichkeitsfunktion oder Dichte maximal ist".

Schreibe die Wkt der Stichprobe mittels Wkfunktion bzw. Dichte auf und maximiere diese Wkt.

Beispiel 2.3.2. *Maximum-Likelihood-Schätzung: Wahrscheinlichkeit*

- *Die* **Bernoulli-Verteilung** *hat Wahrscheinlichkeitsfunktion*

$$f(x|p) = \begin{cases} p, & x = 1, \\ 1-p, & x = 0 \end{cases} \longrightarrow \quad f(x|p) = \mathbb{P}(X = x|p) = p^x \cdot (1-p)^{1-x}, \quad x \in \{0,1\},$$

  mit $p \in [0,1]$ (also $\theta = p$, $\Theta = [0,1]$).

- *Die* **Normalverteilung** *hat Dichte*

$$f(x|\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),$$

  mit $\mu \in \mathbb{R}$ und $\sigma^2 \in \mathbb{R}_+$ (also $\theta = (\mu,\sigma^2)$ und $\Theta = \mathbb{R} \times \mathbb{R}_+$).

- Wegen der **Unabhängigkeit** der Zufallsstichprobe gilt für die gemeinsame Wahrscheinlichkeitsfunktion / Dichte:

Dichte / Wktsfunktion der Stichprobe

$$f(x_1, \dots, x_n|\theta) = \underbrace{f(x_1|\theta)}_{\text{''' von } x_1} \cdot \underbrace{f(x_2|\theta)}_{\text{''' von } x_2} \cdot \dots \cdot \underbrace{f(x_n|\theta)}_{\text{''' von } x_n}.$$

- Ist eine Realisierung $(x_1, \dots, x_n)$ gegeben, so lässt sich die Dichte als Funktion der unbekannten Parameter θ auffassen, der sogenannten **Likelihood-Funktion**

Likelihood-Funktion

$$L(\theta) = f(x_1, \dots, x_n|\theta). = f(x_1|\theta) \cdot f(x_2|\theta) \cdot \dots \cdot f(x_n|\theta)$$

Das **Maximum Likelihood-Prinzip** besagt: Wähle zu $x_1, \dots, x_n$ als Parameterschätzung denjenigen Parameter $\hat{\theta}$, für den die **Likelihood maximal** ist, d.h.

$$\boxed{L(\hat{\theta}) = \max_{\theta} L(\theta),}$$

bzw.

$$f(x_1, \dots, x_n|\hat{\theta}) = \max_{\theta} f(x_1, \dots, x_n|\theta).$$

- Man wählt zu den gegebenen Realisationen $x_1, \dots, x_n$ denjenigen Parameter $\hat{\theta}$, für den die Wahrscheinlichkeit bzw. Dichte, dass gerade diese Werte auftreten, maximal ist.

- Anders ausgedrückt: es handelt sich um diejenigen Parameter θ, die die **plausibelste Erklärung** für das Zustandekommen dieser Werte liefern.

- Die Schätzung hängt insbesondere von der Stichprobe ab: $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$.

- Die Schätzfunktion $g(x_1, \dots, x_n) = \hat{\theta}(x_1, \dots, x_n)$ heißt **Maximum-Likelihood-Schätzer**.

- Zur praktischen Bestimmung des Maximums wählt man häufig den Logarithmus der Likelihood-Funktion, die **Log-Likelihood**, da diese das Produkt der Dichten in eine Summe überführt:

$\ln(a \cdot b \cdot c) = \ln a + \ln b + \ln c$

log-Likelihood Funktion

$$\mathcal{L}(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln f(x_i|\theta).$$

- Wegen der strengen Monotonie des Logarithmus liefern das Maximieren von $L(\theta)$ und $\ln L(\theta)$ denselben Wert $\hat{\theta}$.

Beispiel 2.3.3. *Maximum-Likelihood-Schätzung*

- *Ziehe* $n = 4$ *Kugeln aus Urne mit* r *roten und* s *schwarzen Kugeln (mit Zurücklegen); Mischungsverhältnis* $p = \frac{r}{r+s}$ *unbekannt.*

$X = \begin{cases} 1, & \text{wenn rot} \\ 0, & \text{sonst} \end{cases}$

$\hookrightarrow X \sim Ber(p)$

$\hookrightarrow f(x) = \begin{cases} p, & x = 1 \\ 1-p, & x = 0 \end{cases}$

- *Also:* 4 *unabhängige Wiederholungen des Bernoulli-Experiments "Ziehen einer roten Kugel".*

- *Die Stichprobe ist* $x_1 = 1$, $x_2 = 1$, $x_3 = 0$, $x_4 = 1$.

Wert der gezogenen Stichprobe

- *Likelihood-Funktion (s. nächste Folie):*

$$L(p) = f(x_1|p) \cdots f(x_4|p) = \underbrace{p}_{f(x_1|p)} \cdot \underbrace{p}_{f(x_2|p)} \cdot \underbrace{(1-p)}_{f(x_3|p)} \cdot \underbrace{p}_{f(x_4|p)} = p^3 \cdot (1-p) = \boxed{p^3 - p^4}$$

$f(x) = x^n$

$\hookrightarrow f'(x) = n \cdot x^{n-1}$

$\boxed{L(p) = p^3 - p^4} \xrightarrow[p]{} \max$

- *Ableiten und Nullsetzen ergibt:*

$$L'(p) = 3p^2 - 4 \cdot p^3 \overset{!}{=} 0 \Rightarrow p^2(3 - 4p) \overset{!}{=} 0$$

$$3 - 4p = 0$$

$L''(p) = 6p - 12p^2$
$= 6 \cdot \frac{3}{4} - 12\left(\frac{3}{4}\right)^2$
$= -2{,}25 < 0$
also max.!

- *Maximum bei* $\boxed{\hat{p}_{ML} = \frac{3}{4}}$ ← ML-Schätzer für p

- *Darstellung der Likelihood-Funktion:*

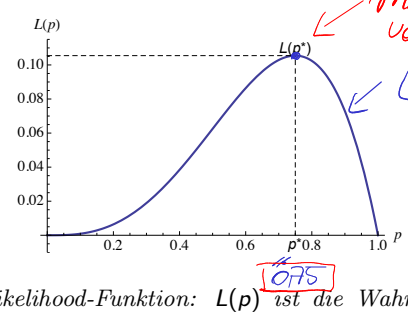

Maximum von $L(p)$

$L(p) = p^3 - p^4$

- *Interpretation der Likelihood-Funktion:* $L(p)$ *ist die Wahrscheinlichkeit für das gemeinsame Auftreten der Beobachtungen* $x_1 = 1, x_2 = 1, x_3 = 0$ *und* $x_4 = 1$ *unter der Annahme das* $\mathbb{P}(X = 1) = p$.

$\ln(a^b) = b \cdot \ln(a)$
$\ln(e) = 1$
$(\ln(x))' = \frac{1}{x}$

Beispiel 2.3.4. *Maximum-Likelihood-Schätzung: Exponentialverteilung*

- *Seien $X_1, \dots, X_4$ unabhängige Wiederholungen einer exponentell-verteilten Größe mit zu schätzendem Wert λ.* $X \sim E(\lambda) \longrightarrow$ Dichte: $f(x) = \lambda \cdot e^{-\lambda \cdot x}$
- *Stichprobe:* $x_1 = 0{,}95$, $x_2 = 1{,}81$, $x_3 = 1$, $x_4 = 0{,}67$
- *Likelihood-Funktion:*

$$\lambda^4 \cdot e^{-\lambda \cdot 4{,}43} = \lambda^4 \cdot e^{-\lambda(0{,}95+1{,}81+1+0{,}67)} = L(\lambda) = f(x_1|\lambda) \cdot f(x_2|\lambda) \cdot f(x_3|\lambda) \cdot f(x_4|\lambda) = \lambda \cdot e^{-\lambda \cdot 0{,}95} \cdot \lambda \cdot e^{-\lambda \cdot 1{,}81} \cdot \lambda \cdot e^{-\lambda \cdot 1} \cdot \lambda \cdot e^{-\lambda \cdot 0{,}67}$$

- *Log-Likelihood-Funktion:* $\mathcal{L}(\lambda) = \ln L(\lambda) = \ln(\lambda^4 \cdot e^{-\lambda \cdot 4{,}43}) = \ln(\lambda^4) + \ln(e^{-\lambda \cdot 4{,}43})$
$= 4 \ln \lambda + (-4{,}43\lambda) \ln(e)$

$$\boxed{\ln L(\lambda) = 4 \ln \lambda - 4{,}43\lambda} \xrightarrow[\lambda]{} \max$$

- *Ableiten und Nullsetzen:*

$$(\ln L(\lambda))' = \frac{4}{\lambda} - 4{,}43 \overset{!}{=} 0 \longrightarrow \boxed{\hat{\lambda}_{ML} = \frac{4}{4{,}43} = 0{,}9029}$$

- *Zweite Ableitung:*

$$(\ln L(\lambda))'' = -\frac{4}{\lambda^2} < 0$$

$\hookrightarrow$ max!

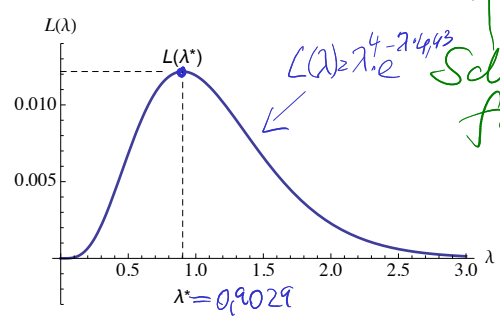

$L(\lambda) = \lambda^4 \cdot e^{-\lambda \cdot 4{,}43}$

Schätzwert für λ.

- *Beachte:* $\boxed{\hat{\lambda}_{ML} = 0{,}9029}$
- *Interpretation der Likelihood-Funktion:* $L(\lambda)$ *ist die Dichte für das gemeinsame Auftreten der Beobachtungen* $x_1 = 0{,}95$, $x_2 = 1{,}81$, $x_3 = 1$ *und* $x_4 = 0{,}67$ *unter der Annahme, dass eine Exponentialverteilung mit Parameter* λ *vorliegt.*
- *Ein hoher Dichtewert* $f(x)$ *an der Stelle* x *impliziert eine hohe Auftretenswahrscheinlichkeit in einem kleinen Intervall um* x.

Beispiel 2.3.5. *Maximum-Likelihood-Schätzung: Normalverteilung*[*]

- *Seien* $X_1, \dots, X_n$ *unabhängige Wiederholungen einer Normalverteilung* (μ,σ^2).
- *Zu schätzen sind* $\theta = (\mu,\sigma^2)$.
- *Likelihood-Funktion:* $L(\mu,\sigma) = \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_1-\mu)^2}{2\sigma^2}}}_{f(x_1|\mu,\sigma^2)} \cdot \ldots \cdot \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_n-\mu)^2}{2\sigma^2}}}_{f(x_n|\mu,\sigma^2)}$.
- *Log-Likelihood-Funktion:*

$$\ln L(\mu,\sigma) = \sum_{i=1}^{n} \left[\ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(x_i-\mu)^2}{2\sigma^2} \right] = -\frac{n}{2}\ln(2\pi) - n\ln\sigma - \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2}.$$

- *Partielles Ableiten und Nullsetzen ergibt:*

$$\frac{\partial \ln L(\mu,\sigma^2)}{\partial \mu} = \sum_{i=1}^{n} \frac{x_i-\mu}{\sigma^2} = 0$$

$$\frac{\partial \ln L(\mu,\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^4} = 0$$

- *Aus der ersten Gleichung ergibt sich* $\sum_{i=1}^{n} x_i - n\hat{\mu} = 0$ *und damit* $\hat{\mu} = \overline{x}$.
- *Aus der zweiten Gleichung ergibt sich* $\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2$, *also die mittlere quadratische Abweichung.*
- *Die ML-Schätzstatistiken der Normalverteilung sind also* $\overline{X}$ *und* $\tilde{S}^2$.