2.7 Regressionsanalyse

- **Lineares Regressionsmodell** aus der **deskriptiven Statistik**:
- Für zwei metrische Merkmale, Y und X, postuliert das **lineare Regressionsmodell** folgenden Zusammenhang:

$$Y = \alpha + \beta X.$$

- Gegeben n Beobachtungen (y_i, x_i), $i = 1, \dots, n$, (zu den Merkmalen Y und X) wird folgendes Gleichungssystem aufgestellt:

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

  wobei $\varepsilon_1, \dots, \varepsilon_n$ **Fehlerterme** sind, die so gewählt werden, dass Gleichheit gilt.
- Die Koeffizienten α und β werden mit der Methode der kleinsten Quadrate bestimmt:

$$\sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - (\alpha + \beta x_i))^2 \quad \to \quad \text{Minimum.}$$

- Im folgenden erweitern wir diesen Ansatz, indem der Fehler ε als Zufallsvariable mit bestimmten Eigenschaften angenommen wird.

2.7.1 Lineare Einfachregression

- In der linearen empirischen Beziehung

$$\boxed{y_i = \alpha + \beta x_i + \varepsilon_i,} \quad i = 1, \dots, n,$$

  seien die Fehlerterme ε_i
  - unbeobachtbare, unabhängige Realisierungen einer Zufallsvariablen,
  - identisch verteilt mit $\mathbb{E}(\varepsilon_i) = 0$ und $\mathrm{Var}(\varepsilon_i) = \sigma^2$. ← immer unbekannt! ($\varepsilon_i$ sind unbeobachtbar)
- Die Werte x_i, $i = 1, \dots, n$, können
  - deterministisch sein (z.B. Dosis eines Medikaments bei einem Versuch),
  - Realisierungen von Zufallsvariablen X_i sein (**stochastischer Regressor**).
- Im Fall eines stochastischen Regressors gelten die Annahmen über ε_i dann nur bedingt, also $\mathbb{E}(\varepsilon_i | X_i = x_i) = 0$, etc.
- Im folgenden nehmen wir der Einfachheit halber an, der Regressor sei deterministisch.

direkte Konsequenz
- KI für σ unbekannt
- t-Test

Werte / unabhängige Var
erklärende Var
Regressor

Standardmodell der linearen Einfachregression

Es gilt:

ZV ZV

Abhängige Var / erklärte Var

$$Y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Dabei sind:

- $Y_1, \dots, Y_n$: beobachtbare metrische Zufallsvariable;
- $x_1, \dots, x_n$: gegebene deterministische Werte;
- $\varepsilon_1, \dots, \varepsilon_n$: unbeobachtbare ZV'en, die unabhängig und identisch verteilt sind mit $\mathbb{E}(\varepsilon_i) = 0$, $\mathrm{Var}(\varepsilon_i) = \sigma^2$.

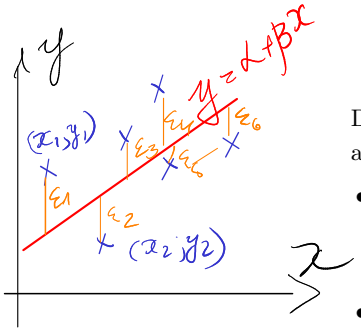

Die Regressionskoeffizienten α,β und die Varianz σ^2 sind unbekannte Parameter, die aus den Daten (y_i,x_i), $i = 1, \dots, n$ zu schätzen sind.

- Es gilt:

$$\mathbb{E}(Y_i) = \mathbb{E}(\alpha + \beta x_i + \varepsilon_i) = \alpha + \beta x_i + \underbrace{\mathbb{E}(\varepsilon_i)}_{=0} = \alpha + \beta \cdot x_i$$

$$\mathrm{Var}(Y_i) = \mathrm{Var}(\alpha + \beta x_i + \varepsilon) = \underbrace{\mathrm{Var}(\alpha + \beta \cdot x_i)}_{=0} + \underbrace{\mathrm{Var}(\varepsilon)}_{\sigma^2} = \sigma^2$$

- Die Verteilungen der Y_i sind, bis auf die Verschiebung der Erwartungswerte, gleich:

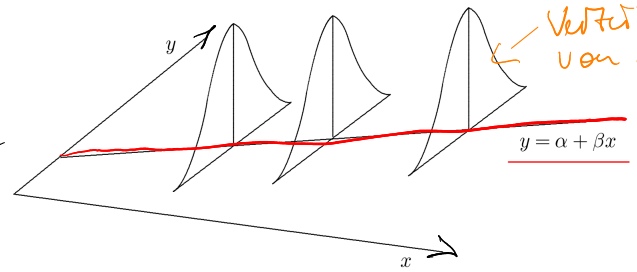

Verteilung von den Fehlertermen

Quelle: Fahrmeir et al.

- Die Eigenschaft gleicher Varianz σ^2 der Fehlerterme heißt **Homoskedastizität**.
- Aussagen zu Verteilungen von Schätzern und Testatistiken, auch für kleine n, erhält man durch folgende – stärkere – Annahme.

Normalverteilungsannahme

Es sei

$$\varepsilon_i \sim \mathrm{N}(0,\sigma^2), \quad i = 1, \dots, n,$$

bzw.

$$Y_i \sim \mathrm{N}(\alpha + \beta x_i, \sigma^2), \quad i = 1, \dots, n.$$

Schätzen, Testen und Prognose

- Im folgenden befassen wir uns mit folgenden Aspekten des linearen Regressionsmodells:
  - Punkt- und Intervallschätzung der unbekannten Parameter α, β, σ^2
  - Testen von Hypothesen über die Regressionskoeffizienten α, β
  - Prognose der Zielvariablen Y für neuen Wert x

2.7.2 Schätzen im linearen Regressionsmodell

Kleinste-Quadrate-Schätzer

- **Kleinste-Quadrate-Methode**: Bestimme $\hat{\alpha}$ und $\hat{\beta}$, so dass

$$\sum_{i=1}^{n} \overbrace{(Y_i - \alpha - \beta x_i)^2}^{\varepsilon_i^2} \quad \to \quad \min_{\alpha,\beta}$$

- Minimieren ergibt:

Schätzung

$$\boxed{\hat{\beta} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(Y_i - \overline{Y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \hat{\rho}_{XY}\frac{\hat{\sigma}_Y}{\hat{\sigma}_X},}$$

$$\boxed{\hat{\alpha} = \overline{Y} - \hat{\beta}\overline{x},}$$

$$\boxed{\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\hat{\varepsilon}_i^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{\alpha} - \hat{\beta}x_i)^2,}$$

mit **Residuen** $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$ und **gefitteten Werten** $\hat{Y}_i = \hat{\alpha} + \hat{\beta}x_i$, $i = 1, \dots, n$.

- Man beachte, dass $\hat{\alpha}$, $\hat{\beta}$ und $\hat{\sigma}^2$ von den Zufallsvariablen $Y_1, \dots, Y_n$ abhängen, und es sich um Schätzfunktionen handelt.

- Diese sind erwartungstreu:

$$\mathbb{E}(\hat{\alpha}) = \alpha, \quad \mathbb{E}(\hat{\beta}) = \beta, \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2,$$

- Es gilt:

$$\mathrm{Var}(\hat{\alpha}) = \sigma_{\hat{\alpha}}^2 = \sigma^2 \frac{\sum x_i^2}{n\left(\sum x_i^2 - n\overline{x}^2\right)}$$

$$\mathrm{Var}(\hat{\beta}) = \sigma_{\hat{\beta}}^2 = \frac{\sigma^2}{\sum x_i^2 - n\overline{x}^2}$$

Werden von Software (Gretl) ausgegeben

- Unter der Normalverteilungsannahme gilt:

$$\varepsilon_i \sim \mathsf{N}(0,\sigma^2), \quad Y_i \sim \mathsf{N}(\alpha + \beta_i, \sigma^2), \quad \hat{\alpha} \sim \mathsf{N}(\alpha, \sigma_{\hat{\alpha}}^2), \quad \hat{\beta} \sim \mathsf{N}(\beta, \sigma_{\hat{\beta}}^2).$$

Verteilung der standardisierten Schätzfunktionen

Unter der Normalverteilungsannahme gilt:

Weil wir hier zwei Parameter schätzen

Standardisierte Schätzer

$$\boxed{\frac{\hat{\alpha} - \alpha}{\hat{\sigma}_{\hat{\alpha}}} \sim t(n-2),} \quad \boxed{\frac{\hat{\beta} - \beta}{\hat{\sigma}_{\hat{\beta}}} \sim t(n-2).}$$

Konfidenzintervalle für α und β

Standardabw. von den Koeffizienten

$$\boxed{\hat{\alpha} \pm \hat{\sigma}_{\hat{\alpha}}\, t_{1-\alpha/2}(n-2), \quad \hat{\beta} \pm \hat{\sigma}_{\hat{\beta}}\, t_{1-\alpha/2}(n-2).}$$

Für $n > 30$ können die t-Quantile durch $\mathsf{N}(0,1)$-Quantile ersetzt werden.

- Falls die Normalverteilungsannahme nicht erfüllt ist, so gilt sie asymptotisch, also gelten obige Ergebnisse approximativ für genügend großes n.

Info um die Konfidenzintervalle zu erstellen

Werte der Koeffizienten

Standardabw. für die Koeffizienten

- `gretl` Output:

realisierte Teststatistik

$\hat{\alpha}$
$\hat{\beta}$

```
gretl: Modell 2
Datei  Bearbeiten  Tests  Speichern  Graphen  Analyse  LaTeX

Modell 2: KQ, benutze die Beobachtungen 1-67
Abhängige Variable: tMWRenditen

                 Koeffizient   Std.-fehler   t-Quotient   p-Wert
  ---------------------------------------------------------------
  const          -0,00233527   0,000853383    -2,736     0,0080    ***
  DAXRenditen     1,12248      0,0933891      12,02      3,59e-18  ***

Mittel d. abh. Var.     -0,000501   Stdabw. d. abh. Var.     0,012244
Summe d. quad. Res.      0,003070   Stdfehler d. Regress.    0,006873
R-Quadrat                0,689686   Korrigiertes R-Quadrat   0,684912
F(1, 65)                 144,4654   P-Wert(F)                3,59e-18
Log-Likelihood           239,6197   Akaike-Kriterium        -475,2394
Schwarz-Kriterium       -470,8300   Hannan-Quinn-Kriterium  -473,4946
rho                      0,040822   Durbin-Watson-Stat       1,912029
```

Wieviel Varianz in Y haben wir durch die Regression erklärt

2.7.3 Testen im linearen Regressionsmodell

- Von besonderer Bedeutung ist das Hypothesenpaar

$$\boxed{H_0 : \beta = 0, \quad H_1 : \beta \neq 0.}$$

- Dabei bedeutet $H_0 : \beta = 0$, dass tatsächlich $Y_i = \alpha + \varepsilon_i$, $i = 1, \dots, n$, gilt, und somit X keinen Erklärungswert für Y besitzt.
- Der ***t*-Test** im Ein-Stichproben-Fall kann zum Testen von Hypothesen bzgl. α und α_0, bzw. β und β_0 eingesetzt werden.
- Die Teststatistiken lauten:

$$\boxed{T_{\alpha_0} = \frac{\hat{\alpha} - \alpha_0}{\hat{\sigma}_{\hat{\alpha}}}, \quad T_{\beta_0} = \frac{\hat{\beta} - \beta_0}{\hat{\sigma}_{\hat{\beta}}}.} \sim t(n-2)$$

- Der ~~***F*-Test**~~ ~~ist ein weiterer Test zur Prüfung von~~ $\cancel{H_0 : \beta = 0}$.
- **Statistische Programmpakete** liefern typischerweise die ***T*-Werte** und ***p*-Werte** zu den Hypothesen $H_0 : \alpha = \alpha_0$ bzw. $H_0 : \beta = \beta_0$ mit $\alpha_0 = 0$ und $\beta_0 = 0$.
- Daraus lässt sich erkennen, ob das Einbeziehen von α, bzw. β in der Regressionsgleichung sinnvoll ist.

2.7.4 Prognose im linearen Regressionsmodell

- Punktschätzer zu einem neuen Wert x_0 ist

neuer Wert für x

Prognose für y

$$\hat{Y}_0 = \hat{\alpha} + \hat{\beta} x_0.$$

- Über die Varianzeigenschaften von $\hat{\alpha}$ und $\hat{\beta}$ lässt sich ein Konfidenzintervall für Y_0 bestimmen.

Bestimmtheitsmaß R^2

- Das **Bestimmtheitsmaß** R^2 gibt den relativen Anteil der Varianz der Stichprobe $(y_1, \dots, y_n)$, der durch die Regressionsgerade erklärt wird.

wie verlässlich ist unsere Prognose / wie gut ist unser Modell

- Im Fall der linearen Regression ist es definiert als

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{\alpha} + \hat{\beta} x_i - Y_i)^2}{\sum_{i=1}^n (Y_i - \overline{Y})^2}.$$

- Man kann zeigen, dass

$$R^2 = \frac{\hat{\beta}^2 \hat{\sigma}_x^2}{\hat{\sigma}_y^2} = \frac{\hat{\rho}_{xy}^2 \, \hat{\sigma}_y^2}{\hat{\sigma}_y^2} = \hat{\rho}_{xy}^2.$$

- Es ist stets $0 \leq R^2 \leq 1$, wobei
  - $R^2 = 0$ den unkorrelierten Fall, und
  - $R^2 = 1$ den Fall eines perfekten linearen Zusammenhangs

  zwischen den Merkmalen X und Y widerspiegelt.

.csv - Datei herunterladen
Dann in gretl:
Daten → öffne Daten...

2.7.6 Regressionsanalyse mit `gretl`

- Die Daten des folgenden Beispiels sind hier verfügbar:

  https://moodle.hwr-berlin.de/mod/resource/view.php?id=1096223

- Wir schätzen ein lineares Modell für BMW Aktienrenditen (Y) und DAX Indexrenditen (X).

- Es liegen die Schlusskurse vom `2018-06-21:2019-06-19 (T = 250)`

  Stichprobenumfang

- Führe aus: `Modell` → `Kleinste Quadrate (OLS)`

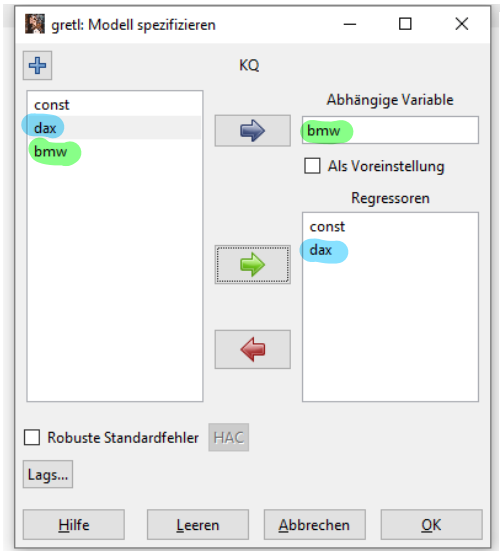

- Output:

gretl: Modell 1

Datei Bearbeiten Tests Speichern Graphen Analyse LaTeX

```
Modell 1: KQ, benutze die Beobachtungen 2018-06-21:2019-06-19 (T = 250)
Abhängige Variable: bmw

             Koeffizient    Std.-fehler    t-Quotient     p-Wert
  ---------------------------------------------------------------
  const      -0,000880327   0,000633091    -1,391         0,1656
  dax         1,03248       0,0662234      15,59          1,16e-038 ***

Mittel abhängige Var.   -0,000961   Stdabw. abhängige Var.   0,014057
Summe quad. Residuen     0,024848   Stdfehler Regression     0,010010
R-Quadrat                0,494983   Korrigiertes R-Quadrat   0,492947
F(1, 248)                243,0728   P-Wert(F)                1,16e-38
Log-Likelihood           797,3192   Akaike-Kriterium        -1590,638
Schwarz-Kriterium       -1583,595   Hannan-Quinn-Kriterium  -1587,804
rho                      0,099665   Durbin-Watson-Stat       1,788493
```