Wie kann man die vielfältigen Daten durch einige wenige Kennzahlen zusammenfassen?

1.4 Kennzahlen bei einem Merkmal

Einstiegsbeispiel: Typischer Kunde

- Wie sieht unser typischer Kunde aus?
- Alter, Geschlecht, Beruf, Einkommen, Erfahrung,...

Lageparameter	• empirischer Erwartungswert (arithmetisches Mittel) • Zentralwert/Median • gestutztes Mittel • geometrisches Mittel • Modalwert
Quantile	• p-Quantil • empirischer Median
Streuungsparameter	• empirische Varianz und mittlere quadratische Abweichung • empirische Standardabweichung • Variationsbreite • Variationskoeffizient
Case Study	• Typischer Kunde + Empirische Quantile und Value at Risk

- **Lageparameter** kennzeichnen den zentralen Wert (die mittlere Lage) der Beobachtungsreihe
- **Quantile** geben Informationen, wie die Daten über die Spannbreite der Beobachtungen verteilt sind.

- **Streuungsparameter** kennzeichnen die Variabilität (die Streuung) der Beobachtungsreihe

- **Induktion**: Schluss von einer empirischen Kennzahl auf die entsprechende Kennzahl der Verteilung (→ Teil 3: Induktive Statistik)

Datenvorgabe

- Empirische Daten können wie folgt gegeben sein:
  - **Stichprobe**: $x_1, x_2, \ldots, x_n$ ← Messwerte
  - **geordnete Stichprobe**: $x_{[1]} \leq x_{[2]} \leq \cdots \leq x_{[n]}$ ← aufsteigend sortierte Werte
  - **diskrete Häufigkeitsverteilung**:

Ausprägungen	a_1	a_2	$\cdots$	a_J
Häufigkeiten	h_1	h_2	$\cdots$	h_J

  - **kontinuierliche Häufigkeitsverteilung**:

Klassen	K_1	K_2	$\cdots$	K_J
Klassenmitten	a_1	a_2	$\cdots$	a_J
Häufigkeiten	h_1	h_2	$\cdots$	h_J

- Mit Ausnahme des empirischen Erwartungswertes (als wichtigster Lageparameter) und der empirischen Varianz (als wichtigster Streuungsparameter) werden im Folgenden die Kennzahlen nur für die Datenvorgaben **Stichprobe** bzw. **geordnete Stichprobe** definiert.

1.5 Lagemaße

1.5.1 Empirischer Erwartungswert / Mittelwert

Der **empirische Erwartungswert** (auch: **Mittelwert**, **arithmetisches Mittel** oder **Stichprobenmittel**) einer Stichprobe $x_1, x_2, \dots, x_n$ wird wie folgt berechnet:

Wenn eine Stichprobe als Darstellung vorliegt

$$\boxed{\overline{x} = \hat{\mu}_X = \frac{1}{n}(x_1 + \cdots + x_n) = \frac{1}{n}\sum_{i=1}^{n} x_i.}$$

Sind Häufigkeiten gegeben, so berechnet sich der empirische Erwartungswert wie folgt:

Wenn Häufigkeiten gegeben

$$\boxed{\hat{\mu}_X = a_1 h_1 + \cdots + a_J h_J = \sum_{j=1}^{J} a_j h_j = \frac{1}{n}\sum_{j=1}^{J} a_j H_j.}$$

relative Häufigkeit — Ausprägung — Summe — absolute Häufigkeiten

Bsp: Stichprobe $n=8$

1; 2; 1; 3; 4; 2; 2; 3

$\overline{x} = \frac{1}{8}(1+2+1+3+4+2+2+3) = 2{,}25$

Bsp: Häufigkeiten:

a_j	1	2	3	4
H_j	2	3	2	1

$\overline{x} = \frac{1}{8}\cdot(1\cdot 2 + 2\cdot 3 + 3\cdot 2 + 4\cdot 1) = \underline{2{,}25}$

1.5.2 Median, α-gestutztes Mittel

Gute Kennzahlen bei Ausreißern — "robust."

Es sei $x_{[1]} \le x_{[2]} \le \cdots \le x_{[n]}$ eine **geordnete** Stichprobe. Der Median ist definiert durch

"Ordnungsindex"

$$x_{\text{med}} = \begin{cases} x_{[\frac{n+1}{2}]}, & \text{falls } n \text{ ungerade,} \\ \frac{1}{2}\left(x_{[\frac{n}{2}]} + x_{[\frac{n}{2}+1]}\right), & \text{falls } n \text{ grade.} \end{cases}$$

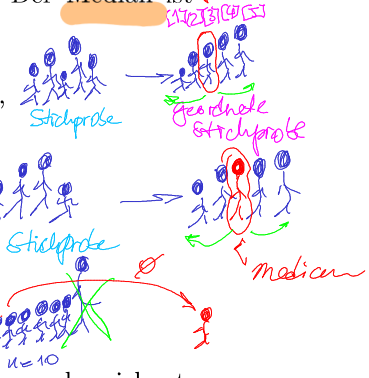

Das **α-gestutztes Mittel** ist definiert durch

"Anteil zum Abschneiden"

$$\boxed{\overline{x}_\alpha = \frac{1}{n-2k}\left(x_{[k+1]} + \cdots + x_{[n-k]}\right),}$$

mit $0 < \alpha < 0{,}5$, wobei $k = \text{int}(\alpha n)$ den ganzzahligen Anteil von αn bezeichnet.

ganzer Teil

geordnete Stichprobe

x_i	1	1	2	2	2	3	3	4
$[i]$	1	2	3	4	5	6	7	8

$x_{med} = \frac{1}{2}(x_{[4]} + x_{[5]}) = \frac{1}{2}(2+2) = \underline{2}$.

$\alpha = 0{,}2$; $k = \text{int}(0{,}2\cdot 8) = \text{int}(1{,}6) = 1$

$\overline{x}_{0,2} = \frac{1}{6}(1+2+2+2+3+3) = \underline{2{,}1667}$

- Diese Maße sind robust gegenüber extremen Werten von Datenpunkten, sogenannten **Ausreißern**.
- Für den Median sind mindestens 50% der Daten $\left\{\begin{matrix}\textbf{kleiner als}\\ \textbf{größer als}\end{matrix}\right\}$ x_{med}.
- Das α-gestutzte Mittel eliminiert die extremsten Beobachtungen. Dies ist nützlich, wenn die Daten (unrealistische) Ausreißer aufweisen.

Beispiel 1.5.1. *Jahresrenditen*

- *Stichprobe: Jahresrenditen einer Aktie A (in %):* $n=6$ Stichprobe

2,2	9,8	– 3,2	– 1,3	4,5	1,8

Die mittlere Rendite

- *Berechnen Sie*
  - *den empirischen Erwartungswert* $\bar{x}$, $\bar{x} = \frac{1}{6}(2{,}2+9{,}8-3{,}2-1{,}3+4{,}5+1{,}8) = \underline{2{,}3}$
  - *den Median* x_{med}, $x_{med} =$
  - *das* α*-gestutzte Mittel für* $\alpha = 0{,}2$.

Median: geordnete Stichprobe:

$x_{[i]}$	$\cancel{-3{,}2}$	$-1{,}3$	$1{,}8$	$2{,}2$	$4{,}5$	$\cancel{9{,}8}$
$[i]$	1	2	3	4	5	6

da $n=6$ gerade: $x_{med} = \frac{1}{2}\left(x_{[\frac{6}{2}]} + x_{[\frac{6}{2}+1]}\right) =$

$= \frac{1}{2}\left(x_{[3]} + x_{[4]}\right) =$

$= \frac{1}{2}(1{,}8+2{,}2) = \underline{2}$

das α-gestutzte Mittel für $\alpha = 0{,}2$:

$k = \text{int}(0{,}2 \cdot 6) = \text{int}(1{,}2) = 1$

$\bar{x}_{0,2} = \frac{1}{4}(-1{,}3+1{,}8+2{,}2+4{,}5) = \underline{1{,}8}$.

$4 = 6-2$

1.5.3 Geometrisches Mittel

- $p_0, p_1, \dots, p_n$ ist eine Zeitreihe von Größen oder Preisen.
- Definiere die **Zuwachsfaktoren** $q_i = \dfrac{p_i}{p_{i-1}}$, $i = 1, \dots, n$.
- Das geometrische Mittel ist das geeignete Maß für das durchschnittliche Wachstum über mehrere Zeitperioden.

Es sei $x_0, x_1, \dots, x_n$ eine Stichprobe von positiven Zahlen (Zuwachsfaktoren). Das **geometrische Mittel** ist definiert als

$$\boxed{x_{\text{geom}} = (x_1 \cdot x_2 \cdot \ldots \cdot x_n)^{1/n}}. \quad = \sqrt[n]{x_1 \cdot x_2 \cdot \ldots \cdot x_n}$$

- Die folgende Gleichung zeigt, dass das geometrische Mittel tatsächlich ein Durchschnitt ist:

$$p_n = p_{n-1} \cdot q_n = p_{n-2} \cdot q_{n-1} \cdot q_n = p_0 \cdot q_1 \cdot \ldots \cdot q_n = p_0 \cdot q_{\text{geom}}^n.$$

Beispiel 1.5.2. *Handelsbuch*

- *Gegeben: Folge* p_0, p_1, p_2, p_3 *der Wertentwicklung eines Handelsbuchs (in Geldeinheiten, GE)*
- *Bestimme Zuwachsfaktoren* q_1, q_2, q_3

Monat	i	p_i	q_i	
Dezember	0	782	–	
Januar	1	854	1,0921	$= \frac{854}{782}$
Februar	2	1042	1,2201	$= \frac{1042}{854}$
März	3	731	0,7015	$= \frac{731}{1042}$

- *Geometrisches Mittel:* $q_{geom} = (q_1 q_2 q_3)^{1/3} = 0{,}9778 < 1$
- *Arithmetisches Mittel:* $\overline{q} = \frac{1}{3}(1{,}0921 + 1{,}2201 + 0{,}7015) = 1{,}0046 > 1$
- *Bemerkungen:*
  - *Das geometrische Mittel beschreibt den Kursrückgang von Dezember bis März.*
  - *Nur das geometrische Mittel hat eine sinnvolle Interpretation als durchschnittlicher Zuwachs.*
  - *Zuwachsfaktoren können durch* **Zuwachsraten** *(d. h.* **Renditen***) ersetzt werden via* $q_i = (1 + r_i)$.

1.5.4 Modalwert

Es sei $x_1, x_2, \dots, x_n$ eine Stichprobe eines Merkmals X mit **beliebiger Skala** und mit möglichen Ausprägungen $a_1, \dots, a_J \in A_X$.

Der **Modalwert** ist definiert als die am häufigsten beobachtete Ausprägung:

$$\boxed{x_{\text{mod}} = a_j} \quad \text{mit } H(a_j) = \max(H(a_1), \dots, H(a_J)).$$

- Der Modalwert ist das einzige sinnvolle Lagemaß für Merkmale auf einer nominalen Skala.

Beispiel 1.5.3. *Kreditausfälle, siehe 1.2.1,Seite 12*

$$x_{\text{mod}} = a_2 = \textit{Probleme bei der Haushaltsführung}$$

ist die häufigste Ursache von Kreditausfällen laut der Datenlage.

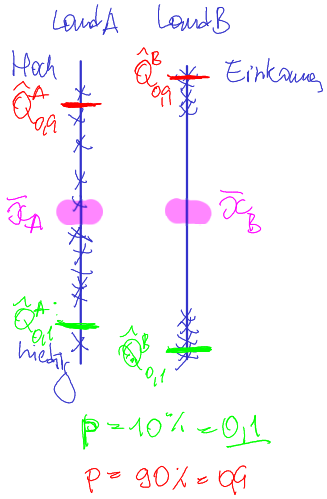

1.6 Quantile und Boxplots

- Eine angemessene, aggregierte Beschreibung einer Datenmenge erfordert zusätzlich Informationen über die Streuung der Daten.
- So kann bspw. trotz gleicher Mittelwerte und/oder Mediane für das Einkommen in zwei Ländern eine große Lücke zwischen armen und reichen Personen bestehen.
- Quantile als ein statistisches Maß und Boxplots als graphisches Werkzeug sind nützlich zum Vergleich von Verteilungen.

1.6.1 Quantile

Es sei p mit $0 < p < 1$ gegeben. Jede Zahl $\hat{Q}_p$ mit der Eigenschaft, dass

- mindestens ein Anteil p der Daten kleiner oder gleich $\hat{Q}_p$ ist, ~~vspace 0.2cm~~
- mindestens ein Anteil $1-p$ der Daten größer oder gleich $\hat{Q}_p$ ist, ~~vspace 0.2cm~~

heißt **p-Quantil**.

Sei $x_{[1]} \leq x_{[2]} \leq \dots \leq x_{[n]}$ eine geordnete Stichprobe eines ordinal oder metrisch skalierten Merkmals X. Das **p-Quantil** $\hat{Q}_p$ erfüllt

$$\hat{Q}_p = \begin{cases} x_{[\text{int}(np)+1]}, & \text{falls } np \text{ keine ganze Zahl ist,} \\ \frac{1}{2}\left(x_{[np]} + x_{[np+1]}\right), & \text{falls } np \text{ eine ganze Zahl ist,} \end{cases}$$

wobei $\text{int}(np)$ den ganzzahligen Anteil von np bezeichnet.

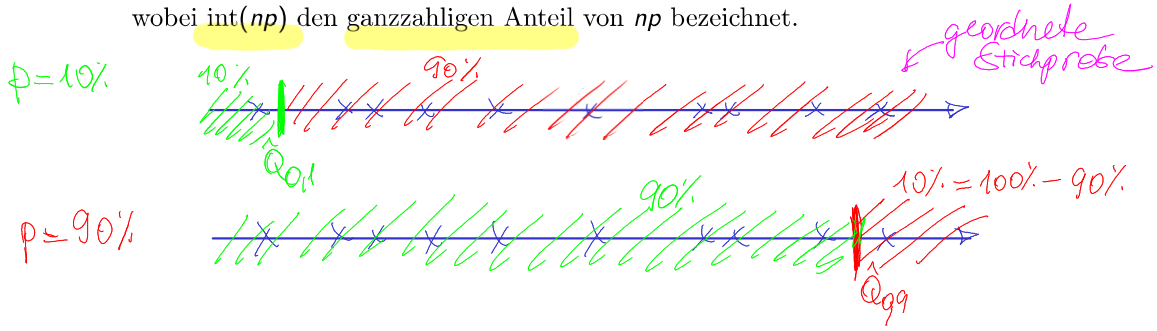

1.6.2 Spezielle Quantile und Quartilsabstand

- $p = 0{,}5$: Der empirische **Median** x_{med} ist das 0,5-Quantil.
- $p = 0{,}25$: **Unteres Quartil**
- $p = 0{,}75$: **Oberes Quartil**
- $p = k/100$: ***k*-tes Percentil** ($k = 1, \dots, 99$)

Der Abstand $\hat{q} = \hat{Q}_{0{,}75} - \hat{Q}_{0{,}25}$ ist der **Quartilsabstand** (**interquartile range (IQR)**).

Beispiel 1.6.1. *Quantile*

$$\hat{Q}_p = \begin{cases} x_{[\text{int}(np)+1]}, & \text{falls } np \text{ keine ganze Zahl ist,} \\ \frac{1}{2}\left(x_{[np]} + x_{[np+1]}\right), & \text{falls } np \text{ eine ganze Zahl ist,} \end{cases}.$$

- *Daten:* $n = 12$ geordnete Stichprobe

$[i]$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{[i]}$	-1,1	-0,5	-0,1	0,2	0,2	0,7	0,8	0,9	1,0	1,3	1,4	5,8

- *Berechnen Sie:*
  - *die Quantile:*

$np = 0{,}05 \cdot 12 = 0{,}6$

$\hat{Q}_{0{,}05} = x_{[\text{int}(0{,}6)+1]} = x_{[0+1]} = x_{[1]} = -1{,}1$

$np = 0{,}15 \cdot 12 = 1{,}8$

$\hat{Q}_{0{,}15} = x_{[\text{int}(1{,}8)+1]} = x_{[1+1]} = x_{[2]} = -0{,}5$

$0{,}25 \cdot 12 = 3$

$\hat{Q}_{0{,}25} = \frac{1}{2}(x_{[3]} + x_{[4]}) = \frac{1}{2}(-0{,}1 + 0{,}2) = \underline{0{,}05}$

$0{,}75 \cdot 12 = 9$

$\hat{Q}_{0{,}75} = \frac{1}{2}(x_{[9]} + x_{[10]}) = \frac{1}{2}(1{,}0 + 1{,}3) = \underline{1{,}15}$

  - *den Quartilsabstand*

$$\hat{q} = \hat{Q}_{0{,}75} - \hat{Q}_{0{,}25} = 1{,}15 - 0{,}05 = \underline{\underline{1{,}1}}$$

- Median: $x_{med} = \frac{1}{2}(x_{[6]} + x_{[7]}) = \frac{1}{2}(0{,}7 + 0{,}8) = 0{,}75$

Der zentrale Schwankungsbereich der Renditenverteilung

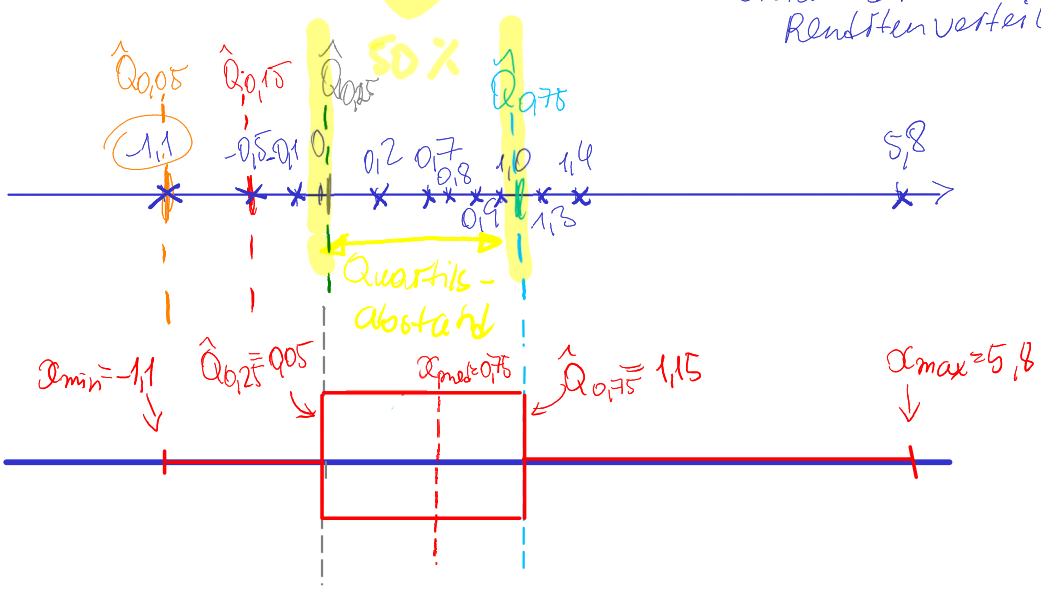

1.6.3 Boxplot

- Eine einfache, jedoch aussagekräftige graphische Darstellung der Verteilung eines Merkmals ist der **Boxplot**, auch genannt **Box-Whisker-Plot**.

Ein **Boxplot** ist eine graphische Darstellung mit den folgenden Komponenten:

- Eine Box mit dem unteren Ende der Box bei $\hat{Q}_{0,25}$ und dem oberen Ende bei $\hat{Q}_{0,75}$.
- Der Median ist markiert als ein Punkt oder eine Linie.
- Zwei Linien (die Whiskers (Antennen)) sind zwischen $\hat{Q}_{0,25}$ und x_{min} bzw. $\hat{Q}_{0,75}$ und x_{max} eingezeichnet. Verschiedene Definitionen der Länge sind praxisüblich.

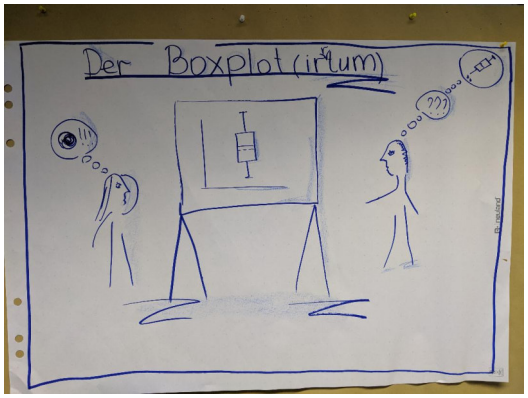

Beispiel 1.6.2. *Renditen von Aktienindizes*

- *Boxplots erzeugt für tägliche Renditen der Indizes DAX, S&P 500, Dow Jones Industrial Average und FTSE 100 vom 1. Oktober 2015 bis 1. Oktober 2016. (Datenquelle: Wolfram):*

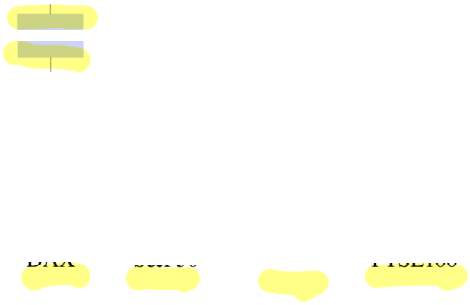

1.7 Streuungsmaße

1.7.1 Empirische Varianz, empirische Standardabweichung

Die **empirische Varianz** einer Stichprobe $x_1, \dots, x_n$ ist gegeben durch

$$\boxed{\hat{\sigma}_X^2 = \frac{1}{n-1}\left[(x_1-\bar{x})^2 + \cdots + (x_n-\bar{x})^2\right] = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2.}$$

Stichprobe

Achtung! Teile durch n-1. Intuition: habe eine Beobachtung "verbraucht" um $\bar{x}$ auszurechnen

Sind Häufigkeiten gegeben, so kann die empirische Varianz wie folgt berechnet werden:

$$\boxed{\hat{\sigma}_X^2 = \frac{n}{n-1}\left[(a_1-\bar{x})^2 h_1 + \cdots + (a_n-\bar{x})^2 h_n\right] = \frac{n}{n-1}\sum_{j=1}^{J}(a_j-\bar{x})^2 h_j.}$$

Häufigkeiten

Die **empirische Standardabweichung** ist die Wurzel der empirischen Varianz:

usigma" $\boxed{\hat{\sigma}_X = \sqrt{\hat{\sigma}_X^2}.}$ σ – σ – σ – sigma

- Die Varianz beschreibt die quadratische *Abweichung* vom Mittelwert.
- Durch Quadrieren werden kleine Abweichungen negiert, während große Abweichungen verstärkt werden.
- $\hat{\sigma}_X$ und X haben dieselbe Einheit.
- Die folgenden Formeln sind nützlich für Berechnungen.

Alternative Varianzformeln

$$\boxed{\hat{\sigma}_X^2 = \frac{1}{n-1}\sum_{i=1}^{n} x_i^2 - \frac{n}{n-1}\bar{x}^2}$$

Stichprobe

$$\boxed{\hat{\sigma}_X^2 = \frac{n}{n-1}\sum_{j=1}^{J} a_j^2 h_j - \frac{n}{n-1}\bar{x}^2}$$

Häufigkeiten

Beispiel 1.7.1. *Empirische Varianz und Standardabweichung*

- *Stichprobe: Jahresrenditen einer Aktie A (in %):* $n=6$ $\bar{x} = 2{,}3$

2,2	9,8	– 3,2	– 1,3	4,5	1,8

← Stichprobe

- *Berechnen Sie die empir. Varianz $\hat{\sigma}_X^2$, die empir. Standardabweichung $\hat{\sigma}_X$.*

$$\hat{\sigma}_X^2 = \frac{1}{6-1}\cdot\underbrace{\left(2{,}2^2+9{,}8^2+(-3{,}2)^2+(-1{,}3)^2+4{,}5^2+1{,}8^2\right)}_{} - \frac{6}{6-1}\underbrace{2{,}3^2}_{}$$

$$= \frac{136{,}3}{5} - \frac{31{,}74}{5} = 20{,}912$$

$$\hat{\sigma}_X = \sqrt{20{,}912} = 4{,}573$$

← mittlere Abweichung von $\bar{x}$ (2,3%)

Erwarte: 2,3% ± 4,6% → 6,9%, → −2,3%

1.7.2 Transformationsregel: $\hat{\mu}$ und $\hat{\sigma}^2$ unter linearen Transformationen

Für eine lineare Transformation der Daten $y_i = a + bx_i$, $i = 1, \dots, n$, gilt

$$\overline{y} = a + b\overline{x}, \quad \hat{\sigma}^2_Y = b^2 \hat{\sigma}^2_X \quad \text{und} \quad \hat{\sigma}_Y = |b| \hat{\sigma}_X.$$

- Beweis:*

$$\overline{y} = \frac{1}{n}\sum_{i=1}^{n} y_i = \frac{1}{n}\sum_{i=1}^{n}(a + bx_i) = \frac{1}{n} \cdot n \cdot a + b \cdot \frac{1}{n}\sum_{i=1}^{n} x_i = a + b\overline{x}$$

$$\hat{\sigma}^2_Y = \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \overline{y})^2 = \frac{1}{n-1}\sum_{i=1}^{n}(a + bx_i - a - b\overline{x})^2$$

$$= b^2 \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2 = b^2 \hat{\sigma}^2_x$$

Beispiel 1.7.2. *lineare Transformation: Temperaturskala*

- *Die Temperaturskala kann in die Einheiten Celsius oder Fahrenheit unterteilt sein.*
- *Zur Umrechnung der Temperatur von X in °C nach Y in °F besteht der lineare Zusammenhang*

$$\boxed{Y = \overset{b}{1{,}8}X + \overset{a}{32}} \leftarrow \text{Transformationsformel}$$

- *An einem Ort ergeben die täglichen Temperaturmessungen eines Jahres (jeweils um 12.00 Uhr mittags) die folgenden Kennzahlen aus der Celsiusskala:*

$$\hat{\mu}_C = 13{,}5°\text{C} \qquad \textit{und} \qquad \hat{\sigma}^2_C = 9{,}5(°\text{C})^2.$$

- *Damit lassen sich - ohne Rückgriff auf die zugrunde liegende Stichprobe - die entsprechenden Fahrenheitwerte ermitteln:*

$$\hat{\mu}_F = 1{,}8 \cdot \hat{\mu}_C + 32 = \qquad \textit{und} \qquad \hat{\sigma}^2_F = 1{,}8^2 \cdot \hat{\sigma}^2_C = 1{,}8^2 \cdot 9{,}5 = \underline{30{,}78}\,(°F)^2$$

$$= 1{,}8 \cdot 13{,}5°C + 32 = \underline{56{,}3°F}$$

1.7.3 z-Score, Spannbreite, Variationskoeffizient

- Gegeben: Stichprobe $x_1, \dots x_n$ eines metrisch skalierten Merkmals X

Der **z-Score**

$$z_i = \frac{x_i - \overline{x}}{\hat{\sigma}}, \quad i = 1, \dots, n,$$

messe, wie viele Standardabw. ist x_i von $\bar{x}$ entfernt.

misst die Abweichung einer Beobachtung vom empirischen Erwartungswert in Einheiten der Standardabweichung.

Die **Spannbreite** (*engl.*: Range) ist definiert durch

$$R = \max(x_1, \dots, x_n) - \min(x_1, \dots, x_n) = x_{[n]} - x_{[1]}.$$

Der **Variationskoeffizient** (*engl.* Coefficient of Variation) ist definiert durch

$$\boxed{\mathrm{cv} = \frac{\hat{\sigma}_X}{\overline{x}}.}$$

Standardabweichung relativ zu dem empir. Erwartungswert

Beispiel 1.7.3. *Zwei Aktien*

- *Kursentwicklung der Aktien A (Merkmal X) und B (Merkmal Y):*

	i	1	2	3	4	5
Aktie A	x_i	1750	1770	1740	1740	1760
Aktie B	y_i	124	119	122	125	120

- *Berechnen Sie die folgenden Kennzahlen:*

$\overline{x} =$	$\hat{\sigma}_X^2 =$	$\hat{\sigma}_X =$	$cv_X =$
$\overline{y} =$	$\hat{\sigma}_Y^2 =$	$\hat{\sigma}_Y =$	$cv_Y =$

- *Interpretieren Sie das Ergebnis!*

$$\hat{\sigma}_X^2 = \frac{1}{n-1}\sum_{i=1}^{n} x_i^2 - \frac{n}{n-1}\overline{x}^2$$

- $\bar{x} = \frac{1}{5}(1750 + 1770 + 1740 + 1740 + 1760) = 1752$
- $\bar{y} = \frac{1}{5}(124 + 119 + 122 + 125 + 120) = 122$
- $\hat{\sigma}_x^2 = \frac{1}{5-1}(1750^2 + 1770^2 + 1740^2 + 1740^2 + 1760^2) - \frac{5}{5-1} \cdot 1752^2 = 170$

  $\hat{\sigma}_x = \sqrt{170} = 13{,}0384 \longrightarrow CV_x = \frac{\hat{\sigma}_x}{\bar{x}} = \frac{13{,}0384}{1752} = 0{,}0074$

- $\hat{\sigma}_y^2 = \frac{1}{5-1}(124^2 + 119^2 + 122^2 + 125^2 + 120^2) - \frac{5}{5-1} \cdot 122^2 = 6{,}5$

  $\hat{\sigma}_y = \sqrt{6{,}5} = 2{,}5495 \longrightarrow CV_y = \frac{\hat{\sigma}_y}{\bar{y}} = \frac{2{,}5495}{122} = 0{,}0209$

Aktie A schwankt weniger bezogen auf den mittleren Kurs.