1.11 Regressionsrechnung

Korrelationsrechnung vs. Regressionsrechnung

Bei der Frage nach dem linearen Zusammenhang zweier Merkmale unterscheiden wir die folgenden beiden Aspekte:

- Korrelationsrechnung:
  - Bestimmt die **Stärke** des linearen Zusammenhangs zwischen zwei Merkmalen X und Y
  - kurz: ob ein linearer Zusammenhang besteht, Richtung
- Regressionsrechnung:
  - Bestimmt die **Form** $Y = a + bX$ des linearen Zusammenhangs zwischen X und Y
  - kurz: welcher lineare Zusammenhang besteht

wie berechne ich den Umsatz wenn ich eine Vorhersage für die Temp. habe?

Die Regressionsrechnung kann auf nicht-lineare Zusammenhänge erweitert werden. Die Rolle des Korrelationskoeffizienten übernimmt dann das **Bestimmtheitsmaß**, das angibt, wie viel des zufälligen Auftretens von X und Y der Regressionsansatz $Y = f(X)$ erklärt.

Wir haben einen linearen Zusammenhang zw. dem Umsatz U und der durchschnittlichen Temperatur T empirisch festgestellt.
Können wir den erwarteten Umsatz für ein gegebenes Temperaturniveau nun berechnen?

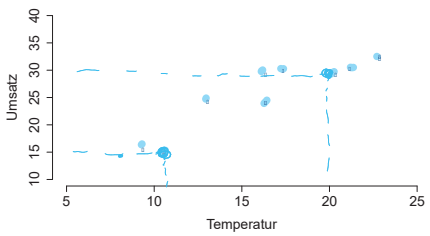

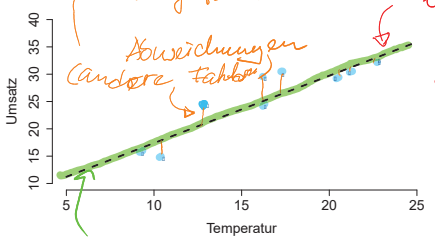

Schulstunde ausgefallen

Abweichungen (andere Faktoren)

kann mir eine Linie hier vorstellen, die die Daten gut approximiert

Brauche eine Formel für diese Linie

1.11.1 Lineare Regression

- Es sei $(x_1, y_1), \dots, (x_n, y_n)$ eine Stichprobe von metrisch skalierten Merkmalen X und Y.

- Wir unterstellen einen linearen funktionalen Zusammenhang zwischen Y und X:

$$\boxed{y = a + bx, \quad a, b \in \mathbb{R},}$$

mit

  - $a + bx$ heißt **Regressionsgerade**;
  - y heißt **Regressand** oder **erklärte Variable**; ← was wir vorhersagen wollen
  - x heißt **Regressor** oder **erklärende Variable**. ← wodurch wir vorhersagen wollen (was wir im Voraus wissen)

- In der Praxis ist der Zusammenhang in der Regel nicht perfekt linear. Daher schreibt man

$$y_1 = a + bx_1 + \varepsilon_1$$

← "Epsilon"

$$\vdots$$

$$y_n = a + bx_n + \varepsilon_n,$$

← Fehlerterme (unbeobachtbare / unvorhersehbare Einflüsse)

wobei $\varepsilon_1, \dots, \varepsilon_n$ die sogenannten **Fehlerterme** oder **Residuen** sind.

Berechnung der Regressionskoeffizienten

- Die Regressionskoeffizienten, der **Interzept** a und die **Steigung** der Regressionsgerade b, sind zu bestimmen.

- Die **Methode der kleinsten Quadrate (MkQ)** bestimmt a und b durch Minimierung der Summe der quadrierten Fehlerterme:

$$\min_{a,b} \sum_{i=1}^{n} \varepsilon_i^2 = \min_{a,b} \sum_{i=1}^{n} (y_i - (a + bx_i))^2.$$

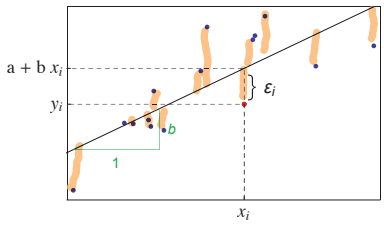

1.11.2 MkQ-Schätzer

Es sei $(x_1,y_1), \dots, (x_n,y_n)$ eine Stichprobe der Merkmale X und Y. Das System der linearen Gleichungen

$$\boxed{y_i = a + bx_i + \varepsilon_i,} \quad i = 1, \dots, n$$

heißt **lineare Regression** mit **Interzept** a, **Steigung** b und **Fehlertermen (Residuen)** $\varepsilon_1, \dots, \varepsilon_n$.

Die **Kleinste-Quadrate-Schätzer** für a und b sind gegeben durch

Aus den Daten geschätzte Koeffizienten $\hat{a}; \hat{b}$

$$\begin{cases} \boxed{\hat{a} = \overline{y} - \hat{b}\overline{x},} \\ \boxed{\hat{b} = \dfrac{\hat{\sigma}_{XY}}{\hat{\sigma}_X^2}} = \hat{\rho}_{XY} \cdot \dfrac{\hat{\sigma}_Y}{\hat{\sigma}_X} = \dfrac{\sum_{i=1}^n x_i y_i - n\overline{x}\overline{y}}{\sum_{i=1}^n x_i^2 - n\overline{x}^2} = \dfrac{\sum_{i=1}^n (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^n (x_i - \overline{x})^2}. \end{cases}$$

Kovarianz

Varianz der erklärenden Variable

1.11.3 Bestimmtheitsmaß R^2

Qualität der Regression →

- Das **Bestimmtheitsmaß** R^2 beschreibt den **Anteil** der Gesamtvarianz der Stichprobe $(y_1, \dots, y_n)$, der durch die Regressionsgerade erklärt wird.

Im Fall der linearen Regression ist das **Bestimmtheitsmaß** R^2 definiert als

$$R^2 = 1 - \frac{\sum_{i=1}^n (a + bx_i - y_i)^2}{\sum_{i=1}^n (y_i - \overline{y})^2}.$$

Hierbei gilt

$$0 \le R^2 \le 1 \quad \text{und} \quad \boxed{R^2 = \hat{\rho}_{XY}^2.}$$

- $R^2 = 0$ entspricht dem Fall der Unkorreliertheit, und ⇒ habe durch die Regression nichts erklärt
- $R^2 = 1$ entspricht dem Fall perfekter linearer Korrelation zwischen den Merkmalen X und Y.

⇒ habe durch die Regression alles erklärt (y ist eine lineare Funktion von x)

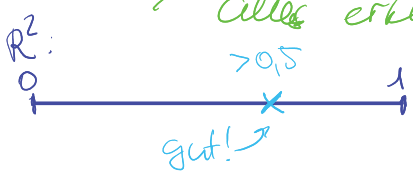

Beispiel 1.11.1. *Kundenaufkommen*

- *Merkmale:*
  - $\boxed{U}$ = *Umsatz pro Kunde* ← erklärte Variable (entspricht Y)
  - $\boxed{T}$ = *durchschnittliche Temperatur* ← erklärende Variable (entspricht X)

  (Daten aus 1.10.1, Seite 53)

- *Bestimme die Regressionsgerade* $\boxed{u = a + bt}$ ← Umsatz als Funktion der Temp.

- *Lösung:*
  - $\bar{u} = 26.115$; $\bar{t} = 17.07$; $\hat{\sigma}_T^2 = 23.73$, $\hat{\sigma}_{UT} = 29.282$, $\rho_{UT} = 0{,}925$
  - $\hat{b} = \frac{\hat{\sigma}_{UT}}{\hat{\sigma}_T^2} = \frac{29{,}282}{23{,}73} = 1{,}23$
  - $\hat{a} = \bar{u} - \hat{b} \cdot \bar{t} = 26{,}115 - 1{,}23 \cdot 17{,}07 = 5{,}12$

$$\boxed{\hat{a} = \bar{y} - \hat{b}\bar{x}, \quad \hat{b} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X^2} =}$$

geschätzte Regressionsgerade

- *Umsatzfunktion:* $\boxed{u = 5{,}12 + 1{,}23 \cdot t,}$ *für* $9 \leq t \leq 25$

- *Bestimmheitsmaß:* $R^2 = \hat{\rho}_{UT}^2 = (0{,}925)^2 = 0{,}856$ ← 85,6 % der Varianz im meinem Umsatz habe ich durch die lineare Regression erklärt.

R^2:

Regressionsgerade:

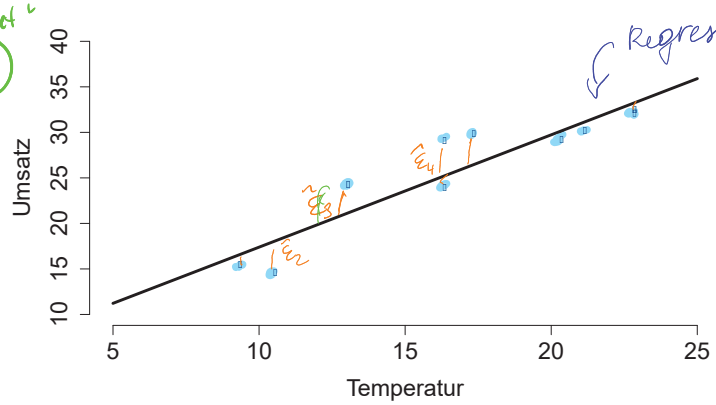

Regressionsgerade: $u = 5{,}12 + 1{,}23 \cdot t$

- Vorhersage:

  $t_0 = 17°C$ (19,05 Vorhersage)

  $u_0 = 5{,}12 + 1{,}23 \cdot 17 = 26{,}03$ ← Umsatzvorhersage

1.11.4 Nicht-lineare Regression

- Wenn der Zusammenhang nicht linear ist, wie etwa $\boxed{v = \alpha \cdot \beta^u}$: $(\ln(\cdot))$
- $\rightarrow$ durch eine geeignete Transformation in einen linearen Zusammenhang überführen, z.B.durch das Logarithmieren: $\underbrace{\ln v}_{y} = \underbrace{\ln \alpha}_{a} + \underbrace{(\ln \beta)}_{b} \cdot \underbrace{u}_{x}$.

$y = a + b \cdot x$

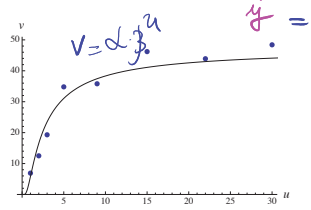

- Setze: $y = \ln v$, $a = \ln \alpha$, $b = \ln \beta$ und $x = u \Rightarrow$ Die transformierte Funktion $\boxed{y = a + bx}$ ist eine Gerade mit den Koeffizienten a, b.
- Das weitere Vorgehen:
  - Transformiere entsprechend die Daten (u_i, v_i) der Stichprobe $(x_i; y_i)$
  - Berechne die Regressionskoeffizienten a und b mit der MkQ
  - Transformiere rückwärts α und β aus a und b; hier $\hat{\alpha} = e^a$ und $\hat{\beta} = e^b$
  - Erhalte die geschätzte Funktionsgleichung; hier $\boxed{v = \hat{\alpha} \cdot \hat{\beta}^u}$

Nicht-lineare Regression (formal)

- Gegeben: Stichprobe $(u_1, v_1), \ldots, (u_n, v_n)$ der Merkmale U und V
- Annahme: $\boxed{v = f(u)}$ mit Parametern α und β in nicht-linearer Form
- Transformation:

$$\boxed{T(v) = a + b\,g(u)} \quad \text{bzw.} \quad \boxed{y = a + b\,x} \quad \text{(Linearisierung)}$$

- Dann:
  1. Stichprobe $(u_i, v_i) \rightarrow (x_i, y_i) = (g(u_i), T(v_i))$ für $i = 1, \ldots, n$
  2. Bestimme mittels Geradenregression $y = a + b\,x$ die Parameter a und b
  3. Berechne aus a und b die ursprünglichen Funktionsparameter α und β
  4. $v = f(u, \alpha, \beta)$ ist die gesuchte Regressionsfunktion

Beispiel 1.11.2. *Nichlineare Nachfrage*

- *Ökonometrischer Zusammenhang: Nachfrage* v *nach einem bestimmten Konsumgut in Abhängigkeit des Einkommens* u

- *Ansatz:*

$$\boxed{v = \alpha e^{\beta/u}}$$

- *Daten:*

i	u_i	v_i	x_i $= \frac{1}{u_i}$	y_i $= \ln(v_i)$
1	1	6,9	$1/1 = 1$	$\ln(6{,}9) = 1{,}9315$
2	2	12,5	0,5	2,5257
3	3	19,3	0,3333	2,9601
4	5	34,8	0,2	3,5496
5	9	35,8	0,1111	3,5778
6	15	46,2	0,0667	3,8333
7	22	43,9	0,0455	3,7819
8	30	48,4	0,0333	3,8795

- *Transformation:*

$\ln(v) = \ln(\alpha) + \ln(e^{\beta/u})$

$$\ln(\cdot)\Big\} \quad v = \alpha\, e^{\beta/u} \quad \Rightarrow \quad \underbrace{\ln v}_{y} = \underbrace{\ln \alpha}_{a} + \underbrace{\beta}_{b} \cdot \underbrace{\frac{1}{u}}_{x} \quad \Longleftrightarrow \quad y = a + b\,x,$$

also: $y = \ln v$, $x = 1/u$, $a = \ln \alpha$, $b = \beta$

- *MkQ für die Parameter* a *und* b ($\sum_{i=1}^n x_i y_i = 5{,}8453$, $\sum_{i=1}^n x_i = 2{,}2899$, $\sum_{i=1}^n y_i = 26{,}0393$ *and* $\sum_{i=1}^n x_i^2 = 1{,}4211$): $n = 8$

$$\boxed{\hat a = \bar y - \hat b \bar x,}$$

$$\boxed{\hat b = \frac{\hat\sigma_{XY}}{\hat\sigma_X^2}} = \hat\rho_{XY} \cdot \frac{\hat\sigma_Y}{\hat\sigma_X} = \frac{\sum_{i=1}^n x_i y_i - n\bar x \bar y}{\sum_{i=1}^n x_i^2 - n\bar x^2} = \frac{\sum_{i=1}^n (x_i - \bar x)(y_i - \bar y)}{\sum_{i=1}^n (x_i - \bar x)^2}.$$

Kovarianz

Varianz der erklärenden Variable

$$\hat b = \frac{5{,}8453 - 8 \cdot \frac{2{,}2899}{8} \cdot \frac{26{,}0393}{8}}{1{,}4211 - 8 \cdot \left(\frac{2{,}2899}{8}\right)^2} = \boxed{-2{,}1}$$

$$\hat a = \frac{26{,}0393}{8} - \boxed{(-2{,}1)} \cdot \frac{2{,}2899}{8} = \boxed{3{,}856}$$

- *Rücktransformation in die Parameter* α *und* β:

$$\boxed{\hat\alpha = e^{\hat a}} = e^{3{,}856} = 47{,}28 \text{ und } \boxed{\hat\beta = \hat b} = -2{,}1$$

- *Nachfragefunktion:* $\boxed{v = 47{,}28\; e^{-2{,}1/u}}$

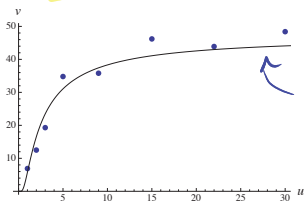

geschätzte nicht-lineare Funktion

Transformationstabelle: $v = f(u,\alpha\beta) \to y = a + b\,x$

- Weitere Beispiele nicht-linearer Problemstellungen, die auf einen linearen Regressionsansatz transformiert werden können, sind:

$v = f(u)$	$y = T(v)$	a	b	$x = g(u)$
$v = \alpha + \beta\, u^k$	$v = \alpha + \beta \cdot u^k$	α	β	u^k
$v = \frac{\alpha\, u}{\beta + u}$	$\frac{1}{v} = \frac{1}{\alpha} + \frac{\beta}{\alpha}\,\frac{1}{u}$	$\frac{1}{\alpha}$	$\frac{\beta}{\alpha}$	$\frac{1}{u}$
$v = \frac{u}{\alpha + \beta\, u}$	$\frac{u}{v} = \alpha + \beta\, u$	α	β	u
$v = \alpha\, \beta^u$	$\ln v = \ln \alpha + (\ln \beta) u$	$\ln \alpha$	$\ln \beta$	u
$v = \alpha\, u^\beta$	$\ln v = \ln \alpha + \beta\, \ln u$	$\ln \alpha$	β	$\ln u$

1.11.5 Fallstudie: Multivariate lineare Regression*

Univariate lineare Regression: Wir haben einen funktionalen Zusammenhang zw. dem Umsatz U und der durchschnittlichen Temperatur T gefunden. Können wir noch weitere Einflüsse (Wochenende, Regen) berücksichtigen?

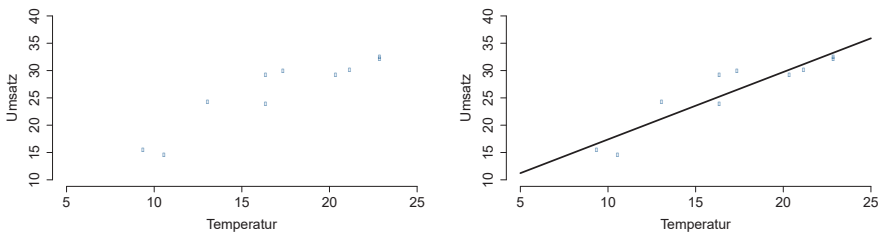

Multivariate lineare Regression*:

- Ansatz:
  - $y = b_0 + b_1\, x_1 + b_2\, x_2 + \cdots + b_L\, x_L$ (mehrere erklärendem Variablen
  - Mit dem Regressanden y und L Regressoren $x_1, \ldots, x_L$ (multivariate Regression); liegt nur ein Regressor x vor, spricht man dagegen von einer **univariaten** Regression

- Stichprobe: $((x_{11}, \ldots, x_{L1}), y_1), \ldots, ((x_{1n}, \ldots, x_{Ln}), y_n)$

- Gleichungssystem:

$$y_1 = b_0 + b_1\, x_{11} + b_2\, x_{21} + \cdots + b_L\, x_{L1} + \varepsilon_1$$
$$\vdots$$
$$y_n = b_0 + b_1\, x_{1n} + b_2\, x_{2n} + \cdots + b_L\, x_{Ln} + \varepsilon_n$$

- Darstellung in Matrixform: $\mathbf{y} = \mathbf{X}\mathbf{b} + \varepsilon,$

  mit der Designmatrix
$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{L1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{Ln} \end{pmatrix}$$

- MkQ-Lösung: $\mathbf{b} = (\mathbf{X}^T\mathbf{X})^{-1}\,\mathbf{X}^T\,\mathbf{y}$ ← Lösung durch Matrix-Inverse und Matrix-Multiplikation

  Multivariate lineare Regression*

- Daten:

Tag	1	2	3	4	5	6	7	8	9	10
u	29.21	23.96	32.47	30.19	29.11	15.47	24.25	29.84	14.57	32.09
t	20.40	16.40	22.90	21.20	16.40	9.40	13.10	17.40	10.60	22.90
r	0	0	0	0	0	0	0	0	1	0
w	0	0	0	0	1	0	1	1	0	0

Regen →
WE / Feiertagen →

- Designmatrix $\mathbf{X}$ mit den Spalten - 1. Konstante (Vektor von Einsen), 2. Temperatur t, 3. Regen r, 4. Wochenende w:

$$\mathbf{X} = \begin{pmatrix} 1 & 20.4 & 0 & 0 \\ 1 & 16.4 & 0 & 0 \\ \cdots & \cdots & \cdots & \\ 1 & 17.4 & 0 & 1 \\ 1 & 10.6 & 1 & 0 \\ 1 & 22.9 & 0 & 0 \end{pmatrix}$$

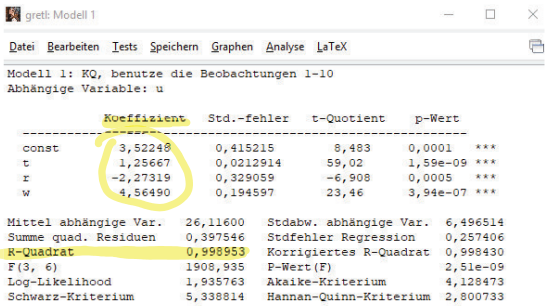

  Multivariate lineare Regression*

- MkQ-Lösung:

$$\mathbf{b} = (\mathbf{X}^T\mathbf{X})^{-1}\,\mathbf{X}^T\,\mathbf{u}$$
$$= \begin{pmatrix} 2.60 & -0.13 & -1.23 & -0.58 \\ -0.13 & 0.01 & 0.06 & 0.02 \\ -1.23 & 0.06 & 1.63 & 0.35 \\ -0.58 & 0.02 & 0.35 & 0.57 \end{pmatrix} \cdot \begin{pmatrix} 261.00 \\ 4721.00 \\ 15.00 \\ 83.00 \end{pmatrix}$$
$$= \begin{pmatrix} 3.51 \\ 1.26 \\ -2.27 \\ 4.57 \end{pmatrix}$$

- Umsatzfunktion: $u \approx 3.51 + 1.26 \cdot t - 2.27 \cdot r + 4.57 \cdot w,\ 9 \le t \le 24,\ r, w \in \{0,1\}.$

  Regen

  Kalender infos.

  Temp. Vorhersagen