Zusammenhangskennzahlen X, Y

Skala	*Kennzahl*
metrisch beide	Korrelation / Korrelationskoeffizient $\hat{\rho}_{XY}$ Berechnung über die Kovarianz $\hat{\sigma}_{XY}$
ordinal metrisch + ordinal oder ordinal + ordinal	Rangkorrelation / Spearman's rho $\hat{\rho}^{S}_{XY}$ Korrelation der Ränge
nominal metrisch + nominal oder ordinal + nominal oder nominal + nominal	normierte Kontingenz / Kontingenzkoeffizient C^* Berechnung über χ^2, C

"Chi"

1.10.3 χ^2-Koeffizient, Kontingenzkoeffizient, normierter Kontingenzkoeffizient

- Falls Merkmale auf der nominalen Skala gemessen werden, so kann ein Maß des Zusammenhangs nicht auf Basis der Ausprägungen bestimmt werden.
- Stattdessen wird ein Maß aus den Häufigkeiten abgeleitet, das den Abstand zum Fall der Unabhängigkeit misst.
- Es sei $\mathbf{H}_{XY}$ die gemeinsame Häufigkeitsverteilung der Merkmale X und Y.
- Genau dann, wenn X und Y unabhängig sind, gilt $\frac{H_{jk}}{H_{\cdot k}} = \frac{H_{j\cdot}}{n}$ für alle j und k.

Der χ^2-**Koeffizient** (Chi-Quadrat) ist definiert durch

die beobachteten gemeinsamen Häufigkeiten

die gemeinsamen Häufigkeiten, die wir unter Unabhängigkeit hätten beobachtet müssen

Quadrierte Abweichung zu Unabhängigkeit

wie weit sind die beobachteten Häufigkeiten von dem Unabhängigkeitsszenario entfernt.

$$\chi^2 = \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{\left(H_{jk} - \frac{H_{j\cdot}H_{\cdot k}}{n}\right)^2}{\frac{H_{j\cdot}H_{\cdot k}}{n}} = n\sum_{j=1}^{J}\sum_{k=1}^{K} \frac{(h_{jk} - h_{j\cdot}h_{\cdot k})^2}{h_{j\cdot}h_{\cdot k}},$$

wobei $\frac{H_{j\cdot}H_{\cdot k}}{n}$ die sogenannten **Unabhängigkeitszahlen** bezeichnen.

- χ^2 misst die quadratische Abweichung von der Unabhängigkeit.

Kontingenzkoeffizient

- χ^2 ist abhängig von der Dimension der Kontingenztafel.
- Die folgenden zwei Maße sind unabhängig von der Umfang der Stichprobe.

Der **Kontingenzkoeffizient** ist definiert als

Berechneter χ^2-Koeffizient

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}},$$

Stichprobenumfang

und nimmt einen Wert $C \in \left[0, \sqrt{\frac{M-1}{M}}\right]$ mit $M = \min(J,K)$ an.

min (# Spalten; # Zeilen)

Der **normierte Kontingenzkoeffizient** ist gegeben durch

$$C^* = C / \sqrt{\frac{M-1}{M}}$$

und besitzt einen Wert $C^* \in [0,1]$.

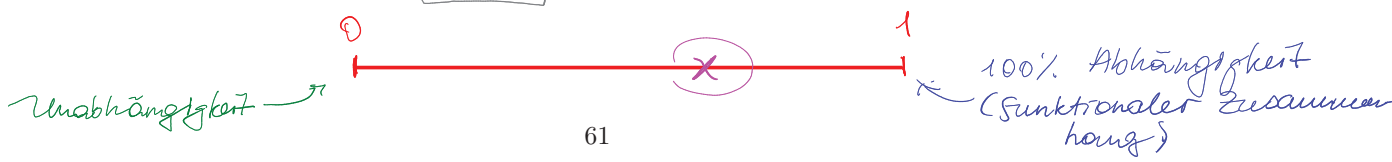

Dort sind die ...

$$\chi^2 = \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{\left(H_{jk} - \frac{H_{j\cdot}H_{\cdot k}}{n}\right)^2}{\frac{H_{j\cdot}H_{\cdot k}}{n}}$$

Beispiel 1.10.7. *Noten und Fitness*

- *Zur Grundgesamtheit der HWR-Studierenden liegt zu den Merkmalen*
  - *A = Fitnessgrad mit den Ausprägungen s = sportlich und u = unsportlich*
  - *B = Examensnote mit den Ausprägungen e = exzellent, g = gut und a = ausreichend*

  eine Stichprobe zum Umfang $n = 200$ mit absoluter Häufigkeitsverteilung vor:

die beobachteten gemeinsamen Häufigkeiten

H_{jk}	$b_1 = e$	$b_2 = g$	$b_3 = a$	$H_{j\cdot}$
$a_1 = s$	14	72	34	120
$a_2 = u$	12	55	13	80
$H_{\cdot k}$	26	127	47	200

mein hypothetisches Szenario: gemeinsame Häufigkeiten die ich unter Unabhängigkeit beobachten würde

$\frac{H_{j\cdot}\cdot H_{\cdot k}}{n}$	b_1	b_2	b_3
a_1	15,6	76,2	28,2
a_2	10,4	50,8	18,8

$a_1; b_1$: $\frac{H_{1\cdot}\cdot H_{\cdot 1}}{n} = \frac{120\cdot 26}{200} = 15{,}6$

$a_1; b_2$: $\frac{H_{1\cdot}\cdot H_{\cdot 2}}{n} = \frac{120\cdot 127}{200} = 76{,}2$

$a_2; b_3$: $\frac{H_{2\cdot}\cdot H_{\cdot 3}}{n} = \frac{80\cdot 47}{200} = 18{,}8$

- *Damit berechnen wir:*
  - $\chi^2 = \frac{(14-15{,}6)^2}{15{,}6} + \frac{(72-76{,}2)^2}{76{,}2} + \frac{(34-28{,}2)^2}{28{,}2} + \frac{(12-10{,}4)^2}{10{,}4} + \frac{(55-50{,}8)^2}{50{,}8} + \frac{(13-18{,}8)^2}{18{,}8}$

$= \underline{3{,}9713}$

$$C = \sqrt{\frac{\chi^2}{n+\chi^2}},$$

200

- $C = \sqrt{\frac{3{,}9713}{200+3{,}9713}} = 0{,}1395$

$$C^* = C/\sqrt{\frac{M-1}{M}}$$

- $C^* = \frac{0{,}1395}{\sqrt{\frac{2-1}{2}}} = \boxed{0{,}1973}$ ist immer im Intervall $[0;1]$

$M = \min(\#\text{Spalten}; \#\text{Zeilen})$ → siehe □

$= \min(2;3) = 2$

$M = \min(\#\text{Ausprägungen von } X; \#\text{Ausprägungen von } Y)$

1.10.4 Fallstudie: Korrelation - Aktienrendite

- Für die Monatsrenditen einer Aktie y bzw. des Marktportfolios x werden in einem halben Jahr die folgenden Werte (in %) gemessen:

Monat i	Marktrendite x_i	Aktienrendite y_i	$R(x_i)$	$R(y_i)$
1	0,4	0,4	4	2
2	0,9	1,5	5	5
3	1,2	1,8	6	6
4	0,2	1,0	3	4
5	−0,4	−1,1	2	1
$n =$ 6	−0,5	0,6	1	3

(a) Bestimmen Sie den empir. Korrelationskoeffizienten und interpretieren Sie das Ergebnis.

(b) Bestimmen Sie den Rangkorrelationskoeffizienten (nach Spearman).

- Empirische Erwartungswerte:

$$\bar{x} = \frac{1}{6}(0{,}4 + 0{,}9 + \ldots + (-0{,}5)) = 0{,}3$$

$$\bar{y} = \frac{1}{6}(0{,}4 + 1{,}5 + \ldots + 0{,}6) = 0{,}7$$

- Empirische Varianzen:

$$\hat{\sigma}_X^2 = \frac{1}{6-1}(0{,}4^2 + 0{,}9^2 + \ldots + (-0{,}5)^2) - \frac{6}{6-1}(0{,}3)^2 = \underline{0{,}464}$$

$$\hat{\sigma}_Y^2 = \frac{1}{6-1}(0{,}4^2 + 1{,}5^2 + \ldots + 0{,}6^2) - \frac{6}{6-1}(0{,}7)^2 = \underline{1{,}056}$$

- Empirische Kovarianz:

$$\hat{\sigma}_{XY} = \frac{1}{6-1}\cdot(0{,}4\cdot 0{,}4 + 0{,}9\cdot 1{,}5 + 1{,}2\cdot 1{,}8 + 0{,}2\cdot 1{,}0 + (-0{,}4)(-1{,}1) + (-0{,}5)\cdot 0{,}6) - \frac{6}{6-1}\cdot 0{,}3\cdot 0{,}7 = \underline{0{,}55}$$

← ein pos. linearer Zusammenhang

ausgeprägter pos. linearer Zusammenhang

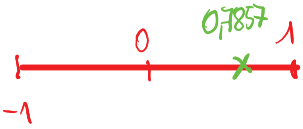

(a) Empirischer Korrelationskoeffizient: $\hat{\rho}_{XY} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X \cdot \hat{\sigma}_Y} = \frac{0{,}55}{\sqrt{0{,}464}\sqrt{1{,}056}} = \underline{0{,}7857}$

(b)

i	$R(x_i)$	$R(y_i)$	d_i^2
1	4	2	$(4-2)^2 = 4$
2	5	5	0
3	6	6	0
4	3	4	1
5	2	1	1
6	1	3	4
		Σ:	10

$$\hat{\rho}_{XY}^S = 1 - \frac{6\sum d_i^2}{n(n^2-1)} = 1 - \frac{6\cdot 10}{6\cdot(6^2-1)} = \underline{0{,}7143}$$

ausgeprägter pos. lin. Zusammenhang der Ränge