1.4 Kennzahlen bei einem Merkmal

Einstiegsbeispiel: Typischer Kunde

- Wie sieht unser typischer Kunde aus?
- Alter, Geschlecht, Beruf, Einkommen, Erfahrung,...

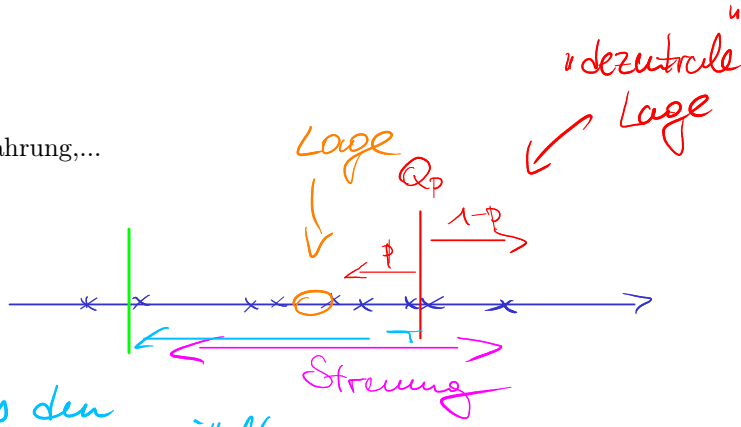

aus den Daten ermittelt

Lageparameter	• empirischer Erwartungswert (arithmetisches Mittel)
	• Zentralwert/Median ⇐ empfr.
	• gestutztes Mittel
	• geometrisches Mittel
	• Modalwert
Quantile	• p-Quantil
	• empirischer Median
Streuungsparameter	• empirische Varianz und ~~mittlere quadratische Abweichung~~
	• empirische Standardabweichung
	• Variationsbreite
	• Variationskoeffizient
Case Study	• Typischer Kunde + Empirische Quantile und Value at Risk

- **Lageparameter** kennzeichnen den zentralen Wert (die mittlere Lage) der Beobachtungsreihe
- **Quantile** geben Informationen, wie die Daten über die Spannbreite der Beobachtungen verteilt sind.

- **Streuungsparameter** kennzeichnen die Variabilität (die Streuung) der Beobachtungsreihe

- **Induktion**: Schluss von einer empirischen Kennzahl auf die entsprechende Kennzahl der Verteilung (→ Teil 3: Induktive Statistik)

Datenvorgabe

- Empirische Daten können wie folgt gegeben sein:
  - **Stichprobe**: $x_1, x_2, \dots, x_n$ ← Messwerte
  - **geordnete Stichprobe**: $x_{[1]} \leq x_{[2]} \leq \cdots \leq x_{[n]}$ ← aufsteigend sortiert
    → Ordnungsindex
  - **diskrete Häufigkeitsverteilung**:

    Ausprägungen

Ausprägungen	a_1	a_2	$\cdots$	a_J
Häufigkeiten	h_1	h_2	$\cdots$	h_J

    Häufigkeiten

  - **kontinuierliche Häufigkeitsverteilung**:

Klassen	K_1	K_2	$\cdots$	K_J
Klassenmitten	a_1	a_2	$\cdots$	a_J
Häufigkeiten	h_1	h_2	$\cdots$	h_J

oder Klassenmittel

- Mit Ausnahme des empirischen Erwartungswertes (als wichtigster Lageparameter) und der empirischen Varianz (als wichtigster Streuungsparameter) werden im Folgenden die Kennzahlen nur für die Datenvorgaben **Stichprobe** bzw. **geordnete Stichprobe** definiert.

1.5 Lagemaße

1.5.1 Empirischer Erwartungswert / Mittelwert

Der **empirische Erwartungswert** (auch: **Mittelwert**, **arithmetisches Mittel** oder **Stichprobenmittel**) einer Stichprobe $x_1, x_2, \dots, x_n$ wird wie folgt berechnet:

$$\boxed{\overline{x} = \hat{\mu}_X = \frac{1}{n}(x_1 + \cdots + x_n)} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Summe von $i=1$ bis n

Sind Häufigkeiten gegeben, so berechnet sich der empirische Erwartungswert wie folgt:

$$\boxed{\hat{\mu}_X = a_1 h_1 + \cdots + a_J h_J} = \sum_{j=1}^{J} a_j h_j = \frac{1}{n}\sum_{j=1}^{J} a_j H_j.$$

a_i	a_1	a_2	…	a_J
h_i	h_1	h_2	…	h_J

Beispiel: Stichprobe $n=8$
1; 2; 1; 3; 4; 2; 2; 3

$\overline{x} = \frac{1}{8}(1+2+1+3+4+2+2+3) = 2{,}25$

Häufigkeiten

a_j	1	2	3	4
H_j	2	3	2	1
h_j	1/4	3/8	1/4	1/8

$\overline{x} = 1\cdot\frac{1}{4} + 2\cdot\frac{3}{8} + 3\cdot\frac{1}{4} + 4\cdot\frac{1}{8} = 2{,}25$

1.5.2 Median, α-gestutztes Mittel

Gute Kennzahlen bei Ausreißern „robust"

Es sei $x_{[1]} \le x_{[2]} \le \cdots \le x_{[n]}$ eine **geordnete** Stichprobe. Der Median ist definiert durch

$$x_{\text{med}} = \begin{cases} x_{\left[\frac{n+1}{2}\right]}, & \text{falls } n \text{ ungerade,} \\ \frac{1}{2}\left(x_{\left[\frac{n}{2}\right]} + x_{\left[\frac{n}{2}+1\right]}\right), & \text{falls } n \text{ grade.} \end{cases}$$

$x_{\left[\frac{5+1}{2}\right]} = x_{[3]}$

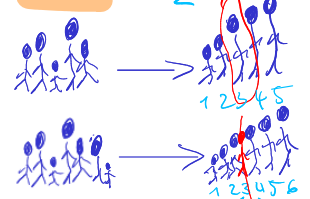

$\frac{1}{2}\left(x_{\left[\frac{6}{2}\right]} + x_{\left[\frac{6}{2}+1\right]}\right)$

Das **α-gestutztes Mittel** ist definiert durch

$$\overline{x}_\alpha = \frac{1}{n-2k}\left(x_{[k+1]} + \cdots + x_{[n-k]}\right),$$

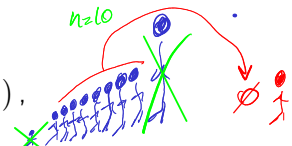

Anteil „zum Abschneiden"

Integer/Ganzzahliger Teil

mit $0 < \alpha < 0{,}5$, wobei $k = \text{int}(\alpha n)$ den ganzzahligen Anteil von αn bezeichnet.

geordnete Stichprobe

$x_{[i]}$	1	1	2	2	2	3	3	4
$[i]$	1	2	3	4	5	6	7	8

- $x_{med} = \frac{1}{2}(x_{[4]} + x_{[5]}) = \frac{1}{2}(2+2) = 2$
- $\alpha = 0{,}2 \longrightarrow k = \text{int}(0{,}2\cdot 8) = \text{int}(1{,}6) = 1$

$\overline{x}_\alpha = \frac{1}{8-2\cdot 1}(1+2+2+2+3+3) = 2{,}1667$

- Diese Maße sind robust gegenüber extremen Werten von Datenpunkten, sogenannten **Ausreißern**.
- Für den Median sind mindestens 50% der Daten $\left\{\begin{matrix}\textbf{kleiner als}\\ \textbf{größer als}\end{matrix}\right\}$ x_{med}.
- Das α-gestutzte Mittel eliminiert die extremsten Beobachtungen. Dies ist nützlich, wenn die Daten (unrealistische) Ausreißer aufweisen.

Beispiel 1.5.1. *Jahresrenditen*

- *Stichprobe: Jahresrenditen einer Aktie A (in %):* $n = 6$ Stichprobe

  2,2 9,8 – 3,2 – 1,3 4,5 1,8

  Ausreißer ?

- *Berechnen Sie*
  - *den empirischen Erwartungswert* $\bar{x}$,
  - *den Median* x_{med},
  - *das* α*-gestutzte Mittel für* $\alpha = 0{,}2$.

die mittlere Rendite

- $\bar{x} = \frac{1}{6}(2{,}2 + 9{,}8 - 3{,}2 - 1{,}3 + 4{,}5 + 1{,}8) = 2{,}3$

- x_{med} : geordnete Stichprobe

$x_{[i]}$	~~-3,2~~	-1,3	1,8	2,2	4,5	~~9,8~~
$[i]$	1	2	3	4	5	6

$n = 6 \longrightarrow$ gerade

$x_{med} = \frac{1}{2}\left(x_{[\frac{n}{2}]} + x_{[\frac{n}{2}+1]}\right) = \frac{1}{2}\left(x_{[3]} + x_{[4]}\right) = \frac{1}{2}(1{,}8 + 2{,}2)$
$= 2$

- $\bar{x}_\alpha$, $\alpha = 0{,}2 \longrightarrow k = \text{int}(0{,}2 \cdot 6) = \text{int}(1{,}2) = 1$

$\bar{x}_{0{,}2} = \frac{1}{6-2\cdot 1}(-1{,}3 + 1{,}8 + 2{,}2 + 4{,}5) = \underline{1{,}8}$