1.5.3 Geometrisches Mittel

- $p_0, p_1, \dots, p_n$ ist eine Zeitreihe von Größen oder Preisen.
- Definiere die **Zuwachsfaktoren** $q_i = \frac{p_i}{p_{i-1}}$, $i = 1, \dots, n$.

wie hoch ist der ∅ Zuwachs

- Das geometrische Mittel ist das geeignete Maß für das durchschnittliche Wachstum über mehrere Zeitperioden.

Es sei $x_0, x_1, \dots, x_n$ eine Stichprobe von positiven Zahlen (Zuwachsfaktoren). Das **geometrische Mittel** ist definiert als

$$\boxed{x_{\text{geom}} = (x_1 \cdot x_2 \cdot \ldots \cdot x_n)^{1/n}.} \quad = \sqrt[n]{x_1 \cdot x_2 \cdot \ldots \cdot x_n}$$

- Die folgende Gleichung zeigt, dass das geometrische Mittel tatsächlich ein Durchschnitt ist:

Anfangspreis

$$p_n = p_{n-1} \cdot q_n = p_{n-2} \cdot q_{n-1} \cdot q_n = p_0 \cdot q_1 \cdot \ldots \cdot q_n = p_0 \cdot q_{\text{geom}}^n.$$

der ∅ Zuwachs

Beispiel 1.5.2. *Handelsbuch*

- *Gegeben: Folge p_0, p_1, p_2, p_3 der Wertentwicklung eines Handelsbuchs (in Geldeinheiten, GE)*
- *Bestimme Zuwachsfaktoren q_1, q_2, q_3*

Monat	i	p_i	q_i
Dezember	*0*	*782*	–
Januar	*1*	*854*	*1,0921*
Februar	*2*	*1042*	*1,2201*
März	*3*	*731*	*0,7015*

$= \frac{854}{782}$ $= \frac{1042}{854}$ $\frac{731}{1042}$

Der Preis ist gesunken → ∅ Zuwachs < 1.

- *Geometrisches Mittel:* $q_{geom} = (q_1 q_2 q_3)^{1/3} = 0{,}9778 < 1$
- *Arithmetisches Mittel:* $\overline{q} = \frac{1}{3}(1{,}0921 + 1{,}2201 + 0{,}7015) = 1{,}0046 > 1$ ← ergibt keinen Sinn
- *Bemerkungen:*
  - *Das geometrische Mittel beschreibt den Kursrückgang von Dezember bis März.*
  - *Nur das geometrische Mittel hat eine sinnvolle Interpretation als durchschnittlicher Zuwachs.*
  - *Zuwachsfaktoren können durch* **Zuwachsraten** *(d. h.* **Renditen***) ersetzt werden via $q_i = (1 + r_i)$.*

1.5.4 Modalwert

Es sei $x_1, x_2, \dots, x_n$ eine Stichprobe eines Merkmals X mit **beliebiger Skala** und mit möglichen Ausprägungen $a_1, \dots, a_J \in A_X$.

Der **Modalwert** ist definiert als die am häufigsten beobachtete Ausprägung:

$$x_{\text{mod}} = a_j \quad \text{mit } H(a_j) = \max(H(a_1), \dots, H(a_J)).$$

- Der Modalwert ist das einzige sinnvolle Lagemaß für Merkmale auf einer nominalen Skala.

Beispiel 1.5.3. *Kreditausfälle, siehe 1.2.1,Seite 12*

$$x_{\text{mod}} = a_2 = \textit{Probleme bei der Haushaltsführung}$$

ist die häufigste Ursache von Kreditausfällen laut der Datenlage.

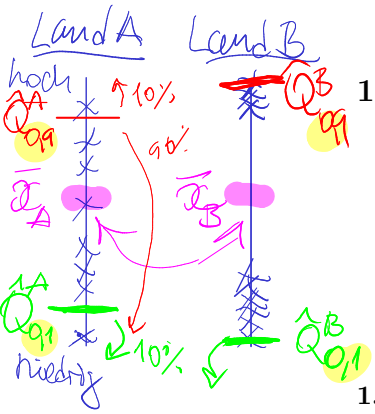

1.6 Quantile und Boxplots

- Eine angemessene, aggregierte Beschreibung einer Datenmenge erfordert zusätzlich Informationen über die Streuung der Daten.
- So kann bspw. trotz gleicher Mittelwerte und/oder Mediane für das Einkommen in zwei Ländern eine große Lücke zwischen armen und reichen Personen bestehen.
- Quantile als ein statistisches Maß und Boxplots als graphisches Werkzeug sind nützlich zum Vergleich von Verteilungen.

1.6.1 Quantile

Es sei p mit $0 < p < 1$ gegeben. Jede Zahl $\hat{Q}_p$ mit der Eigenschaft, dass

- mindestens ein Anteil p der Daten kleiner oder gleich $\hat{Q}_p$ ist, vspace-0.2cm
- mindestens ein Anteil $1-p$ der Daten größer oder gleich $\hat{Q}_p$ ist,vspace-0.2cm

heißt **p-Quantil**.

Sei $x_{[1]} \leq x_{[2]} \leq \dots \leq x_{[n]}$ eine geordnete Stichprobe eines ordinal oder metrisch skalierten Merkmals X. Das **p-Quantil** $\hat{Q}_p$ erfüllt

Ganzer Teil

Anzahl von Beobachtungen, die kleiner oder gleich Q_p sein sollen

$$\hat{Q}_p = \begin{cases} x_{[\text{int}(np)+1]}, & \text{falls } np \text{ keine ganze Zahl ist,} \\ \frac{1}{2}\left(x_{[np]} + x_{[np+1]}\right), & \text{falls } np \text{ eine ganze Zahl ist,} \end{cases}$$

wobei $\text{int}(np)$ den ganzzahligen Anteil von np bezeichnet.

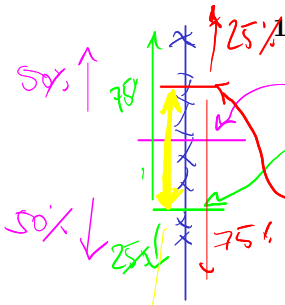

1.6.2 Spezielle Quantile und Quartilsabstand

- $p = 0{,}5$: Der empirische **Median** x_{med} ist das 0,5-Quantil.
- $p = 0{,}25$: **Unteres Quartil**
- $p = 0{,}75$: **Oberes Quartil**
- $p = k/100$: **k-tes Perentil** ($k = 1, \dots, 99$) $k=1 \rightarrow$ erstes Perzentil $= \hat{Q}_{0{,}01}$

Der Abstand $\hat{q} = \hat{Q}_{0{,}75} - \hat{Q}_{0{,}25}$ ist der **Quartilsabstand** (**interquartile range (IQR)**).

zentraler Schwankungsbereich der Daten

Streuungsmaß

Beispiel 1.6.1. *Quantile*

- *Daten:*

geordnete Stichprobe

i	1	2	3	4	5	6	7	8	9	10	11	12
$x_{[i]}$	-1,1	-0,5	-0,1	0,2	0,2	0,7	0,8	0,9	1,0	1,3	1,4	5,8

$n = 12$

- *Berechnen Sie:*

  – *die Quantile:*

der ganze Anteil aus $n \cdot p$

$$\hat{Q}_p = \begin{cases} x_{[\text{int}(np)+1]} & \text{falls } np \text{ keine ganze Zahl ist,} \\ \frac{1}{2}\left(x_{[np]} + x_{[np+1]}\right) & \text{falls } np \text{ eine ganze Zahl ist,} \end{cases}$$

$$\hat{Q}_{0{,}05} = x_{[\text{int}(0{,}6)+1]} = x_{[0+1]} = x_{[1]} = -1{,}1 \qquad n \cdot p = 12 \cdot 0{,}05 = 0{,}6$$

$$\hat{Q}_{0{,}15} = x_{[\text{int}(1{,}8)+1]} = x_{[1+1]} = x_{[2]} = -0{,}5 \qquad n \cdot p = 12 \cdot 0{,}15 = 1{,}8$$

Unteres Quartil

$$\hat{Q}_{0{,}25} = \frac{1}{2}\left(x_{[3]} + x_{[3+1]}\right) = \frac{1}{2}(-0{,}1 + 0{,}2) = \underline{0{,}05} \qquad n \cdot p = 12 \cdot 0{,}25 = 3$$

Oberes Quartil

$$\hat{Q}_{0{,}75} = \frac{1}{2}\left(x_{[9]} + x_{[9+1]}\right) = \frac{1}{2}(1{,}0 + 1{,}3) = \underline{1{,}15} \qquad n \cdot p = 12 \cdot 0{,}75 = 9$$

  – *den Quartilsabstand*

$$\hat{q} = \hat{Q}_{0{,}75} - \hat{Q}_{0{,}25} = 1{,}15 - 0{,}05 = \underline{1{,}1}$$

Der zentrale Schwankungsbereich der Kundiererteilung

– Der Median:

$$x_{\text{med}} \overset{n \text{ gerade}}{=} \frac{1}{2}\left(x_{[6]} + x_{[7]}\right) = \frac{1}{2}(0{,}7 + 0{,}8) = \underline{0{,}75}$$

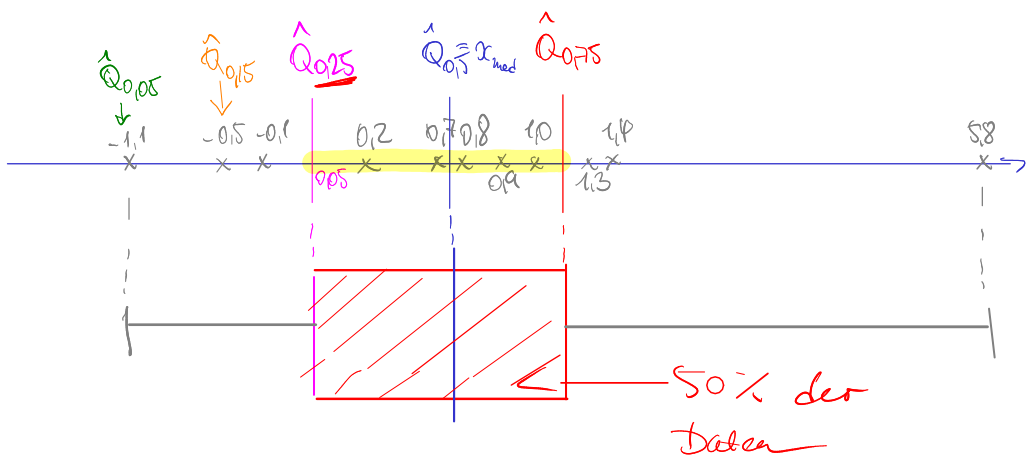

1.6.3 Boxplot

- Eine einfache, jedoch aussagekräftige graphische Darstellung der Verteilung eines Merkmals ist der **Boxplot**, auch genannt **Box-Whisker-Plot**.

Ein **Boxplot** ist eine graphische Darstellung mit den folgenden Komponenten:

- Eine Box mit dem unteren Ende der Box bei $\hat{Q}_{0,25}$ und dem oberen Ende bei $\hat{Q}_{0,75}$.
- Der Median ist markiert als ein Punkt oder eine Linie.
- Zwei Linien (die Whiskers (Antennen)) sind zwischen $\hat{Q}_{0,25}$ und $x_{\min}$ bzw. $\hat{Q}_{0,75}$ und $x_{\max}$ eingezeichnet. Verschiedene Definitionen der Länge sind praxisüblich.

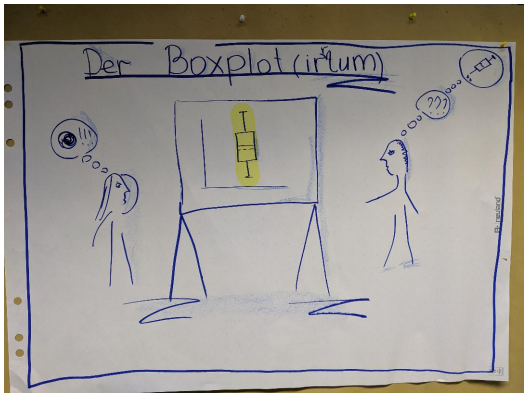

Beispiel 1.6.2. *Renditen von Aktienindizes*

- *Boxplots erzeugt für tägliche Renditen der Indizes DAX, S&P 500, Dow Jones Industrial Average und FTSE 100 vom 1. Oktober 2015 bis 1. Oktober 2016. (Datenquelle: Wolfram):*

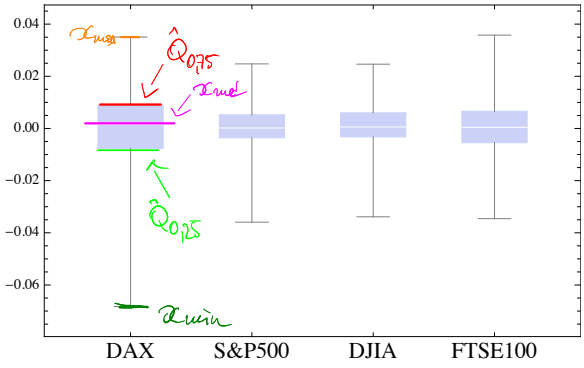

1.7 Streuungsmaße

1.7.1 Empirische Varianz, empirische Standardabweichung

Die **empirische Varianz** einer Stichprobe $x_1, \dots, x_n$ ist gegeben durch

"sigma"

$$\hat{\sigma}_X^2 = \frac{1}{n-1}\left[(x_1-\overline{x})^2 + \dots + (x_n-\overline{x})^2\right] = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\overline{x})^2.$$

$\overline{x}$

Achtung! Teile durch n-1: dies hat mit der Erwartrene eines Schätzer zu tun. Intuition: habe eine Beobachtung "verbraucht" um $\overline{x}$ zu berechnen

die Einheiten der Stichprobenwerte werden quadriert (Euro^2; %^{2})

Sind Häufigkeiten gegeben, so kann die empirische Varianz wie folgt berechnet werden:

$$\hat{\sigma}_X^2 = \frac{n}{n-1}\left[(a_1-\overline{x})^2 h_1 + \dots + (a_n-\overline{x})^2 h_n\right] = \frac{n}{n-1}\sum_{j=1}^{J}(a_j-\overline{x})^2 h_j.$$

Die **empirische Standardabweichung** ist die Wurzel der empirischen Varianz:

$$\hat{\sigma}_X = \sqrt{\hat{\sigma}_X^2}.$$

hat die Einheiten wie die Stichprobenwerte

- Die Varianz beschreibt die quadratische *Abweichung* vom Mittelwert.
- Durch Quadrieren werden kleine Abweichungen negiert, während große Abweichungen verstärkt werden.
- $\hat{\sigma}_X$ und X haben dieselbe Einheit.
- Die folgenden Formeln sind nützlich für Berechnungen.

Alternative Varianzformeln

$$\hat{\sigma}_X^2 = \frac{1}{n-1}\sum_{i=1}^{n} x_i^2 - \frac{n}{n-1}\overline{x}^2$$

$$\hat{\sigma}_X^2 = \frac{n}{n-1}\sum_{j=1}^{J} a_j^2 h_j - \frac{n}{n-1}\overline{x}^2$$

Beispiel 1.7.1. *Empirische Varianz und Standardabweichung*

- *Stichprobe: Jahresrenditen einer Aktie A (in %):*

$n=6$; $\overline{x} = 2{,}3$

Stichprobe → 2,2 9,8 −3,2 −1,3 4,5 1,8

- *Berechnen Sie die empir. Varianz $\hat{\sigma}_X^2$, die empir. Standardabweichung $\hat{\sigma}_X$.*

$$\hat{\sigma}_X^2 = \frac{1}{6-1}\cdot\left(2{,}2^2 + 9{,}8^2 + (-3{,}2)^2 + (-1{,}3)^2 + 4{,}5^2 + 1{,}8^2\right) - \frac{6}{6-1}(2{,}3)^2 =$$

$$= 20{,}912 \quad (\%^2)$$

$(\%_{6000})$

$$\hat{\sigma}_X = \sqrt{\hat{\sigma}_X^2} = \sqrt{20{,}912} = 4{,}573$$

mittlere Abweichung von $\overline{x}$ (2,3%)

Erwarte: $2{,}3\% \pm 4{,}573\%$ → 6,9 % → −2,3 %

die meisten Schwankungen werden in diesem Bereich stattfinden.

1.7.2 Transformationsregel: $\hat{\mu}$ und $\hat{\sigma}^2$ unter linearen Transformationen

Für eine lineare Transformation der Daten $y_i = a + bx_i$, $i = 1, \dots, n$, gilt

$$\overline{y} = a + b\overline{x}, \quad \hat{\sigma}_Y^2 = b^2 \hat{\sigma}_X^2 \quad \text{und} \quad \hat{\sigma}_Y = |b| \hat{\sigma}_X.$$

- Beweis:*

$$\begin{aligned}
\overline{y} &= \frac{1}{n}\sum_{i=1}^{n} y_i = \frac{1}{n}\sum_{i=1}^{n}(a + bx_i) = \frac{1}{n} \cdot n \cdot a + b \cdot \frac{1}{n}\sum_{i=1}^{n} x_i = a + b\overline{x} \\
\hat{\sigma}_Y^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \overline{y})^2 = \frac{1}{n-1}\sum_{i=1}^{n}(a + bx_i - a - b\overline{x})^2 \\
&= b^2 \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2 = b^2 \hat{\sigma}_x^2
\end{aligned}$$

Beispiel 1.7.2. *lineare Transformation: Temperaturskala*

- *Die Temperaturskala kann in die Einheiten Celsius oder Fahrenheit unterteilt sein.*
- *Zur Umrechnung der Temperatur von X in $^\circ C$ nach Y in $^\circ F$ besteht der lineare Zusammenhang*

$$Y = \overset{b}{1{,}8}X + \overset{=a}{32}.$$

- *An einem Ort ergeben die täglichen Temperaturmessungen eines Jahres (jeweils um 12.00 Uhr mittags) die folgenden Kennzahlen aus der Celsiusskala:*

$$\hat{\mu}_C = 13{,}5^\circ\mathrm{C} \qquad \textit{und} \qquad \hat{\sigma}_C^2 = 9{,}5(^\circ\mathrm{C})^2.$$

- *Damit lassen sich - ohne Rückgriff auf die zugrunde liegende Stichprobe - die entsprechenden Fahrenheitwerte ermitteln:*

$$\hat{\mu}_F = 1{,}8 \cdot 13{,}5 + 32 = 56{,}3^\circ\mathrm{F} \qquad \textit{und} \qquad \hat{\sigma}_F^2 = 1{,}8^2 \cdot 9{,}5 = 30{,}78(^\circ\mathrm{F})^2.$$

Ausreißer?

1.7.3 z-Score, Spannbreite, Variationskoeffizient

- Gegeben: Stichprobe $x_1, \dots x_n$ eines metrisch skalierten Merkmals X

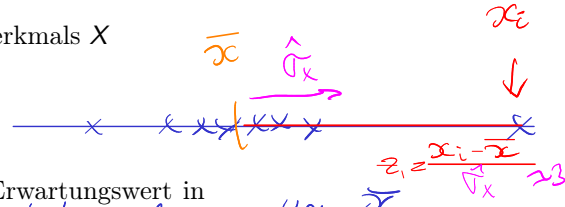

Der **z-Score** z-Score der iten Beobachtung

$$z_i = \frac{x_i - \bar{x}}{\hat{\sigma}}, \quad i = 1, \dots, n,$$

misst die Abweichung einer Beobachtung vom empirischen Erwartungswert in Einheiten der Standardabweichung. (Wieviele Standardabweichungen von $\bar{x}$ entfernt liegt die ite Beobachtung x_i)

Die **Spannbreite** (*engl.*: Range) ist definiert durch

der max Wert

$$R = \max(x_1, \dots, x_n) - \min(x_1, \dots, x_n) = x_{[n]} - x_{[1]}.$$

der min Wert

gesamte Variabilität in den Daten

Der **Variationskoeffizient** (*engl.* Coefficient of Variation) ist definiert durch

$$\text{cv} = \frac{\hat{\sigma}_X}{\bar{x}}.$$

Standardabweichung bezogen auf den Mittelwert.

negiert die Abhängigkeit der $\hat{\sigma}_X$ von dem $\bar{x}$.

Beispiel 1.7.3. *Zwei Aktien*

- *Kursentwicklung der Aktien A (Merkmal X) und B (Merkmal Y):*

	i	1	2	3	4	5
Aktie A	x_i	1750	1770	1740	1740	1760
Aktie B	y_i	124	119	122	125	120

Mittelwerte sind sehr verschieden

Kaum Variabilität in den Aktienkursen besser vergleichen

- *Berechnen Sie die folgenden Kennzahlen:*

$\bar{x} =$ 1752	$\hat{\sigma}_X^2 =$ 170	$\hat{\sigma}_X =$ $\sqrt{170} = 13{,}0384$ $cv_X =$
$\bar{y} =$ 122	$\hat{\sigma}_Y^2 =$ 6,5	$\hat{\sigma}_Y =$ $\sqrt{6{,}5} = 2{,}5495$ $cv_Y =$

- *Interpretieren Sie das Ergebnis!*

empir. Erwartungswerte:

$$\bar{x} = \frac{1}{5}(1750 + 1770 + 1740 + 1740 + 1760) = \underline{1752}$$

$$\bar{y} = \frac{1}{5}(124 + 119 + 122 + 125 + 120) = \underline{122}$$

empir. Varianzen:

$$\hat{\sigma}_X^2 = \frac{1}{5-1} \cdot (1750^2 + 1770^2 + 1740^2 + 1740^2 + 1760^2) - \frac{5}{5-1} \cdot (1752)^2 = \underline{170}$$

$$\hat{\sigma}_Y^2 = \frac{1}{5-1} \cdot (124^2 + 119^2 + 122^2 + 125^2 + 120^2) - \frac{5}{5-1} (122)^2 = \underline{6{,}5}$$

$$\hat{\sigma}_X^2 = \frac{1}{n-1}\sum_{i=1}^{n} x_i^2 - \frac{n}{n-1}\bar{x}^2$$

Variationskoeffizienten:

$$CV_X = \frac{\hat{\sigma}_X}{\bar{x}} = \frac{13{,}0384}{1752} = 0{,}0074 \quad ; \quad CV_Y = \frac{\sigma_Y}{\bar{y}} = \frac{2{,}5495}{122} = 0{,}0209$$

Aktie A ist attraktiver, da die normierte Schwankungen kleiner sind.

Gegeben ist eine Stichprobe von Aktienrenditen:

~~-1,2~~; 3,5; ~~2,0~~; ~~-2,5~~; ~~1,5~~; ~~-0,5~~; 6,1; ~~0~~; ~~-1,1~~; ~~-0,9~~.

Das 5%-Quantil ist [ ]. $\longrightarrow \hat{Q}_{0,05}$ $(p = 0,05)$

$$\hat{Q}_p = \begin{cases} x_{[\mathrm{int}(np)+1]}, & \text{falls } np \text{ keine ganze Zahl ist,} \\ \frac{1}{2}\left(x_{[np]} + x_{[np+1]}\right), & \text{falls } np \text{ eine ganze Zahl ist,} \end{cases}$$

geordnete Stichprobe

$n = 10$

i	1	2	3	4	5	6	7	8	9	10
$x_{[i]}$	-2,5	-1,2	-1,1	-0,9	-0,5	0	1,5	2,0	3,5	6,1

$\hat{Q}_{0,05} = x_{[\mathrm{int}(np)+1]} = x_{[\mathrm{int}(0,5)+1]} = x_{[0+1]} = x_{[1]} = \underline{-2,5}$.

$n \cdot p = 10 \cdot 0,05 = 0,5$ (keine ganze Zahl)

Gegeben ist eine Stichprobe von Aktienrenditen: -1,2; 3,5; 2,0; -2,5; 1,5.

$(n=5)$

Die empirische Varianz ist [ ].

$\bar{x} = \frac{1}{5}(-1,2+3,5+2-2,5+1,5) = \underline{0,66}$

$$\hat{\sigma}_X^2 = \frac{1}{n-1}\sum_{i=1}^{n} x_i^2 - \frac{n}{n-1}\bar{x}^2$$

$\hat{\sigma}_X^2 = \underbrace{\frac{1}{5-1}\left((-1,2)^2+(3,5)^2+(2,0)^2+(-2,5)^2+1,5^2\right)}_{\underline{6,5475}} - \frac{5}{5-1}\cdot(0,66)^2 =$

$= \underline{6,003}$

Gegeben ist die Häufigkeitsverteilung zum Merkmal X:

$n = 10$

i	1	2	3	4
a_i	2	4	6	8
H_i	3	2	2	3
h_i	0,3	0,2	0,2	0,3

$\Sigma = 10$

$\bar{x} = \sum_{i=1}^{4} a_i \cdot h_i = 2\cdot 0,3 + 4\cdot 0,2 + 6\cdot 0,2 + 8\cdot 0,3 = \underline{5}$

$$\hat{\sigma}_X^2 = \frac{n}{n-1}\sum_{j=1}^{J} a_j^2 h_j - \frac{n}{n-1}\bar{x}^2$$

$\hat{\sigma}_X^2 = \frac{10}{10-1}\cdot\left(2^2\cdot 0,3 + 4^2\cdot 0,2 + 6^2\cdot 0,2 + 8^2\cdot 0,3\right) - \frac{10}{10-1}\cdot(5)^2 =$

$= \underline{6,4444}$

$\hat{\sigma}_X = \sqrt{6,4444} = \underline{2,5386}$.

Gegeben ist die Häufigkeitsverteilung zum Merkmal X:

j	1	2	3
K_j	[0;10)	[10;30)	[30;60]
a_j	5	20	45
h_j	0,5	0,2	0,3

$n = 10$

$\bar{x} = \sum_{j=1}^{3} a_j \cdot h_j = \underline{20}$

$\hat{\sigma}_X^2 = \frac{10}{10-1}\cdot\left(5^2\cdot 0,5 + 20^2\cdot 0,2 + 45^2\cdot 0,3\right) - \frac{10}{10-1}\cdot 20^2 = \underline{333,3333}$

$\hat{\sigma}_X = \sqrt{333,3333} = \underline{18,2574}$