Ein Merkmal → Häufigkeitsverteilung: H_i; h_i; H_j; h_j
→ Kennzahlen: empir. Erwartungswert $\bar{x}$; empir. Varianz $\hat{\sigma}^2$
→ Verteilung auf die Merkmalsträger → Lorenzkurve → Gini → CRa

1.9 Zusammenhangsmaße bei zwei Merkmalen

Beispiel 1.9.1. *Kundenaufkommen und Wetter. Hypothese: Ihr Umsatz ist wetterabhängig.*

Ihre Chefin braucht dennoch datenbasierte Evidenz. Sie haben folgende Daten vorliegen. Wie gehen Sie vor?

→ Zwei Merkmale

	X	Y
Tag	*Wetterbedingungen*	*Umsatzniveau*
1	*gut*	*mittel*
2	*schlecht*	*mittel*
3	*gut*	*hoch*
4	*gut*	*hoch*
5	*schlecht*	*mittel*
6	*schlecht*	*niedrig*
7	*schlecht*	*mittel*
8	*schlecht*	*mittel*
9	*schlecht*	*niedrig*
10	*gut*	*hoch*

- Ob ein Zusammenhang besteht
- Wie stark ist dieser Zusammenhang

Einführung

- Wir erweitern den Begriff der Häufigkeitsverteilung auf **zwei Merkmale**. Das Paar (X,Y) nimmt nun Ausprägungskombinationen (a,b) mit $a \in A_X$ und $b \in A_Y$ an.

- Aus der **gemeinsamen Häufigkeitsverteilung** von (X,Y) (relative oder absolute Häufigkeiten) kann auf die entsprechenden **Randhäufigkeiten** von X und Y geschlossen werden. Die Umkehrung gilt allgemein nicht: Die Rand- häufigkeiten legen die gemeinsame Häufigkeitsverteilung nicht eindeutig fest.

betrachte isoliert nur ein Merkmal

- Ist die Ausprägung b des Merkmals Y bekannt, erhalten wir aus der gemeinsamen Häufigkeitsverteilung von (X,Y) die **bedingte Häufigkeitsverteilung** von X (unter der Bedingung $Y = b$).

- Sind für alle Ausprägungen $b \in A_Y$ die bedingten Häufigkeitsverteilungen von X gleich der Randhäufigkeit von X, so ist das Merkmal X **unabhängig** von Y.

ob ein Zusammenhang besteht oder nicht.

- Für abhängige Merkmale X und Y schließen sich zwei wichtige Fragen an:

  1. Kann die **Stärke des Zusammenhangs** gemessen werden?

     $\rightsquigarrow$ **Korrelationskoeffizient**

  2. Kann ein **funktionaler Zusammenhang** bestimmt werden?

     In der deskriptiven Statistik beschränken wir unsere Analyse auf die Annahme eines **linearen** Zusammenhangs zwischen den Merkmalen X und Y.

     $\rightsquigarrow$ **lineare Regression**

1.9.1 Häufigkeiten und Randhäufigkeiten

- Es sei $(x_1,y_1), \dots, (x_n,y_n)$ eine gemeinsame Stichprobe der Merkmale X, Y.
  - Die möglichen Ausprägungen von X werden mit $A_X = \{a_1, \dots, a_J\}$ bezeichnet.
  - Die möglichen Ausprägungen von Y werden mit $B_Y = \{b_1, \dots, b_K\}$ bezeichnet.

Absolute und relative Häufigkeiten

- Die **absolute Häufigkeit** $H_{jk} = H(a_j, b_k)$ ist gegeben durch die Anzahl der Beobachtungen mit $(x_i, y_i) = (a_j, b_k)$.
- Die **relative Häufigkeit** $h_{jk} = h(a_j, b_k)$ berechnet sich als H_{jk}/n.
- Die **gemeinsame Häufigkeitsverteilung** ist gegeben durch

$$\mathbf{h}_{XY} = \begin{pmatrix} h_{11} & h_{12} & \cdots & h_{1K} \\ \vdots & \vdots & & \vdots \\ h_{J1} & h_{J2} & \cdots & h_{JK} \end{pmatrix} = \frac{1}{n}\mathbf{H}_{XY} = \frac{1}{n}\begin{pmatrix} H_{11} & H_{12} & \cdots & H_{1K} \\ \vdots & \vdots & & \vdots \\ H_{J1} & H_{J2} & \cdots & H_{JK} \end{pmatrix}.$$

Randhäufigkeiten

Es seien $\mathbf{H}_{XY}$ $\mathbf{h}_{XY}$ die gemeinsamen Häufigkeiten von $(x_1, y_1), \ldots, (x_n, y_n)$.

- Die **Randhäufigkeiten** sind die univariaten Häufigkeiten:

Summiere zeilenweise! ignoriere das zweite Merkmal

die "normalen" Häufigkeiten für ein Merkmal

$$\boxed{H_{j\cdot}} = \sum_{k=1}^{K} H_{jk} = \text{absolute Randhäufigkeit von } a_j$$

Summiere spaltenweise

$$\boxed{H_{\cdot k}} = \sum_{j=1}^{J} H_{jk} = \text{absolute Randhäufigkeit von } b_k$$

$$\boxed{h_{j\cdot}} = \sum_{k=1}^{K} h_{jk} = \text{relative Randhäufigkeit von } a_j$$

$$\boxed{h_{\cdot k}} = \sum_{j=1}^{J} h_{jk} = \text{relative Randhäufigkeit von } b_k$$

- Die **Randhäufigkeitsverteilungen** sind gegeben durch:

$$\mathbf{h}_X = \begin{pmatrix} h_{1\cdot} & h_{2\cdot} & \cdots & h_{J\cdot} \end{pmatrix} \qquad \textbf{Randhäufigkeitsverteilung von } X$$

$$\mathbf{h}_Y = \begin{pmatrix} h_{\cdot 1} & h_{\cdot 2} & \cdots & h_{\cdot K} \end{pmatrix} \qquad \textbf{Randhäufigkeitsverteilung von } Y$$

Kontingenztafel

Eine **Kontingenztafel** ist die gemeinsame Darstellung der gemeinsamen Häufigkeiten und der Randhäufigkeiten (bezeichnet als $\sum$):

Ausprägungen von Y

Ausprägungen von X

	b_1	b_2	$\cdots$	b_K	$\sum$
a_1	H_{11}	H_{12}	$\cdots$	H_{1K}	$H_{1\cdot}$
a_2	H_{21}	H_{22}	$\cdots$	H_{2K}	$H_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_J	H_{J1}	H_{J2}	$\cdots$	H_{JK}	$H_{J\cdot}$
$\sum$	$H_{\cdot 1}$	$H_{\cdot 2}$	$\cdots$	$H_{\cdot K}$	n

	b_1	b_2	$\cdots$	b_K	$\sum$
a_1	h_{11}	h_{12}	$\cdots$	h_{1K}	$h_{1\cdot}$
a_2	h_{21}	h_{22}	$\cdots$	h_{2K}	$h_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_J	h_{J1}	h_{J2}	$\cdots$	h_{JK}	$h_{J\cdot}$
$\sum$	$h_{\cdot 1}$	$h_{\cdot 2}$	$\cdots$	$h_{\cdot K}$	1

gemeinsame Häufigkeiten

Randhäufigkeiten für X

Randhäufigkeiten für Y.

Tag	Wetterbedingungen (X)	Umsatzniveau (Y)
1	gut	mittel
2	schlecht	mittel
3	gut	hoch
4	gut	hoch
5	schlecht	mittel
6	schlecht	niedrig
7	schlecht	mittel
8	schlecht	mittel
9	schlecht	niedrig
10	gut	hoch

$A_X = \{\text{"gut"}; \text{"schlecht"}\}$

$\text{"gut"} \to a_1, \quad \text{"schlecht"} \to a_2$

$A_Y = \{\text{"niedrig"}; \text{"mittel"}; \text{"hoch"}\}$

$\text{"niedrig"} \to b_1, \quad \text{"mittel"} \to b_2, \quad \text{"hoch"} \to b_3$

$n = 10$

Kontingenztabelle

Randhäufigkeiten für X

H_{jk}	"niedrig" b_1	"mittel" b_2	"hoch" b_3	$H_{j\cdot}$
a_1 "gut"	0	1	3	0+1+3 = 4
a_2 "schlecht"	2	4	0	2+4+0 = 6
$H_{\cdot k}$	0+2 = 2	1+4 = 5	3+0 = 3	10

Randhäufigkeiten für Y

Relative Randhäufigkeit für X

h_{jk}	"niedrig" b_1	"mittel" b_2	"hoch" b_3	$h_{j\cdot}$
a_1 "gut"	0	0,1	0,3	0,4
a_2 "schlecht"	0,2	0,4	0	0,6
$h_{\cdot k}$	0,2	0,5	0,3	1

relative Randhäufigkeit für Y

Beispiel 1.9.2. *Kontingenztafel: Firmenkunden*

- *Grundgesamtheit* Ω*: Firmenkunden einer Bank*
- *Merkmal* X*: Branche mit den Ausprägungen* 1 *(Versicherungen),* 2 *(Automobil),* 3 *(Bau)*
- *Merkmal* Y*: Bonität mit Ausprägungen* 1 *(Rating* A*),* 2 *(*B*),* 3 *(*C*),* 4 *(*D*)*
- *Kontingenztafel der absoluten Häufigkeiten:*

		A	B	C	D	$H_{X\cdot}$
H_{XY}	$Y=1$	2	3	4	Σ	
V $X=1$	24	6	2	0	32	
A 2	8	30	5	1	44	
B 3	0	4	16	4	24	
Σ	32	40	23	5	100	

Randhäufigkeiten für X

Randhäufigkeiten für Y

- *Randverteilungen:*

$$\mathbf{h}_X = \begin{bmatrix} \overset{V}{1} & \overset{A}{2} & \overset{B}{3} \\ 0{,}32 & 0{,}44 & 0{,}24 \end{bmatrix} \quad \text{und} \quad \mathbf{h}_Y = \begin{bmatrix} \overset{A}{1} & \overset{B}{2} & \overset{C}{3} & \overset{D}{4} \\ 0{,}32 & 0{,}4 & 0{,}23 & 0{,}05 \end{bmatrix}$$

- $H_{3,1} = 0$*: kein Bau-Firmenkunde hat das Rating* A
- $h_{2,3} = 0{,}05$*: nur* 5% *der Firmenkunden sind Automobilkunden mit Rating* C

$0{,}05 = \frac{5}{100} = \frac{H_{2,3}}{n} =$

- $H_{1\cdot} = 32$*: 32 Firmenkunden sind aus der Versicherungsbranche*
- $h_{\cdot 4} = 0{,}05$*:* 5% *der Firmenkunden haben das schlechteste Rating* D

$0{,}05 = \frac{5}{100} = \frac{H_{\cdot 4}}{n} =$

- $\mathbf{h}_X(2) = h_{2\cdot} = 0{,}44$*: die relative Häufigkeit des Merkmals* X *mit der Ausprägung* 2 *ist* 44%*; oder:* 44% *der Firmenkunden sind aus der Automobilbranche*
- $\frac{h_{2,3}}{h_{2\cdot}} = \frac{0{,}05}{0{,}44} = 0{,}11$*:* 11% *der Automobil-Firmenkunden haben Rating* C

Graphische Darstellung als Säulendiagramm

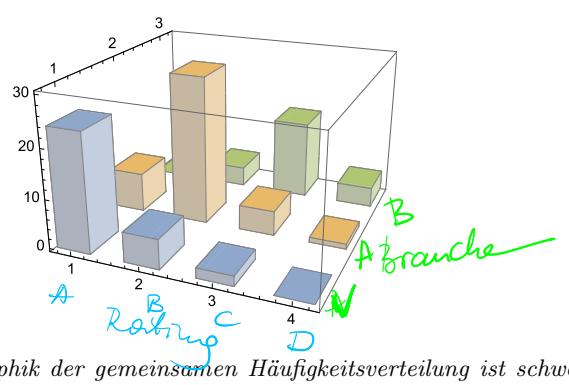

- **Beachte:** *Die Graphik der gemeinsamen Häufigkeitsverteilung ist schwer zu interpretieren, wenn die Anzahl der Ausprägungen bzw. Klassen groß ist.*

1.9.2 Bedingte Häufigkeiten

- Absolute oder relative Häufigkeiten zeigen nicht *direkt* einen Zusammenhang zwischen zwei Merkmalen auf.
- **Bedingte Häufigkeiten** sind Häufigkeiten eines Merkmals, wenn die Ausprägung des anderen Merkmals fixiert ist (d. h. quasi bekannt ist).
- Wie ist die Umsatzverteilung bei Aussentemperaturen von über 20 Grad?

Umsatzklassen

Temperatur-Klassen

	$U \in [10;20)$	$[20;30)$	$[30;40)$	$\sum$
$T \in [9;15)$	20	10	5	35
$[15;20)$	10	25	5	40
$[20;25)$	0	5	20	25
$\sum$	30	40	30	100

nicht mehr relevant

Es sei $\mathbf{h}_{XY}$ die gemeinsame Häufigkeitsverteilung der Merkmale X und Y.
Die **relative bedingte Häufigkeit** von $X = a_j$ gegeben $Y = b_k$ ist

gemeinsame Häufigkeit von $X = a_j$ und $Y = b_k$

$$h_{j|k} = h(X = a_j | Y = b_k) = \frac{h_{jk}}{h_{\cdot k}}, \quad \text{ebenso } h_{j|k} = \frac{H_{jk}}{H_{\cdot k}}.$$

Bedingung / "unter Bedingung"

Randhäufigkeit der Bedingung ($Y = b_k$)

Die **relative bedingte Häufigkeit** von $Y = b_k$ gegeben $X = a_j$ ist

$$h_{k|j} = h(Y = b_k | X = a_j) = \frac{h_{jk}}{h_{j\cdot}}, \quad \text{ebenso } h_{k|j} = \frac{H_{jk}}{H_{j\cdot}}.$$

Die **bedingte Häufigkeitsverteilung** von X gegeben $Y = b_k$ ist

für alle j:

$$\mathbf{h}_{X|Y=b_k} = \begin{pmatrix} h_{1|k} & \cdots & h_{J|k} \end{pmatrix}.$$

Die **bedingte Häufigkeitsverteilung** von Y gegeben $X = a_j$ ist

$$\mathbf{h}_{Y|X=a_j} = \begin{pmatrix} h_{1|j} & \cdots & h_{K|j} \end{pmatrix}.$$

für alle k:

Beispiel 1.9.3. *Rating*

- *Gegeben: Merkmale X und Y notleidender Firmenkunden einer Bank:*

  X = *Rating zum Periodenanfang mit den Ausprägungen*
  A = *schwach*, B = *mittel*, C = *stark notleidend*

  Y = *Situation zum Periodenende mit den Ausprägungen*
  D = *Totalausfall*, D^c = *kein Totalausfall*

  Ausfall
  kein Ausfall

- *Häufigkeitsverteilung:*

  gemeinsame rel. Häufigkeiten
  Situation am Ende

$\mathbf{h}_{XY}$	$Y = D$	$Y = D^c$	$\mathbf{h}_X$
$X = A$	0,05	0,45	0,5
B	0,04	0,16	0,2
C	0,21	0,09	0,3
$\mathbf{h}_Y$	0,3	0,7	1

Randhäufigkeiten für X

Rating

Randhäufigkeiten für Y

Berechnungen und Interpretationen

Wie häufig wurde das Rating A den Kunden vergeben, die am Ende ausgefallen sind

$$h_{A|D} = h(X = A|Y = D) = \frac{h_{AD}}{h_{.D}} = \frac{0{,}05}{0{,}3} = 0{,}1667$$

Interpretation: $h_{A|D} = 0{,}1667$ *heißt, dass von den am Periodenende ausgefallenen Firmenkunden anfangs* 16,67% *schwach notleidend waren.*

Wie wahrscheinlich ist es dass der Kunden mit Rating A am Ende doch ausfällt?

$$h_{D|A} = h(Y = D|X = A) = \frac{h_{AD}}{h_{A.}} = \frac{0{,}05}{0{,}5} = 0{,}1$$

Interpretation: $h_{D|A} = 0{,}1$ *heißt, dass von den anfangs schwach notleidenden Firmenkunden am Ende der Periode* 10% *ausgefallen sind.*

  – *Beachte:* $h_{AD} = 0{,}05$ *heißt, dass* 5% *der Firmenkunden anfangs nur schwach notleidend waren* ***und*** *dann schließlich doch ausgefallen sind.*

- *Bedingte Häufigkeitsverteilung von X gegeben $Y = D^c$:*

$$\mathbf{h}_{X|Y=D^c} = \begin{pmatrix} h_{A|D^c} & h_{B|D^c} & h_{C|D^c} \end{pmatrix} =$$

- *Bedingte Häufigkeitsveteilung von Y gegeben $X = C$:*

$$\mathbf{h}_{Y|X=C} = \begin{pmatrix} h_{D|C} & h_{D^c|C} \end{pmatrix} =$$