– Haben festgestellt, ob zwei Merkmale X, Y im Zusammenhang zueinander stehen → abhängig → unabhängig

– Brauche Kennzahlen um die Stärke des Zusammenhangs zu beurteilen.

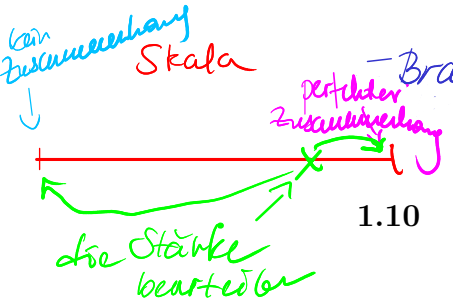

1.10 Zusammenhangskennzahlen bei zwei Merkmalen

Beispiel 1.10.1. *Kundenaufkommen und Wetter* *Hypothese: Ihr Umsatz ist wetterabhängig.*

Ihre Chefin braucht dennoch datenbasierte Evidenz. Sie haben folgende Daten vorliegen. Wie gehen Sie vor?

Tag	*Temp*	*Umsatz/Kd*	$K_{j,Temp}$	$K_{l,Ums}$
1	20.40	29.21	[20,25)	[20,30)
2	16.40	23.96	[15,19)	[20,30)
3	22.90	32.47	[20,25)	[30,40)
4	21.20	30.19	[20,25)	[30,40)
5	16.40	29.11	[15,20)	[20,30)
6	9.40	15.47	[9,15)	[10,20)
7	13.10	24.25	[9,15)	[20,30)
8	17.40	29.84	[15,20)	[20,30)
9	10.60	14.57	[9,15)	[10,20)
10	22.90	32.09	[20,25)	[30,40)

- Ziel: Angabe von Maßen, die den Zusammenhang zwischen zwei Merkmalen X und Y beschreiben

- Die Kennzahlen sind abhängig
  - vom Skalentyp der Merkmale X und Y

    'rho'

    metrisch: **Empirischer Korrelationskoeffizient** ρ_{XY} → Korrelation

    ordinal: **Spearman's Rho** ρ^S_{XY} → Rangkorrelation

    nominal: **Quadratische Kontingenz** (Chi-Quadrat-Koeffizient (χ^2)) → normierte Version C / C^*
  - und von der Datenlage

    Stichprobe: $(x_1,y_1), (x_2,y_2), \ldots, (x_n,y_n)$

    Häufigkeitsverteilung: $\mathbf{h}_{XY}$ (relativ) bzw. $\mathbf{H}_{XY}$ (absolut)

1.10.1 Empirische Kovarianz, empirischer Korrelationskoeffizient bei gegebener Stichprobe

- Es sei $(x_1,y_1),\dots,(x_n,y_n)$ eine Stichprobe der metrisch skalierten Merkmale X und Y.

Die **empirische Kovarianz** ist definiert als

"Sigma"

X-Abweichungen zu $\bar{x}$

$$\hat{\sigma}_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y}) = \frac{1}{n-1}\sum_{i=1}^{n}x_iy_i - \frac{n}{n-1}\bar{x}\bar{y}.$$

Y-Abweichung zu $\bar{y}$

Der **empirische Korrelationskoeffizient** (Bravais / Pearson) ist definiert durch

$$\hat{\rho}_{XY} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X\hat{\sigma}_Y} = \frac{\sum_{i=1}^{n}x_iy_i - n\bar{x}\bar{y}}{\sqrt{\sum_{i=1}^{n}x_i^2 - n\bar{x}^2}\cdot\sqrt{\sum_{i=1}^{n}y_i^2 - n\bar{y}^2}}.$$

- Interpretation: $\hat{\sigma}_{XY}$ und $\hat{\rho}_{XY}$ sind Maße für den **linearen Zusammenhang** zwischen zwei Merkmalen X und Y.
- Die Einheit der Kovarianz entspricht dem Produkt der Einheiten der zugrunde liegenden Merkmale; die Höhe der Kovarianz kann schwer zu interpretieren sein.

~~kein lin Zusam~~ $\hat{\rho}_{XY}=0$

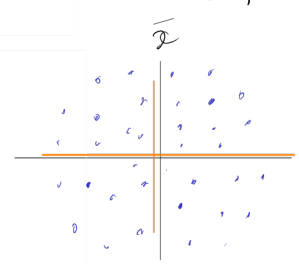

Graphische Darstellung: Scatterplot (Streudiagramm)

Die Darstellung der Stichprobenpaare $(x_1,y_1),\dots,(x_n,y_n)$ als Punkte in einem x-y-Koordinatensystem heißt **Scatterplot**.

neg. lin. Zusammenhang

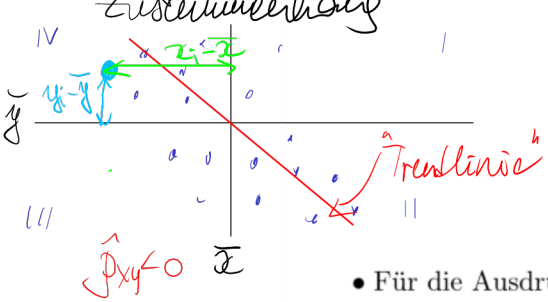

- Beispiel:

pos. lineare Zusammenhang

"Trendlinie"

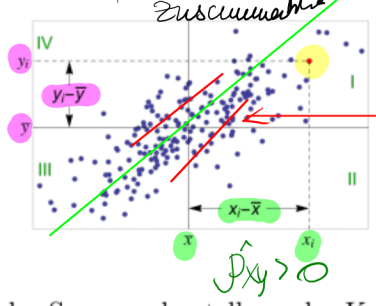

Stärke des Zusammenhangs (wie "dicht" die Punkte an der Linie sind)

$\hat{\rho}_{XY}>0$

- Für die Ausdrücke in der Summendarstellung der Kovarianz gilt:

$$(x_i-\bar{x})(y_i-\bar{y}) \begin{cases} >0, & \text{falls } (x_i,y_i)\in I \text{ oder } III \text{ (gemeinsam positiv oder negativ)} \\ <0, & \text{falls } (x_i,y_i)\in II \text{ oder } IV \text{ (verschiedene Vorzeichen)} \end{cases}$$

perfekter negativer linearer Zusammenhang

kein linearer Zusammenhang

perfekter positiver linearer Zusammenhang

Eigenschaften des empirischen Korrelationskoeffizienten:

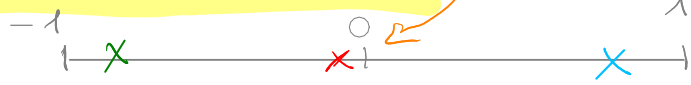

- $-1 \leq \hat{\rho}_{XY} \leq 1$
- $\hat{\rho}_{XY} > 0$: Positiver linearer Zusammenhang; die Werte (x_i, y_i) liegen tendenziell auf oder in der Nähe einer Geraden mit positivem Anstieg.
- $\hat{\rho}_{XY} < 0$: Negativer linearer Zusammenhang; die Werte (x_i, y_i) liegen tendenziell auf oder in der Nähe einer Geraden mit negativem Anstieg.
- $\hat{\rho}_{XY} = 0$: unkorreliert; kein linearer Zusammenhang.

Empirischer Korrelationskoeffizient: Interpretation

- Verschiedene Beispiele von Scatterplots zusammen mit den Korrelationskoeffizienten (Quelle: wikipedia.org):

$\hat{\rho}_{XY} =$

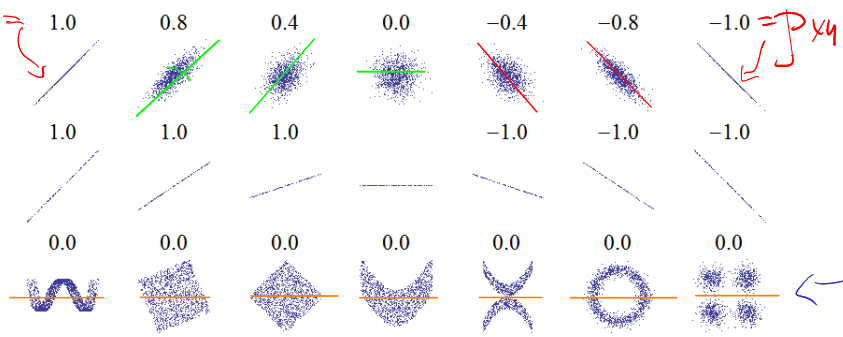

$= \hat{\rho}_{XY}$

nicht-lineare Zusammenhänge

$$\hat{\sigma}_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}\underbrace{(x_i-\bar{x})}_{\text{X-Abweichungen zu } \bar{x}}\underbrace{(y_i-\bar{y})}_{\text{Y-Abweichungen zu } \bar{y}} = \boxed{\underbrace{\frac{1}{n-1}\sum_{i=1}^{n} x_i y_i}_{\mathrm{I}} - \underbrace{\frac{n}{n-1}\bar{x}\bar{y}}_{\mathrm{II}}}$$

$$\hat{\rho}_{XY} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X \hat{\sigma}_Y}$$

Beispiel 1.10.2. *Korrelationskoeffizient*

- *Merkmale:*

$$X = \textit{Einkommen privater Haushalte}$$
$$Y = \textit{Konsum privater Haushalte}$$

- *Stichprobe:* $n = 6$ ~~6 Haushalte~~

Haushalte i	*Einkommen* x_i	*Konsum* y_i
1	3,2	2,8
2	3,7	3,1
3	3,5	2,8
4	4,1	3,7
5	4,4	3,5
6	3,9	3,3

- *Berechnen Sie den empirischen Korrelationskoeffizienten* $\hat{\rho}_{XY}$.

- *Zwischenergebnisse:*
  - *Stichprobenmittel:* $\bar{x} = \frac{1}{6}(3{,}2 + 3{,}7 + \ldots + 3{,}9) = \underline{3{,}8}$

    $\bar{y} = \frac{1}{6}(2{,}8 + 3{,}1 + \ldots + 3{,}3) = \underline{3{,}2}$
  - *empirische Varianzen:* $\hat{\sigma}_X^2 = \frac{1}{6-1}(3{,}2^2 + 3{,}7^2 + \ldots + 3{,}9^2) - \frac{6}{6-1}\cdot(3{,}8)^2 = \underline{0{,}1840}$

    $\hat{\sigma}_Y^2 = \frac{1}{6-1}(2{,}8^2 + 3{,}1^2 + \ldots + 3{,}3^2) - \frac{6}{6-1}(3{,}2)^2 = \underline{0{,}1360}$
  - *empirische Kovarianz:*

$$\hat{\sigma}_{XY} = \overbrace{\frac{1}{6-1}\cdot(3{,}2\cdot 2{,}8 + 3{,}7\cdot 3{,}1 + 3{,}5\cdot 2{,}8 + 4{,}1\cdot 3{,}7 + 4{,}4\cdot 3{,}5 + 3{,}9\cdot 3{,}3)}^{\mathrm{I}} - \overbrace{\frac{6}{6-1}\cdot 3{,}8\cdot 3{,}2}^{\mathrm{II}} = \underline{0{,}1420}$$

$\hat{\sigma}_{XY} > 0$, d.h. ein pos. lin. Zusammenhang ist vorhanden

- *Damit berechnet sich der Korrelationskoeffizient zu:*

$$\hat{\rho}_{XY} = \frac{0{,}1420}{\sqrt{0{,}1840}\cdot\sqrt{0{,}1360}} = 0{,}8977$$

- *Einkommen und Konsum sind also deutlich positiv korreliert.*

Stark ausgeprägter lin. Zhg.

Aufgabe 1.10.3. *Korrelationskoeffizient*

- *Merkmale:*[1]

$$X = \text{Änderung } \underline{\text{6-Monats}} \text{ EURIBOR (in bp)}$$
$$Y = \text{Änderung } \underline{\text{10-Jahres}} \text{ Swapsatz (in bp)}$$

Zinssatz	*Veränderung* x_i
3,90	
4,02	12
3,98	− 4
4,08	10
4,16	8
4,04	−12

Zinssatz	*Veränderung* y_i
5,75	
5,78	3
5,79	1
5,81	2
5,83	2
5,79	−4

$n=5$

- *Berechnen Sie den empirischen Korrelationskoeffizienten.*

Hinweis: $\bar{x} = 2{,}8$ $\quad \hat{\sigma}_x^2 = 107{,}2$
$\bar{y} = 0{,}8$ $\quad \hat{\sigma}_y^2 = 7{,}7$

$$\sigma_{xy} = \frac{1}{5-1}\left(12\cdot 3 + (-4)\cdot 1 + 10\cdot 2 + 8\cdot 2 + (-12)(-4)\right) - \frac{5}{5-1}\cdot 2{,}8\cdot 0{,}8 = \underline{26{,}2}$$

$$\hat{\rho}_{xy} = \frac{26{,}2}{\sqrt{107{,}2}\cdot\sqrt{7{,}7}} = \underline{0{,}9119}$$

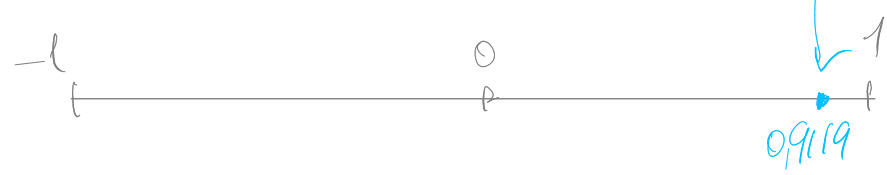

starke pos Korrelation

[1] bp = Basispunkt = 0,01%

Kovarianz und Korrelation bei gegebener Häufigkeitsverteilung*

- Es seien $\mathbf{H}_{XY}$ / $\mathbf{h}_{XY}$ die gemeinsamen Häufigkeiten der Stichprobe $(x_1, y_1), \dots, (x_n, y_n)$.

  Die **empirische Kovarianz** ist gegeben durch

$$\hat{\sigma}_{XY} = \frac{1}{n-1} \sum_{j=1}^{J} \sum_{k=1}^{K} (a_j - \bar{x})(b_k - \bar{y}) H_{jk} = \frac{1}{n-1} \sum_{j=1}^{J} \sum_{k=1}^{K} a_j b_k H_{jk} - \frac{n}{n-1} \bar{x}\,\bar{y}$$

$$= \frac{n}{n-1} \sum_{j=1}^{J} \sum_{k=1}^{K} a_j b_k h_{jk} - \frac{n}{n-1} \bar{x}\,\bar{y}.$$

Der **empirische Korrelationskoeffizient** ist gegeben durch

$$\hat{\rho}_{XY} = \frac{\sum_{j=1}^{J} \sum_{k=1}^{K} a_j b_k h_{jk} - \bar{x} \cdot \bar{y}}{\sqrt{\sum_{j=1}^{J} a_j^2 h_{j\cdot} - \bar{x}^2} \sqrt{\sum_{k=1}^{K} b_k^2 h_{\cdot k} - \bar{y}^2}} = \frac{\sum_{j=1}^{J} \sum_{k=1}^{K} a_j b_k H_{jk} - n\,\bar{x} \cdot \bar{y}}{\sqrt{\sum_{j=1}^{J} a_j^2 H_{j\cdot} - n\,\bar{x}^2} \sqrt{\sum_{k=1}^{K} b_k^2 H_{\cdot k} - n\,\bar{y}^2}}. = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X \hat{\sigma}_Y}$$

Beispiel 1.10.4. *Korrelation bei Häufigkeitsverteilung**

- *Merkmale:* X = *Wochenrendite des Anlagefonds* A; Y = *Wochenrendite des Anlagefonds* B

- *Klassenmitten:*

  $a_1 = -2\%, \quad a_2 = 0\%, \quad a_3 = 2\%$ *(Fonds A)*

  $b_1 = -4\%, \quad b_2 = -2\%, \quad b_3 = 0\%, \quad b_4 = 2\%, \quad b_5 = 4\%$ *(Fonds B)*

- *Kontingenztafel:*

		b_1 (−4)	b_2 (−2)	b_3 (0)	b_4 (2)	b_5 (4)	$\sum$
−2	a_1	0,0000	0,0513	0,0577	0,0449	0,0128	0,1667
0	a_2	0,0385	0,0962	0,2308	0,1474	0,0321	0,5449
2	a_3	0,0192	0,0321	0,1090	0,0577	0,0705	0,2885
	$\sum$	0,0577	0,1795	0,3974	0,2500	0,1154	1,0000

- *Berechnung der empirischen Erwartungswerte:*

  Randhäufigkeiten

$$\hat{\mu}_X = -2 \cdot 0{,}1667 \cancel{+ 0 \cdot 0{,}5449} + 2 \cdot 0{,}2885 = 0{,}2436\%$$

$$\hat{\mu}_Y = -4 \cdot 0{,}0577 - 2 \cdot 0{,}1795 + 2 \cdot 0{,}2500 + 4 \cdot 0{,}1154 = 0{,}3718\%$$

- *Berechnung der empirischen Varianzen und Kovarianz:*

mu_X	0,2436
mu_Y	0,3716
sigma^2_X	1,77925156
sigma^2_Y	4,39385196
Kovarianz	0,34896792
Korrelation	0,12480849

- *Berechnung des Korrelationskoeffizienten:* $\hat{\rho}_{XY} =$

1.10.2 Rangkorrelation

- Wenn das Merkmal mindestens ordinal skaliert ist, kann ein empirischer Korrelationskoeffizient aus den **Rängen** der Stichprobenwerte berechnet werden.

- Es sei $x_1, \dots, x_n$ eine Stichprobe eines mindestens ordinal skalierten Merkmals.

- Es bezeichne $x_{[1]} \leq x_{[2]} \leq \cdots \leq x_{[n]}$ die geordnete Stichprobe.

Ränge

- Falls alle Werte der Stichprobe verschieden sind: Ist $x_i = x_{[k]}$, so ist der **Rang** von x_i definiert als $R(x_i) = k$.

- Falls einige Werte mehrfach auftreten, so ist der **Rang** definiert als das arithmetische Mittel der möglichen Ränge.

12425 ← Stichprobe
12245 ← geordnete Stichprobe
1 2 3 4 5
2,5 2,5

Beispiel 1.10.5. *Lateinisches Alphabet*

- *Zum Merkmal X = Lateinisches Alphabet mit der geordneten Ausprägungsmenge $A_X = \{a \leq b \leq \cdots \leq z\}$ liegen die Stichproben vor:*

  1 2 3 4 5 6 7 8 9 10

  1. x_i : *q, m, a, d, w, o, k, e, s, t (paarweise verschieden)*

     1 2 3 4 5 6 7 8 9 10

     – *Ordnen:* $x_{[i]}$: *a, d, e, k, m, o, q, s, t, w*

     – *Rangzahlen:* $R(x_7) = R(k) = 4$, *da* $x_{[4]} = k$,
     $R(x_6) = R(o) = 6$, *da* $x_{[6]} = o$.

  2. x_i : *d, s, a, d, k, s, k, e, s, t (nicht paarweise verschieden)*

     2 3 5 6 7 8 9

     – *Ordnen:* $x_{[i]}$: *a, d, d, e, k, k, s, s, s, t*

     – *Rangzahlen:* $R(x_1) = R(x_4) = R(d) = \frac{1}{2}(2+3) = 2{,}5$, *da* $x_{[2]} = x_{[3]} = d$
     $R(x_2) = R(x_6) = R(x_9) = R(s) = \frac{1}{3}(7+8+9) = 8$, *da* $x_{[7]} = x_{[8]} = x_{[9]} = s$

Rangkorrelation /Spearman's Rho

- Es sei $(x_1,y_1),\dots,(x_n,y_n)$ eine Stichprobe ordinal oder metrisch skalierter Merkmale X und Y.
- Es seien $R(x_1),\dots,R(x_n)$ und $R(y_1),\dots,R(y_n)$ die zugehörigen Ränge.

Der **Korrelationskoeffizient von Spearman** / **Spearman's Rho** geht auf Pearson's Korrelationskoeffizienten zurück und ersetzt dort die Stichprobenwerte durch die entsprechenden Ränge:

$$\hat{\rho}^S_{XY} = \frac{\sum_{i=1}^n R(x_i)R(y_i) - n\cdot\overline{R(x)}\cdot\overline{R(y)}}{\sqrt{\sum_{i=1}^n R(x_i)^2 - n\cdot\overline{R(x)}^2}\sqrt{\sum_{i=1}^n R(y_i)^2 - n\cdot\overline{R(y)}^2}}.$$

Spezialfall: Sind sowohl die Stichprobenwerte $x_1,\dots,x_n$ als auch $y_1,\dots,y_n$ verschieden, so gilt

Annäherung $\longrightarrow$ $$\boxed{\hat{\rho}^S_{XY} = 1 - \frac{6\sum_{i=1}^n d_i^2}{n(n^2-1)}} \quad \text{mit } d_i = R(x_i) - R(y_i).$$

Beispiel 1.10.6. *Rangkorrelation*

- *Vergleich zweier Ratingverfahren (Firmenkunden)*
- *Bonitätsklassen:* AAA, AA, A, BBB, BB, B, CCC, CC, C, D

Allgemeine Ordnung

$n=10$

	Firmenkunde	1	2	3	4	5	6	7	8	9	10
Ratingverfahren X	x_i *mit (1)*	B	A	CC	BB	CC	D	C	A	AA	BBB
	$R(x_i)$	6	~~3~~ 2,5	~~4~~ 7,5	5	~~8~~ 7,5	10	9	~~2~~ 2,5	1	4
Ratingverfahren Y	y_i *mit (2)*	BB	A	BBB	B	CC	CC	CCC	AA	A	BB
	$R(y_i)$	~~5~~ 5,5	~~2~~ 2,5	4	7	~~9~~ 9,5	~~10~~ 9,5	8	1	~~3~~ 2,5	~~6~~ 5,5
	d_i	0,5	0	3,5	-2	2	0,5	1	1,5	-1,5	-1,5

- $\overline{R(x)} = \overline{R(y)} = 5{,}5$ *und*

$$\underline{0{,}8246} = \hat{\rho}^S_{XY} = \frac{6\cdot 5{,}5 + 2{,}5\cdot 2{,}5 + 7{,}5\cdot 4{,}5 + \dots + 4\cdot 5{,}5 - 10\cdot 5{,}5\cdot 5{,}5}{\sqrt{6^2+2{,}5^2+\dots+4^2 - 10\cdot 5{,}5^2}\cdot\sqrt{5{,}5^2+2{,}5^2+\dots+5{,}5^2 - 10\cdot 5{,}5}}$$

- $$\hat{\rho}^S_{XY} \approx 1 - \frac{6\cdot(0{,}5^2+0^2+3{,}5^2+\dots+(-1{,}5)^2)}{10(10^2-1)} = \underline{0{,}8272}$$

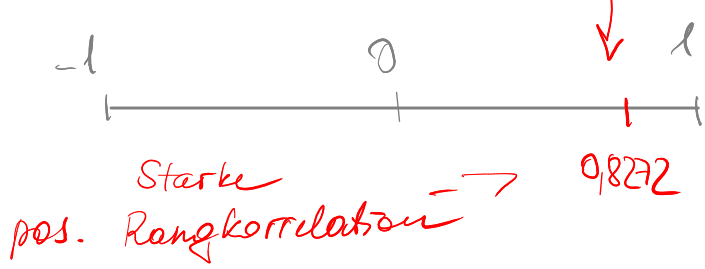

Starke pos. Rangkorrelation $\longrightarrow$