Zusammenhangskennzahlen X, Y

Skala	Kennzahl
metrisch beide	Korrelation / Korrelationskoeffizient $\hat{\rho}_{XY}$ Berechnung über die Kovarianz $\hat{\sigma}_{XY}$
ordinal metrisch + ordinal oder ordinal + ordinal	Rangkorrelation / Spearman's Rho $\hat{\rho}^{S}_{XY}$ Korrelation der Ränge
nominal metrisch + nominal oder ordinal + nominal oder nominal + nominal	normierter Kontingenzkoeffizient C^* Berechnung über χ^2-Koeff. und C.

Unabhängigkeit

Perfekte Abhängigkeit

"Chi"

1.10.3 χ^2-Koeffizient, Kontingenzkoeffizient, normierter Kontingenzkoeffizient

- Falls Merkmale auf der nominalen Skala gemessen werden, so kann ein Maß des Zusammenhangs nicht auf Basis der Ausprägungen bestimmt werden.
- Stattdessen wird ein Maß aus den Häufigkeiten abgeleitet, das den Abstand zum Fall der Unabhängigkeit misst.
- Es sei $\mathbf{H}_{XY}$ die gemeinsame Häufigkeitsverteilung der Merkmale X und Y.
- Genau dann, wenn X und Y unabhängig sind, gilt $\frac{H_{jk}}{H_{.k}} = \frac{H_{j.}}{n}$ für alle j und k.

Unabhängigkeit:
$h_{jk} = h_{j.} \cdot h_{.k}$
$H_{jk} = \frac{H_{j.} \cdot H_{.k}}{n}$

Der χ^2-**Koeffizient** (Chi-Quadrat) ist definiert durch

$$\chi^2 = \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{\boxed{\left(H_{jk} - \frac{H_{j.}H_{.k}}{n}\right)^2}}{\frac{H_{j.}H_{.k}}{n}} = n \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{\boxed{(h_{jk} - h_{j.}h_{.k})^2}}{h_{j.}h_{.k}},$$

die beobachteten gemeinsamen Häufigkeiten

die gemeinsamen Häufigkeiten, die wir unter Unabhängigkeit von X,Y beobachten würden

die quadrierten Abweichungen von Unabhängigkeit

Kontingenztafel

	b_1	b_2	b_3
a_1			
a_2			

wobei $\frac{H_{j.}H_{.k}}{n}$ die sogenannten **Unabhängigkeitszahlen** bezeichnen.

- χ^2 misst die quadratische Abweichung von der Unabhängigkeit.

Kontingenzkoeffizient

- χ^2 ist abhängig von der Dimension der Kontingenztafel.
- Die folgenden zwei Maße sind unabhängig von der Umfang der Stichprobe.

Bsp.
$M = \min(3;2) = 2$
Spalten # Zeilen

Der **Kontingenzkoeffizient** ist definiert als

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}},$$

Anzahl Spalten
Anzahl Zeilen

und nimmt einen Wert $C \in \left[0, \sqrt{\frac{M-1}{M}}\right]$ mit $M = \min(J,K)$ an.

Der **normierte Kontingenzkoeffizient** ist gegeben durch

$$C^* = C / \sqrt{\frac{M-1}{M}}$$

und besitzt einen Wert $C^* \in [0,1]$.

$$\chi^2 = \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{\left(H_{jk} - \frac{H_{j.}H_{.k}}{n}\right)^2}{\frac{H_{j.}H_{.k}}{n}} = n \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{(h_{jk} - h_{j.}h_{.k})^2}{h_{j.}h_{.k}},$$

Beispiel 1.10.7. *Noten und Fitness*

- *Zur Grundgesamtheit der HWR-Studierenden liegt zu den Merkmalen*
  - A = *Fitnessgrad mit den Ausprägungen* s = *sportlich und* u = *unsportlich*
  - B = *Examensnote mit den Ausprägungen* e = *exzellent,* g = *gut und* a = *ausreichend*

  eine Stichprobe zum Umfang $n = 200$ *mit absoluter Häufigkeitsverteilung vor:*

Unabhängigkeit:
$h_{jk} = h_{j.} \cdot h_{k.}$
$H_{jk} = \frac{H_{j.} \cdot H_{.k}}{n}$

die gemeinsamen Häufigkeiten aus den Daten

Daten

H_{jk}	$b_1 = e$	$b_2 = g$	$b_3 = a$	$H_{j.}$
$a_1 = s$	14	72	34	120
$a_2 = u$	12	55	13	80
$H_{.k}$	26	127	47	200

Unabhängigkeit

$\frac{H_{j.} \cdot H_{.k}}{n}$	b_1	b_2	b_3
a_1	15,6	76,2	28,2
a_2	10,4	50,8	18,8

die Häufigkeiten unter dem Unabhängigkeitsszenario

$a_1 b_1$: $\frac{H_{1.} \cdot H_{.1}}{n} = \frac{120 \cdot 26}{200} = 15{,}6$

$a_1 b_2$: $\frac{H_{1.} \cdot H_{.2}}{n} = \frac{120 \cdot 127}{200} = 76{,}2$

$a_2 b_3$: $\frac{H_{2.} \cdot H_{.3}}{n} = \frac{80 \cdot 47}{200} = 18{,}8$

- *Damit berechnen wir:*

1) $$\chi^2 = \frac{(14-15{,}6)^2}{15{,}6} + \frac{(72-76{,}2)^2}{76{,}2} + \frac{(34-28{,}6)^2}{28{,}6} + \frac{(12-10{,}4)^2}{10{,}4} + \frac{(55-50{,}8)^2}{50{,}8} + \frac{(13-18{,}8)^2}{18{,}8} = \underline{3{,}9713}$$

2) $$C = \sqrt{\frac{\chi^2}{n+\chi^2}} = \sqrt{\frac{3{,}9713}{200+3{,}9713}} = \underline{0{,}1395}$$

3) $$C^* = C / \sqrt{\frac{M-1}{M}} = \frac{0{,}1395}{\sqrt{\frac{2-1}{2}}} = 0{,}1973$$

ist immer im Intervall $[0;1]$

$$\boxed{M = \min(J;K) = \min(3;2) = 2}$$

Unabhängigkeit → 0 — 0,1973 — 1 ←

geringe Abhängigkeit

100% Abhängigkeit

1.10.4 Fallstudie: Korrelation - Aktienrendite

- Für die Monatsrenditen einer Aktie y bzw. des Marktportfolios x werden in einem halben Jahr die folgenden Werte (in %) gemessen:

Monat i	Marktrendite x_i	Aktienrendite y_i	$R(x_i)$	$R(y_i)$
1	0,4	0,4	4	2
2	0,9	1,5	5	5
3	1,2	1,8	6	6
4	0,2	1,0	3	4
5	−0,4	−1,1	2	1
6	−0,5	0,6	1	3

(a) Bestimmen Sie den empir. Korrelationskoeffizienten und interpretieren Sie das Ergebnis.

(b) Bestimmen Sie den Rangkorrelationskoeffizienten (nach Spearman).

- Empirische Erwartungswerte:

$$\bar{x} = \frac{1}{6}(0{,}4 + \ldots - 0{,}5) = 0{,}3$$

$$\bar{y} = \frac{1}{6}(0{,}4 + \ldots + 0{,}6) = 0{,}7$$

- Empirische Varianzen:

$$\hat{\sigma}_X^2 = \frac{1}{6-1}\left(0{,}4^2 + \ldots + (-0{,}5)^2\right) - \frac{6}{6-1} \cdot 0{,}3^2 = 0{,}464$$

$$\hat{\sigma}_Y^2 = \frac{1}{6-1}\left(0{,}4^2 + \ldots + 0{,}6^2\right) - \frac{6}{6-1} \cdot 0{,}7^2 = 1{,}056$$

ausgeprägter pos. lin Zhg

- Empirische Kovarianz:

$$\hat{\sigma}_{XY} = \frac{1}{6-1} \cdot (0{,}4 \cdot 0{,}4 + 0{,}9 \cdot 1{,}5 + 1{,}2 \cdot 1{,}8 + 0{,}2 \cdot 1 + (-0{,}4)(-1{,}1) + (-0{,}5) \cdot 0{,}6 - \frac{6}{6-1} \cdot 0{,}3 \cdot 0{,}7 = 0{,}55$$

ein pos. lin. Zhg

0,7857

(a) Empirischer Korrelationskoeffizient: $\hat{\rho}_{XY} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X \cdot \hat{\sigma}_Y} = \frac{0{,}55}{\sqrt{0{,}464} \cdot \sqrt{1{,}056}} = \underline{0{,}7857}$

(b)

i	$R(x_i)$	$R(y_i)$	d_i^2
1	4	2	4
2	5	5	0
3	6	6	0
4	3	4	1
5	2	1	1
6	1	3	4
		Σ: =	10

$$\hat{\rho}_{XY}^S = 1 - \frac{6 \sum d_i^2}{n(n^2-1)} = 1 - \frac{6 \cdot 10}{6(6^2-1)} = \underline{0{,}7143}$$

ausgeprägter pos lin Zhg

0,7143

etwas kleiner als die normale Korrelation

$$\boxed{\hat{\rho}_{XY}^S = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2-1)}} \quad \text{mit } d_i = R(x_i) - R(y_i).$$

Tag	Wetterbedingungen (X)	Umsatzniveau (Y)
1	gut	mittel
2	schlecht	mittel
3	gut	hoch
4	gut	hoch
5	schlecht	mittel
6	schlecht	niedrig
7	schlecht	mittel
8	schlecht	mittel
9	schlecht	niedrig
10	gut	hoch

Kontingenztabelle (Daten)

Randhäufigkeiten für X

H_{jk}	"niedrig" b_1	"mittel" b_2	"hoch" b_3	$H_{j\cdot}$
a_1 "gut"	0	1	3	4
a_2 "Schlecht"	2	4	0	6
$H_{\cdot k}$	2	5	3	10

Randhäufigkeiten für Y

Kontingenztabelle (Unabhängigkeit)

$\frac{H_{j\cdot} \cdot H_{\cdot k}}{n}$	"niedrig" b_1	"mittel" b_2	"hoch" b_3	$H_{j\cdot}$
a_1 "gut"	$(2\cdot 4):10 = 0{,}8$	$(5\cdot 4):10 = 2$	$(3\cdot 4):10 = 1{,}2$	4
a_2 "Schlecht"	$(2\cdot 6):10 = 1{,}2$	$(5\cdot 6):10 = 3$	$(3\cdot 6):10 = 1{,}8$	6
$H_{\cdot k}$	2	5	3	10

$n = 10$

$$\chi^2 = \frac{(0-0{,}8)^2}{0{,}8} + \frac{(1-2)^2}{2} + \dots + \frac{(0-1{,}8)^2}{1{,}8} = 6{,}6667$$

$$C = \sqrt{\frac{6{,}6667}{10+6{,}6667}} = 0{,}6325$$
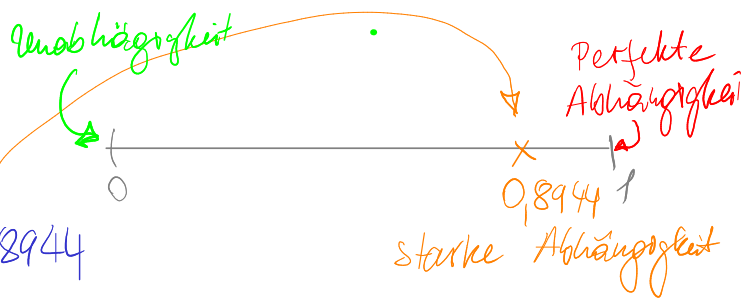
$$C^* = \frac{C}{\sqrt{\frac{M-1}{M}}} = \frac{0{,}6325}{\sqrt{\frac{2-1}{2}}} = 0{,}8944$$