1.11 Regressionsrechnung

Korrelationsrechnung vs. Regressionsrechnung

Bei der Frage nach dem linearen Zusammenhang zweier Merkmale unterscheiden wir die folgenden beiden Aspekte:

perfekte neg. Korrelation

perfekte pos. Korrelation

-1 0 1

kein lin. Zug

- Korrelationsrechnung:
  - Bestimmt die **Stärke** des linearen Zusammenhangs zwischen zwei Merkmalen X und Y
  - kurz: ob ein linearer Zusammenhang besteht
- Regressionsrechnung:
  - Bestimmt die **Form** $Y = a + bX$ des linearen Zusammenhangs zwischen X und Y
  - kurz: welcher lineare Zusammenhang besteht

? ?

wie berechne den Umsatz, wenn eine Vorhersage für Temperatur verfügbar ist?

Die Regressionsrechnung kann auf nicht-lineare Zusammenhänge erweitert werden. Die Rolle des Korrelationskoeffizienten übernimmt dann das **Bestimmtheitsmaß**, das angibt, wie viel des zufälligen Auftretens von X und Y der Regressionsansatz $Y = f(X)$ erklärt.

Wir haben einen linearen Zusammenhang zw. dem Umsatz U und der durchschnittlichen Temperatur T empirisch festgestellt.
Können wir den erwarteten Umsatz für ein gegebenes Temperaturniveau nun berechnen?

Vorhersage

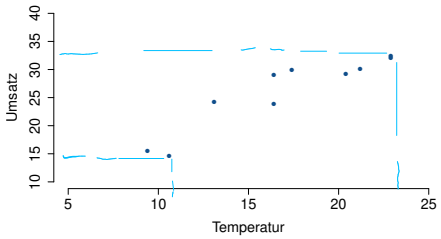

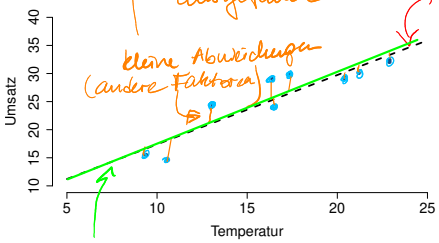

Bspw. Schulstunde ausgefallen

kleine Abweichungen (andere Faktoren)

kaum eine Linie hier vorstellen, die die Daten gut approximiert (annähert)

Brauche eine Formel für diese Linie!

Regression

1.11.1 Lineare Regression

- Es sei $(x_1, y_1), \dots, (x_n, y_n)$ eine Stichprobe von metrisch skalierten Merkmalen X und Y.

- Wir unterstellen einen linearen funktionalen Zusammenhang zwischen Y und X:

$$y = \boxed{a + bx}, \quad a, b \in \mathbb{R},$$

mit

  - $\boxed{a + bx}$ heißt **Regressionsgerade**;
  - y heißt **Regressand** oder **erklärte Variable**; was wir vorhersagen wollen
  - x heißt **Regressor** oder **erklärende Variable**. womit wir vorhersagen wollen (was wir im Voraus wissen)

- In der Praxis ist der Zusammenhang in der Regel nicht perfekt linear. Daher schreibt man

$$\begin{aligned} y_1 &= a + bx_1 + \varepsilon_1 \\ &\vdots \\ y_n &= a + bx_n + \varepsilon_n, \end{aligned}$$

"Epsilon"

Fehlerterme (unbeobachtbare/unvorhersehbare Einflüsse)

wobei $\varepsilon_1, \dots, \varepsilon_n$ die sogenannten **Fehlerterme** oder **Residuen** sind.

Berechnung der Regressionskoeffizienten

- Die Regressionskoeffizienten, der **Interzept** a und die **Steigung** der Regressionsgerade b, sind zu bestimmen.

- Die **Methode der kleinsten Quadrate (MkQ)** bestimmt a und b durch Minimierung der Summe der quadrierten Fehlerterme:

$$\min_{a,b} \sum_{i=1}^{n} \varepsilon_i^2 = \min_{a,b} \sum_{i=1}^{n} (\overbrace{y_i - (a + bx_i)}^{\varepsilon_i})^2.$$

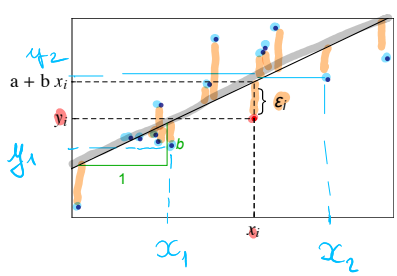

1.11.2 MkQ-Schätzer

Es sei $(x_1,y_1), \dots, (x_n,y_n)$ eine Stichprobe der Merkmale X und Y. Das System der linearen Gleichungen

$$y_i = a + bx_i + \varepsilon_i, \quad i = 1, \dots, n$$

heißt **lineare Regression** mit **Interzept** a, **Steigung** b und **Fehlertermen (Residuen)** $\varepsilon_1, \dots, \varepsilon_n$.

Die **Kleinste-Quadrate-Schätzer** für a und b sind gegeben durch

Aus den Daten geschätzt:

$\boxed{y = \hat{a} + \hat{b} \cdot x}$

$$\hat{a} = \overline{y} - \hat{b}\overline{x},$$

$$\boxed{\hat{b} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X^2}} = \hat{\rho}_{XY} \cdot \frac{\hat{\sigma}_Y}{\hat{\sigma}_X} = \frac{\sum_{i=1}^n x_i y_i - n\overline{x}\overline{y}}{\sum_{i=1}^n x_i^2 - n\overline{x}^2} = \frac{\sum_{i=1}^n (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^n (x_i - \overline{x})^2}.$$

1.11.3 Bestimmtheitsmaß R^2

- Das **Bestimmtheitsmaß** R^2 beschreibt den **Anteil** der Gesamtvarianz der Stichprobe $(y_1, \dots, y_n)$, der durch die Regressionsgerade erklärt wird.

- Wie „gut" ist die Formel?
- Wie hoch ist die Qualität der Vorhersage?

Im Fall der linearen Regression ist das **Bestimmtheitsmaß** R^2 definiert als

Qualität der Regression

$$\boxed{R^2} = 1 - \frac{\sum_{i=1}^n (\overbrace{a + bx_i - y_i}^{\varepsilon_i})^2}{\sum_{i=1}^n (y_i - \overline{y})^2}.$$

unerklärte Varianz

gesamte Varianz in y.

Hierbei gilt

$$\underbrace{0 \le R^2 \le 1}, \quad \text{und} \quad \boxed{R^2 = \hat{\rho}_{XY}^2.}$$

- $R^2 = 0$ entspricht dem Fall der Unkorreliertheit, und
- $R^2 = 1$ entspricht dem Fall perfekter linearer Korrelation zwischen den Merkmalen X und Y.

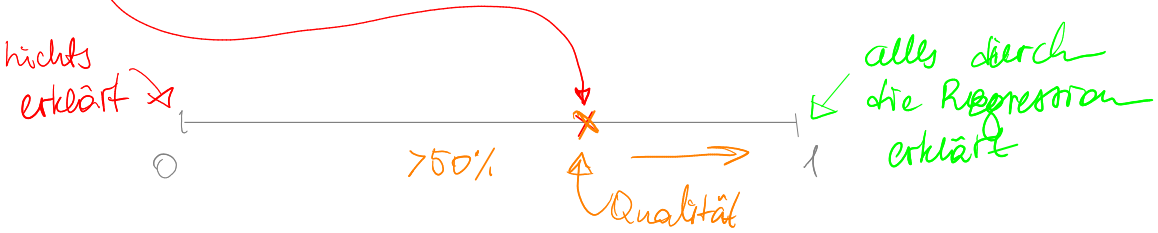

Beispiel 1.11.1. *Kundenaufkommen*

- *Merkmale:*
  - U = *Umsatz pro Kunde* ← erklärte Variable / abhängige Variable / Regressand
  - T = *durchschnittliche Temperatur* ← erklärende Variable / unabhängige Variable / Regressor

  (Daten aus 1.10.1, Seite 53)

- *Bestimme die Regressionsgerade* $\boxed{u = a + bt}$ ← Umsatz als lin. Funktion der Temperatur

- *Lösung:*
  - $\bar{u} = 26{,}115$; $\bar{t} = 17{,}07$; $\hat{\sigma}_T^2 = 23{,}73$, $\hat{\sigma}_{UT} = 29{,}282$, $\hat{\rho}_{UT} = 0{,}925$

Kleinste-Quadrate Schätzer

$$\hat{a} = \bar{y} - \hat{b}\bar{x},$$
$$\hat{b} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X^2}$$

  - $\hat{b} = \frac{29{,}282}{23{,}73} = 1{,}23$
  - $\hat{a} = \bar{u} - \hat{b} \cdot \bar{t} = 26{,}115 - 1{,}23 \cdot 17{,}07 = 5{,}12$

- *Umsatzfunktion:* $\boxed{u = 5{,}12 + 1{,}23t,}$ *für* $9 \le t \le 25$ ← geschätzte Regressionsgerade

$$\boxed{R^2 = \hat{\rho}_{XY}^2.}$$

- *Bestimmtheitsmaß:* $R^2 = \hat{\rho}_{UT}^2 = 0{,}925^2 = 0{,}856$ ← 85,6% der Varianz in den Umsätzen wurde durch die Regression auf die Temperatur erklärt

R^2:

0 — 0,856 — 1

Regressionsgerade:

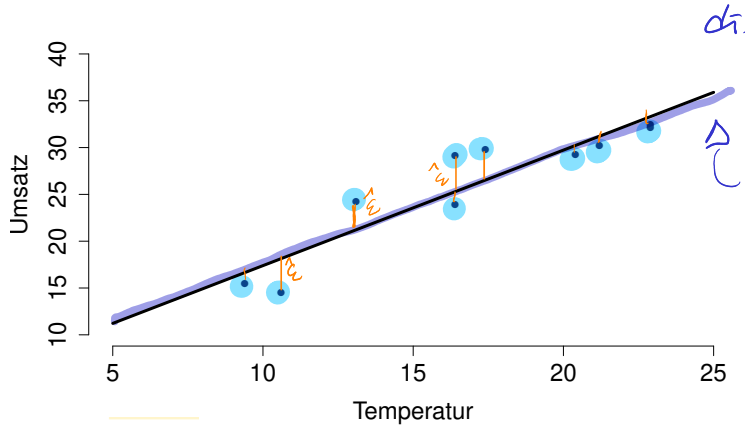

Regressionsgerade: $u(t) = 5{,}12 + 1{,}23t$

- Vorhersage

$t_0 = 8°$ (Temperaturvorhersage)

$u_0(t_0) = 5{,}12 + 1{,}23 \cdot 8 = 14{,}96$ ← Umsatzvorhersage (für heute)