$\ln(a \cdot b) = \ln(a) + \ln(b)$

$\ln(a^b) = b \ln(a)$

1.11.4 Nicht-lineare Regression

- Wenn der Zusammenhang nicht linear ist, wie etwa $v = \alpha \cdot \beta^u$:

$\ln(v) = \ln(\alpha \cdot \beta^u)$

$\ln(v) = \ln(\alpha) + \ln(\beta^u)$

$\ln(v) = \ln(\alpha) + u \ln(\beta)$

- $\rightarrow$ durch eine geeignete Transformation in einen linearen Zusammenhang überführen, z.B.durch das Logarithmieren: $\ln v = \ln \alpha + (\ln \beta) \cdot u$.

$y = a + b \cdot x$

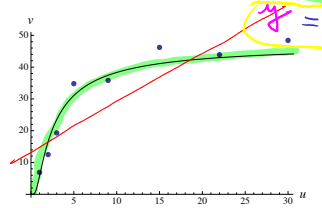

- Setze: $y = \ln v$, $a = \ln \alpha$, $b = \ln \beta$ und $x = u$ $\Rightarrow$ Die transformierte Funktion $y = a + bx$ ist eine Gerade mit den Koeffizienten a, b.
- Das weitere Vorgehen:
  - Transformiere entsprechend die Daten (u_i, v_i) der Stichprobe
  - Berechne die Regressionskoeffizienten a und b mit der MkQ
  - Transformiere rückwärts α und β aus a und b; hier $\hat{\alpha} = e^a$ und $\hat{\beta} = e^b$
  - Erhalte die geschätzte Funktionsgleichung; hier $v = \hat{\alpha} \cdot \hat{\beta}^u$

$\hat{a} = \ln \hat{\alpha} \rightarrow \hat{\alpha} = e^{\hat{a}}$

$\hat{b} = \ln \hat{\beta} \rightarrow \hat{\beta} = e^{\hat{b}}$

Nicht-lineare Regression (formal)

- Gegeben: Stichprobe $(u_1, v_1), \ldots, (u_n, v_n)$ der Merkmale U und V
- Annahme: $v = f(u)$ mit Parametern α und β in nicht-linearer Form
- Transformation:

$$T(v) = a + b\,g(u) \quad \text{bzw.} \quad y = a + b\,x \quad \text{(Linearisierung)}$$

- Dann:
  1. Stichprobe $(u_i, v_i) \rightarrow (x_i, y_i) = (g(u_i), T(v_i))$ für $i = 1, \ldots, n$
  2. Bestimme mittels Geradenregression $y = a + b\,x$ die Parameter a und b
  3. Berechne aus a und b die ursprünglichen Funktionsparameter α und β
  4. $v = f(u, \alpha, \beta)$ ist die gesuchte Regressionsfunktion

Beispiel 1.11.2. *Nichlineare Nachfrage*

- *Ökonometrischer Zusammenhang: Nachfrage v nach einem bestimmten Konsumgut in Abhängigkeit des Einkommens u*

- *Ansatz:*

$$\boxed{v = \alpha e^{\beta/u}}$$

- *Daten:*

i	u_i	v_i	$x_i = \frac{1}{u_i}$	$y_i = \ln(v_i)$
1	1	6,9	$\frac{1}{1} = 1$	$\ln(6{,}9) = 1{,}9315$
2	2	12,5	$\frac{1}{2} = 0{,}5$	$\ln(12{,}5) = 2{,}5257$
3	3	19,3	$\frac{1}{3} = 0{,}3333$	$\ln(19{,}3) = 2{,}9601$
4	5	34,8	$\frac{1}{5} = 0{,}2$	$\ln(34{,}8) = 3{,}5496$
5	9	35,8	$\frac{1}{9} = 0{,}1111$	$\ln(35{,}8) = 3{,}5778$
6	15	46,2	$\frac{1}{15} = 0{,}0667$	$\ln(46{,}2) = 3{,}833$
7	22	43,9	$\frac{1}{22} = 0{,}0455$	$\ln(43{,}9) = 3{,}7819$
8	30	48,4	$\frac{1}{30} = 0{,}0333$	$\ln(48{,}4) = 3{,}8795$

- *Transformation:*

$$\ln(v) = \ln(\alpha \cdot e^{\beta/u}) \to \ln(\alpha) + \ln(e^{\beta/u}) \to \ln(\alpha) + \underbrace{\frac{\beta}{u}}_{\beta \cdot \frac{1}{u}} \cdot \underbrace{\ln(e)}_{1}$$

$$\ln(\cdot) \quad \boxed{v = \alpha\, e^{\beta/u}} \quad \Rightarrow \quad \underbrace{\ln v}_{y} = \underbrace{\ln \alpha}_{a} + \underbrace{\beta}_{b} \cdot \underbrace{\frac{1}{u}}_{x} \quad \Longleftrightarrow \quad y = a + b\,x,$$

also: $y = \ln v$, $x = 1/u$, $a = \ln \alpha$, $b = \beta$

- *MkQ für die Parameter a und b ($\sum_{i=1}^n x_i y_i = 5{,}8453$, $\sum_{i=1}^n x_i = 2{,}2899$, $\sum_{i=1}^n y_i = 26{,}0393$ and $\sum_{i=1}^n x_i^2 = 1{,}4211$):*

$$\hat b = \frac{\hat\sigma_{XY}}{\hat\sigma_X^2} = \hat\rho_{XY} \cdot \frac{\hat\sigma_Y}{\hat\sigma_X} = \boxed{\frac{\sum_{i=1}^n x_i y_i - n\bar x \bar y}{\sum_{i=1}^n x_i^2 - n\bar x^2}}$$

$$\hat b = \frac{5{,}8453 - 8 \cdot \frac{2{,}2899}{8} \cdot \frac{26{,}0393}{8}}{1{,}4211 - 8 \cdot \left(\frac{2{,}2899}{8}\right)^2} = \underline{-2{,}1}$$

$$\hat a = \bar y - \hat b \cdot \bar x = \frac{26{,}0393}{8} - (-2{,}1) \cdot \frac{2{,}2899}{8} = \underline{3{,}856}$$

- *Rücktransformation in die Parameter α und β:*

$$\hat a = \ln \hat\alpha \longrightarrow \boxed{\hat\alpha = e^{\hat a}} = e^{3{,}856} = \underline{47{,}28} \text{ und } \boxed{\hat\beta = \hat b} = -2{,}1$$

- *Nachfragefunktion:*

$$\boxed{v = 47{,}28\, e^{-2{,}1/u}}$$

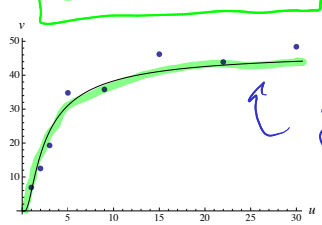

geschätzte nicht-lin. Funktion

Transformationstabelle: $v = f(u,\alpha\beta) \to y = a + b\,x$

- Weitere Beispiele nicht-linearer Problemstellungen, die auf einen linearen Regressionsansatz transformiert werden können, sind:

$v = f(u)$	$y = T(v)$	a	b	$x = g(u)$
$v = \alpha + \beta\, u^k$	$v = \alpha + \beta \cdot u^k$	α	β	u^k
$v = \frac{\alpha\, u}{\beta + u}$	$\frac{1}{v} = \frac{1}{\alpha} + \frac{\beta}{\alpha}\,\frac{1}{u}$	$\frac{1}{\alpha}$	$\frac{\beta}{\alpha}$	$\frac{1}{u}$
$v = \frac{u}{\alpha + \beta\, u}$	$\frac{u}{v} = \alpha + \beta\, u$	α	β	u
$v = \alpha\, \beta^u$	$\ln v = \ln \alpha + (\ln \beta) u$	$\ln \alpha$	$\ln \beta$	u
$v = \alpha\, u^\beta$	$\ln v = \ln \alpha + \beta \ln u$	$\ln \alpha$	β	$\ln u$

1.11.5 Fallstudie: Multivariate lineare Regression*

Univariate lineare Regression: Wir haben einen funktionalen Zusammenhang zw. dem Umsatz U und der durchschnittlichen Temperatur T gefunden. Können wir noch weitere Einflüsse (Wochenende, Regen) berücksichtigen?

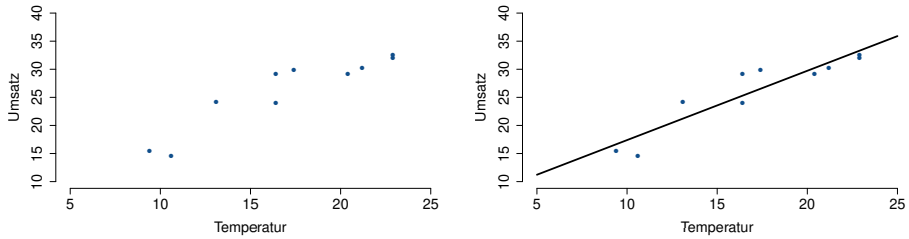

Multivariate lineare Regression*: Einflußfaktoren

- Ansatz:
  - $y = b_0 + b_1\, x_1 + b_2\, x_2 + \cdots + b_L\, x_L$
  - Mit dem Regressanden y und L Regressoren $x_1, \ldots, x_L$ (multivariate Regression); liegt nur ein Regressor x vor, spricht man dagegen von einer **univariaten** Regression

- Stichprobe: $((x_{11}, \ldots, x_{L1}), y_1), \ldots, ((x_{1n}, \ldots, x_{Ln}), y_n)$

- Gleichungssystem:

$$y_1 = b_0 + b_1\, x_{11} + b_2\, x_{21} + \cdots + b_L\, x_{L1} + \varepsilon_1$$
$$\vdots$$
$$y_n = b_0 + b_1\, x_{1n} + b_2\, x_{2n} + \cdots + b_L\, x_{Ln} + \varepsilon_n$$

- Darstellung in Matrixform: $\mathbf{y} = \mathbf{X}\mathbf{b} + \varepsilon,$

  mit der Designmatrix
$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{L1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{Ln} \end{pmatrix}$$

- MkQ-Lösung: $\mathbf{b} = (\mathbf{X}^T\mathbf{X})^{-1}\,\mathbf{X}^T\,\mathbf{y}$

  Multivariate lineare Regression*

1, es regnet

Regen

0, sonst

Wochenende

- Daten:

Tag	1	2	3	4	5	6	7	8	9	10
u	29.21	23.96	32.47	30.19	29.11	15.47	24.25	29.84	14.57	32.09
t	20.40	16.40	22.90	21.20	16.40	9.40	13.10	17.40	10.60	22.90
r	0	0	0	0	0	0	0	0	1	0
w	0	0	0	0	1	0	1	1	0	0

- Designmatrix $\mathbf{X}$ mit den Spalten - 1. Konstante (Vektor von Einsen), 2. Temperatur t, 3. Regen r, 4. Wochenende w:

$$\mathbf{X} = \begin{pmatrix} 1 & 20.4 & 0 & 0 \\ 1 & 16.4 & 0 & 0 \\ \dots & \dots & \dots & \\ 1 & 17.4 & 0 & 1 \\ 1 & 10.6 & 1 & 0 \\ 1 & 22.9 & 0 & 0 \end{pmatrix}$$

  Multivariate lineare Regression*

- MkQ-Lösung:

$$\begin{aligned} \hat{\mathbf{b}} &= (\mathbf{X}^T\mathbf{X})^{-1}\,\mathbf{X}^T\,\mathbf{u} \\ &= \begin{pmatrix} 2.60 & -0.13 & -1.23 & -0.58 \\ -0.13 & 0.01 & 0.06 & 0.02 \\ -1.23 & 0.06 & 1.63 & 0.35 \\ -0.58 & 0.02 & 0.35 & 0.57 \end{pmatrix} \cdot \begin{pmatrix} 261.00 \\ 4721.00 \\ 15.00 \\ 83.00 \end{pmatrix} \\ &= \begin{pmatrix} 3.51 \\ 1.26 \\ -2.27 \\ 4.57 \end{pmatrix} \end{aligned}$$

Temperatur
Regen
Wochenende

- Umsatzfunktion: $u \approx 3.51 + 1.26 \cdot t - 2.27 \cdot r + 4.57 \cdot w,\ 9 \le t \le 24,\ r, w \in \{0,1\}.$

I. Deskriptive Statistik → Ende
II. Grundlagen der Wahrscheinlichkeitstheorie
III. Schließende Statistik / Induktive Statistik

Zusammenfassung Teil I

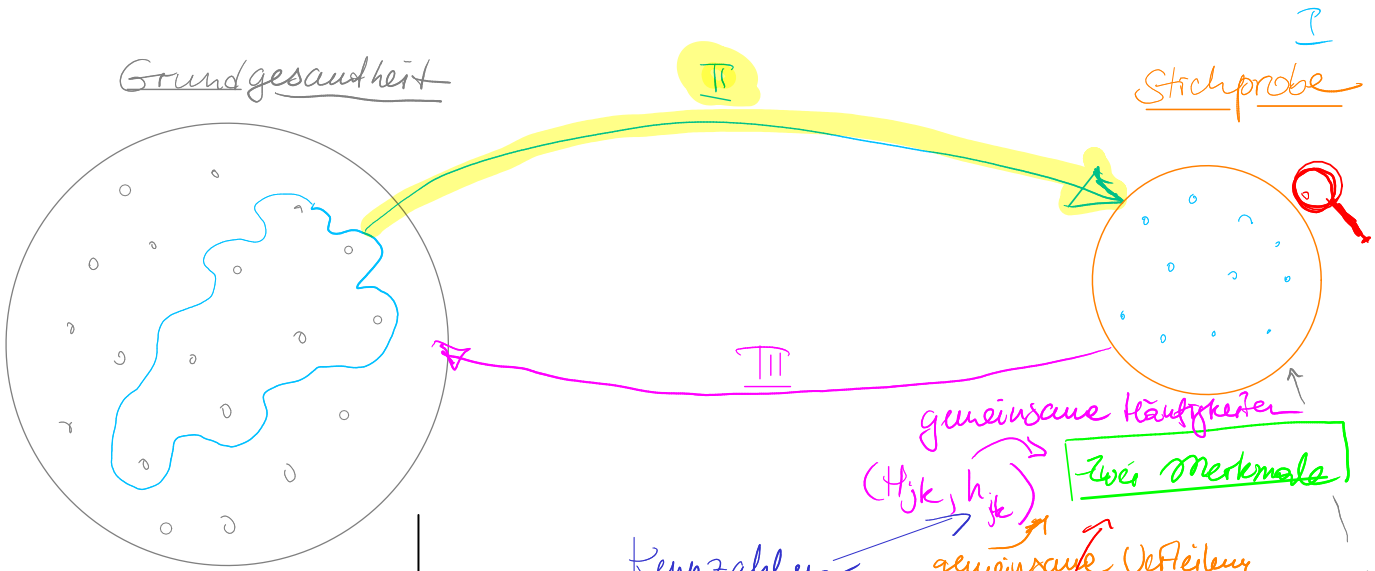

ein Merkmal

- Skala
- empir. Wkt
- Häufigkeiten (H_i, h_i)
- empirische Verteilung $(\hat{f}(x); \hat{F}(x))$
- "Gleichmäßigkeit" der Verteilung → Lorenz-Kurve / Gini-Koeffizient / Konzentrationsrate

Kennzahlen

- Lageparameter
  - empir. Erwartungswert $\bar{x}$
  - Median / Quartile $\hat{\mu}$
- Streuungsparameter
  - empir. Varianz / Standardabw. $\hat{\sigma}^2$ / $\hat{\sigma}$
  - Quartilsabstand
  - Variationskoeff

zwei Merkmale

gemeinsame Häufigkeiten (H_{jk}, h_{jk})

gemeinsame Verteilung

bedingte Häufigkeiten $h_{x|y}$

→ Kriterium für die empir. Unabhängigkeit $(h_{xy} = h_x \cdot h_y)$

Kennzahlen für den Zusammenh.

→ empir. Korrelation $(\hat{\rho}_{xy})$ $\hat{\sigma}_{xy}$

→ empir. Rangkorrelation $(\hat{\rho}^s_{xy})$ ← $R(x); R(y)$

→ empir. Kontingenz $\chi^2 \to C \to C^*$ (normiert)

Regression

Erkläre ein Merkmal durch das andere Merkmal

- linear → $y = a + bx$ → MkQ-Methode
- nicht-linear → Transformation → zurück transformieren

Offene Fragen

- Wie kommen die Daten zustande?
  - II ↳ Zufallsmechanismus
  - ↳ Modell?
  - III ↳ Kennzahlen aus der Stichprobe verallgemeinern?
- Woher kommen die Formeln für die Kennzahlen
  - III ↳ Schätzer für die Parameter der GG?
  - ↳ Qualität der Schätzung?