Einstiegsbeispiele

Beispiel 0.0.1. *Beurteilung der Kreditwürdigkeit und Bonitätsprüfung*

- *Vor Vergabe eines Kredits muss die Bank die Kreditqualität und die Wahrscheinlichkeit des Ausfalls des Kreditnehmers beurteilen.*
- *Eine typische Beurteilung basiert auf beobachtbaren Faktoren, die mit dem Ausfallrisiko verbunden sind:*
  - *Konsumentenkredit: Einkommen, Sicherheiten, Alter, Beruf, Ort, ...*
  - *Unternehmensanleihen: Bilanzgrößen, Rating, ...*
- *Die Entscheidung, einen Kredit zu gewähren, basiert auf existierenden Kreditdaten (beobachtbare Größen als Indikatoren für Ausfall/kein Ausfall).*
- *Ein* **statistisches Modell** *ist erforderlich, um diese Daten zu verlinken.*

Beispiel 0.0.2. *Werbekampagne*

- *Die Wirkung einer Werbekampagne, wo Kunden per Email angesprochen werden, muss hinsichtlich meßbarer KPIs (key performance indicators) evaluiert werden.*
- *Mittels einer randomisierten Auswahl werden Kunden zufällig der Ansprachegruppe oder der Kontrollgruppe zugeordnet.*
- *Es muss getestet werden, ob die Werbekampagne erfolgreich verlaufen ist, d.h. ob die Verbesserung von KPIs bei der Ansprachegruppe gegenüber der Kontrollgruppe statistisch* **signifikant** *ist.*

Beispiel 0.0.3. *Marktanteile von Smartphones*

- *Im Jahr 2014 wurden ca. 1,3 Milliarden Smartphones verkauft.*
- *Die folgende Tabelle zeigt die Absatzzahlen (in Millionen) der zehn erfolgreichsten Hersteller:*

Samsung	314,2	*LG*	59,1
Apple	192,7	*Coolpad*	50,4
Lenovo	95,0	*ZTE*	46,1
Huawei	75,0	*TCL-Alcatel*	41,4
Xiaomi	61,1	*Sony*	40,2

Quelle: Fahrmeir et al.: Statistik. Springer, 2016.

- *Ist der Markt konzentriert, d. h. dominiert durch wenige Hersteller?*
  (→ **Lorenz-Kurve***)*

Die Vorlesung gliedert sich in drei Teile:

- **Teil I: Deskriptive Statistik**

  Datenerhebung + **Datenzusammenfassung und -analyse** → geeignete graphische und analytische Verfahren.

- **Teil II: Wahrscheinlichkeitstheorie**

  Viele ökonomischen Größen unterliegen zufälligen Einflüssen → Beschreibung durch **ein stochastisches Modell** → Wahrscheinlichkeiten von Ereignissen berechnen und charakteristische Kennzahlen (Parameter) der Verteilung definieren.

- **Teil III: Induktive Statistik**

  Aus den Daten Erkenntnisse generieren → Parameter eines geeigneten stochastischen Modells **schätzen**, Hypothesen **testen**.

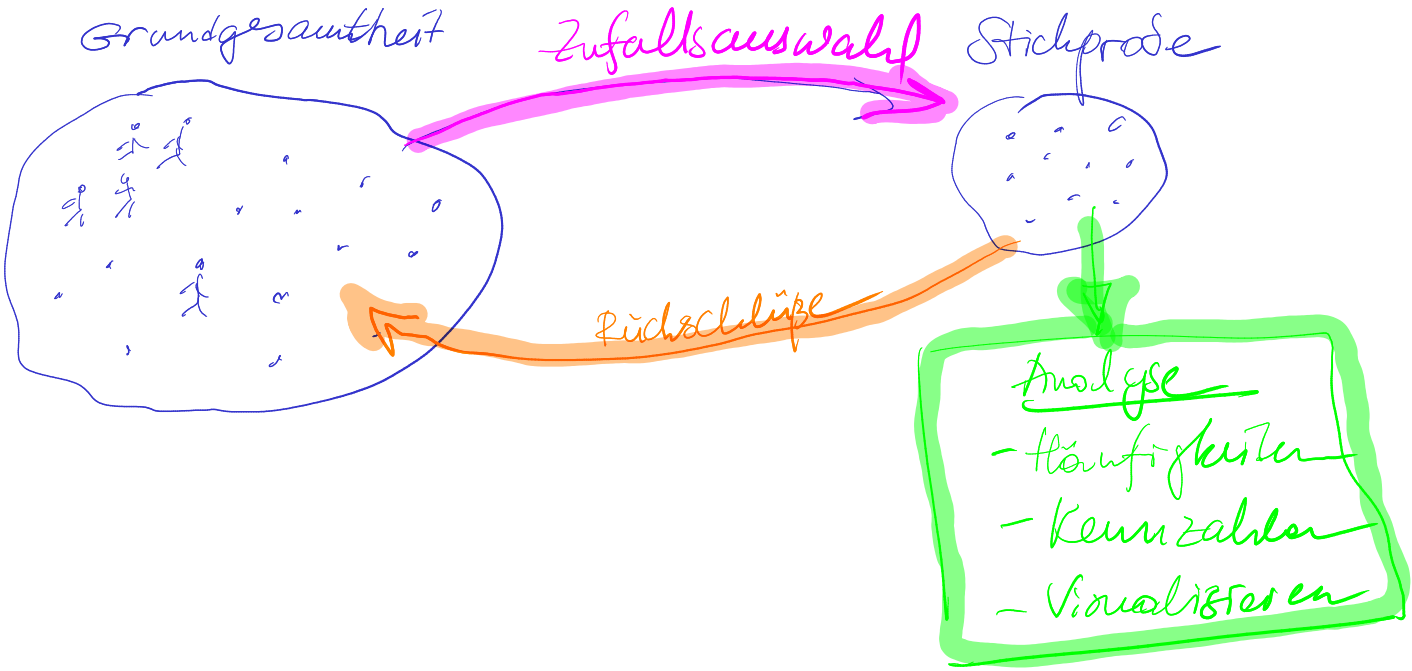

Inhalt

1 Deskriptive Statistik **7**

1.1 Merkmale . . . 8

1.1.1 Grundgesamtheit, Merkmal, mögliche Ausprägungen . . . 8

1.1.2 Skalentypen . . . 9

1.1.3 Stichprobe . . . 10

1.2 Häufigkeitsverteilungen . . . 11

1.2.1 Häufigkeitsverteilung ohne Klassenbildung . . . 11

1.2.2 Häufigkeitsverteilung mit Klassenbildung . . . 13

1.2.3 Klassenmitte und Klassenmittel . . . 13

1.2.4 Histogramm . . . 14

1.3 Empirische Dichtefunktion und empirische Verteilungsfunktion . 16

1.3.1 Empirische Dichtefunktion / Verteilungsfunktion (diskreter Fall) . . . 16

1.3.2 Empirische Dichtefunktion / Verteilungsfunktion (kontinuierlicher Fall) . . . 18

1.3.3 Fallstudie . . . 20

1.4 Kennzahlen bei einem Merkmal . . . 22

1.5 Lagemaße . . . 24

1.5.1 Empirischer Erwartungswert / Mittelwert . . . 24

1.5.2 Median, α-gestutztes Mittel . . . 24

1.5.3 Geometrisches Mittel . . . 26

1.5.4 Modalwert . . . 27

1.6 Quantile und Boxplots . . . 27

1.6.1 Quantile . . . 27

1.6.2 Spezielle Quantile und Quartilsabstand . . . 28

1.6.3 Boxplot . . . 29

1.7 Streuungsmaße . . . 30

1.7.1 Empirische Varianz, empirische Standardabweichung . . . 30

1.7.2 Transformationsregel: $\hat{\mu}$ und $\hat{\sigma}^2$ unter linearen Transformationen . . . 31

1.7.3 **z**-Score, Spannbreite, Variationskoeffizient . . . 32

1.7.4 Fallstudie: Typischer Kunde . . . 33

1.7.5 Fallstudie: Empirische Quantile und Value at Risk . . . 35

1.8 Konzentrationsmaße . . . 36

1.8.1 Lorenz-Kurve . . . 37

1.8.2 Gini-Koeffizient . . . 40

1.8.3 Konzentrationsrate . . . 42

1.8.4 Fallstudie: Konzentration . . . 42

1.9 Zusammenhangsmaße bei zwei Merkmalen 45
1.9.1 Häufigkeiten und Randhäufigkeiten 46
1.9.2 Bedingte Häufigkeiten 49
1.9.3 Empirische Unabhängigkeit 52
1.10 Zusammenhangskennzahlen bei zwei Merkmalen 53
1.10.1 Empirische Kovarianz, empirischer Korrelationskoeffizient 54
1.10.2 Rangkorrelation 59
1.10.3 χ^2-Koeffizient, Kontingenzkoeffizient, normierter Kontingenzkoeffizient 61
1.10.4 Fallstudie: Korrelation - Aktienrendite 63
1.11 Regressionsrechnung 64
1.11.1 Lineare Regression 65
1.11.2 MkQ-Schätzer 66
1.11.3 Bestimmtheitsmaß R^2 66
1.11.4 Nicht-lineare Regression 68
1.11.5 Fallstudie: Multivariate lineare Regression* 70

2 Wahrscheinlichkeitstheorie 72
2.6 Wahrscheinlichkeiten 72
2.6.1 Wahrscheinlichkeitsraum 73
2.6.2 Laplace-Modell 77
2.6.3 Kombinatorik* 79
2.6.4 Endliche Wahrscheinlichkeitsräume 81
2.6.5 Rechnen mit Wahrscheinlichkeiten 82
2.7 Unabhängigkeit und bedingte Wahrscheinlichkeiten 84
2.7.1 Bedingte Wahrscheinlichkeiten 84
2.7.2 Unabhängigkeit 87
2.7.3 Totale Wahrscheinlichkeit/Bayes 89
2.8 Zufallsvariablen 93
2.8.1 Diskrete Zufallsvariablen und diskrete Verteilungen 94
2.8.2 Stetige Zufallsvariablen und stetige Verteilungen 100
2.8.3 Erwartungswert und Varianz 104
2.8.4 Unabhängigkeit, Kovarianz und Korrelation* 108
2.8.5 Quantile 110
2.9 Wahrscheinlichkeitsverteilungen 112
2.9.1 Bernoulli-Verteilung 113
2.9.2 Diskrete Gleichverteilung 114
2.9.3 Binomialverteilung 115
2.9.4 Poisson-Verteilung* 119
2.9.5 Exponentialverteilung* 121

2.9.6 Normalverteilung 122
2.9.7 Zentraler Grenzwertsatz (ZGS) 126
2.9.8 Chi-Quadrat-Verteilung und Student-t-Verteilung 128

3 Induktive Statistik **131**
3.1 Parameterschätzung 131
3.1.1 Punktschätzverfahren 132
3.1.2 Eigenschaften von Schätzern 134
3.1.3 Intervallschätzverfahren 138
3.2 Testverfahren 145
3.2.1 Konstruktion von Tests 147
3.2.2 Binomialtest 147
3.2.3 Der approximative Binomialtest 149
3.2.4 Gauß-Test 151
3.2.5 t-Test 152

1 Deskriptive Statistik

Merkmale und Häufigkeiten

Beispiel 1.0.1. *Device-Nutzung*

Gegenstand	*Device-Nutzung für Bankgeschäfte bei einer Online-Bank*
Zielsetzung	*Welcher Kundenanteil nutzt welches Device (Smartphone, Tablet, PC) für Bankgeschäfte?*
Grundgesamtheit	*Kundenstamm*
Merkmal D	*für Bankgeschäfte genutztes Device*
Ausprägungen	*Smartphone, Tablet, PC und keine Antwort.*
Stichprobe	*repräsentative Befragung von* 500 *Kunden*
Auswertung	
Prognose	*etwa* 46% *der Kunden nutzt Smartphone für Bankgeschäfte.*
Bemerkung	*Es kann von Interesse sein, weitere Merkmale zu erfassen und ihre Beziehung zu* D *zu analysieren; etwa Altersgruppe; Transaktionsart; Transaktionssumme.*

Smartphone	*Tablet*	*PC*	*keine Antwort*
228	114	156	2

← Häufigkeiten (H)

0,46

H_D →

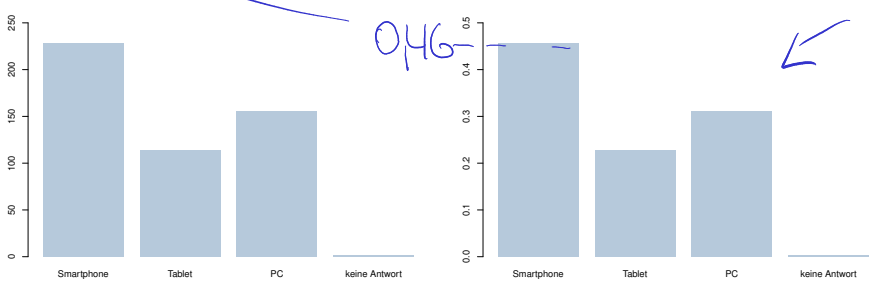

relativen Häufigkeiten (h_D)

Grundlegende Begriffe

- Eine **Grundgesamtheit** ist eine Menge einheitlicher Objekte (statistischer Einheiten), die alle durch die gleichen **Merkmale** charakterisiert sind.
- Jedes Merkmal erscheint in verschiedenen **Ausprägungen**.
- Eine **Stichprobe** ist die **zufällige** Auswahl von Objekten der Grundgesamtheit und die Messung der jeweiligen Ausprägung eines oder mehrerer bestimmter Merkmale an diesen Objekten.

- Ziel: die Bestimmung und die Visualisierung von **Häufigkeitsverteilungen**, d. h. die Berechnung der Häufigkeiten, mit denen die einzelnen Ausprägungen in der Stichprobe vorkommen.
- Ist die Stichprobe **repräsentativ**, kann von der Stichprobenverteilung auf die Verteilung der Ausprägungen in der Grundgesamtheit geschlossen werden (**Induktiver Schluss**).

1.1 Merkmale

1.1.1 Grundgesamtheit, Merkmal, mögliche Ausprägungen

"Omega"

- Ω: **Grundgesamtheit**, besteht aus einheitlichen Objekten (die Elemente $\omega \in \Omega$ werden auch statistische Einheiten genannt)

"ein Element von ..."

- X: **Merkmal** (beobachtbare Eigenschaft der Objekte)
- A_X: Menge der **Ausprägungen** des Merkmals X

Beispiel 1.1.1 (Kundenbewertungen)**.** Ω: *Kundenbewertungen, d. h. Objekte sind Bewertungen*

Wie viele erlaubte Zeichen (anteilig) benutzt

Merkmal	*Ausprägungen*
X =*rel. Länge*	$A_X = [0, 1]$ *(Intervall)*
Y =*Kategorie*	$A_X = \{$*bug_ report, user_ experience, feature_ request, review,sonstiges*$\}$
Z =*Sterne*	$A_Z = \{1,2,3,4,5\}$

Rating AAA AA A BBB BB B C D

"best" "worst"

1.1.2 Skalentypen

Ausprägungen lassen sich als Werte auf einer Skala darstellen.

Informationsgehalt

wenig

viel

Nominalskala Die Ausprägungen stehen gleichberechtigt nebeneinander; keine Rangfolge der Ausprägungen.

Ordinalskala Zwischen den Ausprägungen besteht eine (natürliche) Rangordnung; z. B. größer als, besser als.

Metrische Skala Jeder Ausprägung entspricht ein Wert des Zahlenstrahls. Es lassen sich Abstände zwischen den Merkmalsausprägungen messen.

- **diskret**: $A_X = \{a_1, \dots, a_J\}$ oder $A_X = \{a_1, a_2, \dots\}$
- **kontinuierlich**: A_X ist ein Intervall

Bewertungen:

- X=rel.Länge ist metrisch skaliert
- Y=Kategorie nominal skaliert
- Z=Sterne ist ordinal skaliert

Aufgabe 1.1.2. *Firmenkunden*

- Ω: *Firmenkunden einer Bank*
- *Merkmale:*
  - X_1: *Anzahl der Beschäftigten*
  - X_2: *Verschuldungsgrad*
  - X_3: *Unternehmensform*
  - X_4: *Ratingkategorie*

natürliche Zahlen

Merkmal	*Ausprägungen*	*Skala*
X_1	300; 2; $\mathbb{N}$	metrisch / diskret
X_2	0,12/20% 0,01 150%	metrisch / kontinuierlich
X_3	AG / GmbH	nominal
X_4	AAA, C, BB, ...	ordinal

aa+, b-

1.1.3 Stichprobe

- Gegeben:
  - X: Merkmal von Objekten einer Grundgesamtheit Ω
  - A_X: Menge der Ausprägungen von X
- Definiere
  - **Stichprobe** / Messreihe $x_1, x_2, \ldots, x_n$,
    also: Beobachtung der jeweiligen Ausprägungen des Merkmals X an n zufällig ausgewählten Objekten

Stichprobenwerte

n Objekte

- Bezeichnungen:
  - n: Umfang der Stichprobe
  - x_i = i-ter **Messwert** / **Stichprobenwert**

$i = 1; 2; 3; \ldots; n$

Index

Beispiel: 1) Device-Nutzung D 2) Zeit auf der Website Z

Grundgesamtheit: Kd1 Kd2 Kd3 .... Kd100, ... Kd200 Kd201, ... Kd1000

Stichprobe: Kd1, Kd2, Kd3 ... Kd500

Ausprägungen von D: "PC", "Smartphone", "PC", "Tablet"

Messwerte zu D: d_1, d_2, $d_3, \ldots, d_{500}$

Ausprägung	"PC"	"Smartphone"	"Tablet"	"Sonstiges"
Häufigkeit	156	228	114	2

Gruppieren

Ausprägungen von Z: 20 min – 30 min: 25,5 Minuten, > 60 min: 72,1 Minuten, 10 min – 20: 10 min, 1,2 min

Messwerte zu Z: z_1, z_2, $z_3, \ldots z_{500}$

Stichprobenmittelwert $\bar{z}(\bar{X}) = \frac{25{,}5 + 72{,}1 + \ldots + 10{,}0 + \ldots + 1{,}2}{500}$

Erwartungswert $E(X)$ $E(Z)$

1.2 Häufigkeitsverteilungen

X hat
J Ausprägungen

- Gegeben:
  - Merkmal X
  - Ausprägungsmenge $A_X\{a_1, \dots, a_J\}$ oder
  - Stichprobe $x_1, \dots, x_n$

- Ziel:
  Angabe der Verteilung (Häufigkeiten) der Stichprobenwerte auf die einzelnen Ausprägungen der Menge A_X

- Unterscheide dabei zwei Fälle:
  - **Häufigkeitsverteilung ohne Klassenbildung**: wenn bestimmte Ausprägungen in der Stichprobe wiederholt vorkommen, z. B. bei nominaler, ordinaler oder diskret metrischer Skalierung
  - **Häufigkeitsverteilung mit Klassenbildung**: wenn sich die Stichprobenwerte kaum oder gar nicht wiederholen, z. B. bei kontinuierlich metrischer Skalierung

1.2.1 Häufigkeitsverteilung ohne Klassenbildung

- Definiere

$$
\begin{aligned}
H_j &= H(a_j) \quad \text{j-te Ausprägung} \\
&= \text{Anzahl der Messwerte mit } \boxed{x_i = a_j} \\
&= \text{absolute Häufigkeit von } a_j
\end{aligned}
$$

und

$$
\begin{aligned}
\boxed{h_j = \frac{H_j}{n} = h(a_j)} \quad & \text{Absolute Häufigkeit / Stichprobenumfang} \\
&= \text{relative Häufigkeit von } a_j
\end{aligned}
$$

- **Häufigkeitsverteilung**:

Ausprägung	a_1	a_2	$\cdots$	a_J
relative Häufigkeit	h_1	h_2	$\cdots$	h_J

- Bemerkung: In der Häufigkeitsverteilung können statt der relativen auch die absoluten Häufigkeiten stehen.

- Darstellung: Balkendiagramm oder Kreisdiagramm

Kreditnehmer Nr	Ausfall j/n	Grund
1234567	ja	Arbeitslos
8910112	ja	Krankheit
13141516 17	ja	Arbeitslos
	...	

Beispiel 1.2.1. *Kreditausfall*

- *Grundgesamtheit* Ω*: Notleidende Kredite im Sektor Privatkunden*
- *Merkmal* X*: Ursache der Insolvenz (nominale Skalierung)*

wie oft? wie oft (anteilig)?

Ausprägung a_j	*abs. Häufigkeit* H_j	*rel. Häufigkeit* h_j
a_1 = *Arbeitslosigkeit*	261	$\frac{261}{1236} = 0{,}2112$
a_2 = *Probleme bei der Haushaltsführung*	301	$\frac{301}{1236} = 0{,}2435$
a_3 = *Schwangerschaft*	22	$\frac{22}{1236} = 0{,}0178$
a_4 = *Scheidung / Trennung*	124	$\frac{124}{1236} = 0{,}1003$
a_5 = *Krankheit*	198	$\frac{198}{1236} = 0{,}1602$
a_6 = *soziale Probleme*	211	$\frac{211}{1236} = 0{,}1707$
a_7 = *sonstige Ursachen*	119	$\frac{119}{1236} = 0{,}0963$
Summe	$n =$ 1236	≈ 1

Balken- und Kreisdiagramme

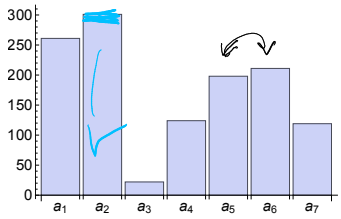

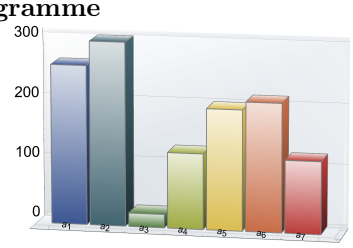

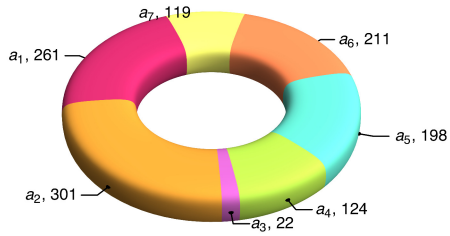

3 Werte → Häufigkeit von K_1 ist 3.

1.2.2 Häufigkeitsverteilung mit Klassenbildung

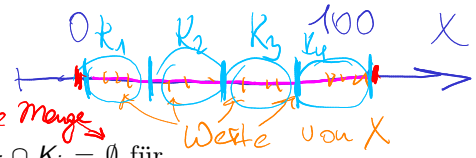

- Gegeben:
  - Stichprobe $x_1, \dots, x_n$ eines Merkmals X
  - Klasseneinteilung $A_X = K_1 \cup \dots \cup K_J$ mit $K_i \cap K_j = \emptyset$ für $i \neq j$

Leere Menge

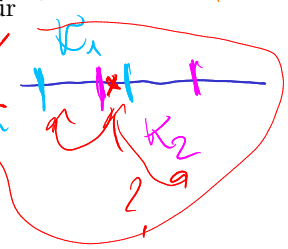

- Definiere

Anzahl von x, die in diese Klasse hineinfallen

$$H_j = H(K_j)$$
$$= \text{Anzahl der Messwerte mit } x_i \in K_j$$
$$= \text{absolute Häufigkeit von } K_i$$

und
$$\boxed{h_j = \frac{H_j}{n} = h(K_j)}$$
$$= \text{relative Häufigkeit von } K_j$$

Klassen

- **Häufigkeitsverteilung**:

Klasse	K_1	K_2	$\cdots$	K_J
rel. Häufigkeit	h_1	h_2	$\cdots$	h_J

- Darstellung: Balkendiagramm, Histogramm oder Kreisdiagramm

Kd = 10 min

Kd = 20 min

Zeit auf der Website:

$K_2 = [10; 20)$

$K_1 = [0; 10)$

obere Grenze von K_1 = untere Grenze von K_2

1.2.3 Klassenmitte und Klassenmittel

- Gegeben:
  - metrisch skaliertes Merkmal X mit Klasseneinteilung $K_1, K_2, \dots, K_J$ der Ausprägungsmenge
  - Klassen sind Intervalle: $K_j = [b_{j-1}, b_j)$, $j = 1, \dots, J$

untere Grenze ist im Intervall enthalten

untere Grenze

obere Grenze nicht im Intervall enthalten

  - Stichprobe $x_1, \dots, x_n$

Es gibt zwei Möglichkeiten, das Zentrum einer Klasse festzulegen:

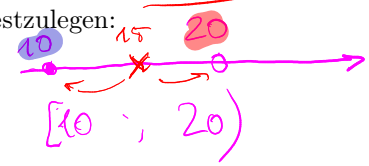

- **Klassenmitte**: a_j = Mittelpunkt des Intervalls:

$$a_j = \frac{b_j + b_{j-1}}{2}$$

- **Klassenmittel**: a_j = arithmetisches Mittel der Stichprobenwerte in K_j:

$$a_j = \frac{1}{H_j} \sum_{x_i \in K_j} x_i$$

Anzahl der Werte in K_j

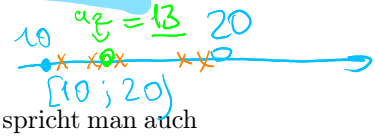

bevorzugt

- Bei einem metrisch skalierten Merkmal mit Intervallklassen spricht man auch von einer **kontinuierlichen Häufigkeitsverteilung** im Gegensatz zu einer **diskreten Häufigkeitsverteilung**, wenn keine Klasseneinteilung vorliegt.

Beispiel 1.2.2. *Aktienkursänderungen*

- X = *Kursänderungen einer Aktie für* $\Delta t = 1$ *Tag*
- *Klasseneinteilung einer Stichprobe vom Umfang* $n = 250$

Klassenbreite = 2

	Klasse	*Klassenmitte*	*abs. Häufigkeit*	*rel. Häufigkeit*
j	K_j	a_j	H_j	h_j
1	$-10 \le x_i < -8$		10	10/250 = 0,04
2	$-8 \le x_i < -6$		4	4/250 = 0,016
3	$-6 \le x_i < -4$		40	40/250 = 0,16
4	$-4 \le x_i < -2$		15	15/250 = 0,06
5	$-2 \le x_i < 0$		25	0,1
6	$0 \le x_i < 2$		87	0,348
7	$2 \le x_i < 4$		15	0,06
8	$4 \le x_i < 6$		33	0,132
9	$6 \le x_i < 8$		6	0,024
10	$8 \le x_i < 10$		15	0,06
Summe		$n =$	250	≈ 1

Summe der rel. Häufigkeiten

Handelstage

1.2.4 Histogramm

$\frac{H_1}{d_1} \cdot d_1 = H_1$

Man zeichnet für jede Klasse $K_j = [b_{j-1}, b_j)$ ein Rechteck mit

- Breite $d_j := b_j - b_{j-1}$, = Abstand zw. der oberen & der unteren Grenze
- Höhe: proportional zu H_j/d_j bzw. h_j/d_j.

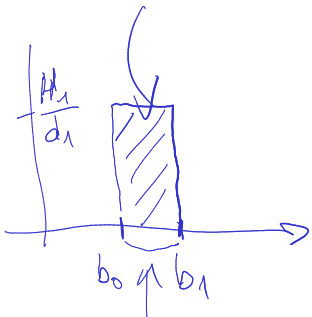

d_1 = Klassenbreite

Die Fläche des Rechtecks ist proportional zu H_j bzw. h_j.

- Bemerkungen:
  - Die Größe h_j/d_j heißt **Dichte** der Klasse c_j.
  - Falls die Klassen dieselbe Breite haben, so können für das Histogramm absolute oder relative Häufigkeiten verwendet werden.

Beispiel 1.2.3. *Aktienkursänderungen*

- *Klassenintervalllänge* $d_j = 2$ *und* $d_j = 4$, $j = 1, \dots, J$
- *Histogramme (oben: absolute Häufigkeiten, unten: Dichte)*

Klassenbreite=2

Klassenbreite = 4

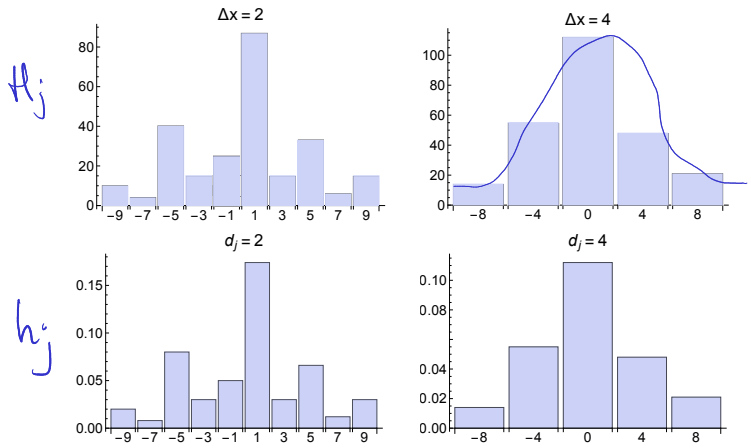

Aufgabe 1.2.4. *Häufigkeiten mit Klasseneinteilung*

- *Gegeben:*
  - *Merkmal* X = *Alter der Mitarbeiter im Geschäftsfeld Firmenkunden*
  - *Stichprobe vom Umfang* $n = 20$*:*

$$53, 32, 51, 37, 22, 33, 51, 62, 53, 44, 36, 28, 51, 60, 37, 56, 46, 45, 59, 55$$

- *Bestimmen Sie zur Klasseneinteilung von* 15 *bis* 65 *mit Klassenbreite* 10*:*

  (i) die Klassenmitten;

  (ii) die Klassenmittel;

  (iii) die Häufigkeitsverteilung;

  (iv) das Histogramm.