Verteilungsmodelle:
- nützliche Verteilungstypen, die in vielen praktischen Fragestellungen anwendbar sind.
- bestimmte Voraussetzungen, wenn ein Verteilungsmodell angewandt werden kann
- $f(x)$; $F(x)$; $\mathbb{E}(X)$, $Var(X)$

Formeln in Abhängigkeit von Parametern der Verteilung →

2.9 Wahrscheinlichkeitsverteilungen

Einleitung

- In diesem Abschnitt werden eine Reihe von Verteilungen vorgestellt, die häufig in Anwendungen auftreten.
- Jede Verteilung stellt eine Familie von Verteilungen dar, da sie mindestens einen freien Parameter enthält.
- Eine konkrete Verteilung ist erst durch Festsetzung aller Parameter spezifiziert.

I. **Diskrete Verteilung einer Zufallsvariable X:**

1. Bernoulli-Vert.
2. Binomialvert.
3. Diskrete Gleichvert.

Träger von X:	$\{x_1, x_2, \ldots\}$
Wahrscheinlichkeitsfunktion:	$x_n \mapsto f(x_n)$ für x_n aus dem Träger von X
Wahrscheinlichkeiten:	$P_X(B) = P(X \in B) = \sum_{x_n \in B} f(x_n)$ für $B \subseteq \mathbb{R}$
Erwartungswert:	$\mathbb{E}(X) = \sum_n x_n f(x_n)$
Varianz:	$\mathrm{Var}(X) = \underbrace{\sum_x x_n^2 f(x_n)}_{\mathbb{E}(X^2)} - (\mathbb{E}(X))^2$

II **Stetige Verteilung einer Zufallsvariable X:**

1. Normalvert.
2. χ^2-Vert. } wichtig für die Schätzung
3. t-Vert.

Dichte:	$x \mapsto f(x)$, $x \in \mathbb{R}$
Verteilungsfunktion:	$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$
Wahrscheinlichkeiten:	$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X < b) = \int_a^b f(x)\,\mathrm{d}x = F(b) - F(a)$
Erwartungswert:	$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x)\,\mathrm{d}x$
Varianz:	$\mathrm{Var}(X) = \underbrace{\int_{\mathbb{R}} x^2 f(x)\,\mathrm{d}x}_{\mathbb{E}(X^2)} - [\mathbb{E}(X)]^2$

I. Diskrete Verteilungen

2.9.1 Bernoulli-Verteilung

Erfolgswkt

- Es sei $A \in \mathcal{F}$ ein Ereignis mit $p = \mathbb{P}(A)$.
- Die Zufallsvariable $X = \mathbf{1}_A$, die anzeigt, ob das Ereignis A eintritt oder nicht,

Indikatorfkt von A

$$\mathbf{1}_A = \begin{cases} 1, & \text{falls } A \text{ eintritt}, \\ 0, & \text{falls } A \text{ nicht eintritt}, \end{cases}$$

besitzt eine **Bernoulli-Verteilung** mit Parameter p.

- Beispiele für A:
  - Werfen einer geraden Zahl beim Würfeln,
  - Ausfall eines Kredits,
  - erfolgreiche Behandlung eines Patienten,
  - Eintritt eines Schadens bei einer Versicherung.

Eine ZV X folgt einer **Bernoulli-Verteilung** mit Parameter $p \in (0,1)$, falls:

- Träger: $\mathcal{T} = \{0;1\}$
- Wahrscheinlichkeitsfunktion: $f(1) = p$, $f(0) = 1 - p$

Eigenschaften:

$$\boxed{\mathbb{E}(X) = p \quad \text{und} \quad \mathrm{Var}(X) = p(1-p).}$$

$\mathbb{E}(X) = 1 \cdot p + 0 \cdot (1-p) = p$

$\mathrm{Var}(X) = 1^2 \cdot p + 0^2 (1-p) - p^2 = p - p^2 = p(1-p)$

Beispiel 2.9.1. *Urne*

Experiment: *zufälliges Ziehen eines Balls aus eine Urne mit r roten und s schwarzen Bällen*

Zufallsvariable: $X = \mathbf{1}_{rot} = \begin{cases} 1, & \textit{falls der Ball rot ist} \\ 0, & \textit{falls der Ball schwarz ist} \end{cases}$

Wkt für rot

Folgerung: $X \sim Bern(p), p = \dfrac{r}{r+s}$

Bsp: 10 rot und 5 schwarz

$\rightarrow p = \frac{10}{10+5} = \frac{2}{3} \rightarrow X \sim Bern(p = \frac{2}{3})$

Beispiel 2.9.2. *Kundenaufkommen und Regen, siehe 2.7.3, Seite 86*

- *ZV:* $R = \begin{cases} 1, & \textit{es regnet}, \\ 0, & \textit{es regnet nicht}. \end{cases}$ *und* $K = \begin{cases} 1, & \textit{Kundenaufkommen} > 3, \\ 0, & \textit{Kundenaufkommen} \leq 3. \end{cases}$
- *Es gilt* $f_R(1) = f_R(0) = p_R = \frac{1}{2}$ *und* $f_K(1) = 1 - f_K(0) = K = 0.375$.
- $R \sim Bern(p_R)$ *und* $K \sim Bern(p_K)$ *mit* $p_R = \frac{1}{2}$ *und* $p_K = 0.375$: $K \sim Bern(0{,}375)$

$R \sim Bern(p = \frac{1}{2})$

$\mathbb{E}(R) = \frac{1}{2}$ $\quad \mathrm{Var}(R) = \frac{1}{2}(1 - \frac{1}{2}) = \frac{1}{4}$

$\mathbb{E}(K) = \underline{0{,}375}$ $\quad \mathrm{Var}(R) = 0{,}375(1 - 0{,}375) = \underline{0{,}2344}$

2.9.2 Diskrete Gleichverteilung

Eine diskrete Zufallsvariable X besitzt eine **Gleichverteilung** auf dem Träger $\{x_1, x_2, \dots, x_n\}$, falls für alle $i = 1, \dots, n$:

$$f(x_i) = \frac{1}{n}.$$

Eigenschaften:

$$\boxed{\mathbb{E}(X) = \frac{1}{n}\sum_{i=1}^{n} x_i} \longrightarrow E(X) = \sum_{i=1}^{n} x_i \cdot f(x_i) = \sum_{i=1}^{n} x_i \cdot \frac{1}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$\boxed{\mathrm{Var}(X) = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - (\mathbb{E}(X))^2}$$

- Beispiel: Werfen eines fairen Würfels , German Tank Problem

Beispiel 2.9.3. *Kundenbewertungen, siehe 2.8.2und 2.8.3*

- *Bewertungen von zwei Kunden (Annahmen: Kunden agieren unabhängig und jede Sternezahl hat die gleiche Chance vergeben zu werden).*

- *Zufallsvariable S_1 = "Sterne von Kunde 1" mit Wertebereich:*

$$\mathcal{T}_{S_1} = \{s_{1,1}, \dots, s_{1,n}\} = \{1; 2; \dots; 5\}$$

  nimmt $n = 5$ mögliche Werte mit gleicher Wahrscheinlichkeit $\mathbb{P}(S_1 = s_{1,i}) = \frac{1}{n} = \frac{1}{5}$ für jedes i an.

- *Erwartungswert und Varianz von S_1:*

$$\mathbb{E}(S_1) = \frac{1}{5}(1 + 2 + 3 + 4 + 5) = 3,$$

$$\mathrm{Var}(S_1) = \frac{1}{5}(1^2 + 2^2 + 3^2 + 4^2 + 5^2) - 3^2 = 2.$$

2.9.3 Binomialverteilung

$\begin{cases} 1, & \text{falls } A \text{ eintritt} \\ 0, & \text{sonst} \end{cases}$

- Ein Bernoulli-Experiment mit Wahrscheinlichkeit $p = \mathbb{P}(A)$ wird n-mal wiederholt.

- Die Zufallsvariable

  = "Anzahl von Einsen"

  $$X = \text{Anzahl der Versuche, in denen Ereignis } A \text{ eintritt}$$

  = Anzahl der Erfolge bei n Wiederholungen von Bernoulli-Experiment

  folgt einer Binomialverteilung mit den Parametern n und p.

Eine Zufallsvariable X besitzt eine **Binomialverteilung** mit den Parametern n und p, symbolisch $X \sim B(n,p)$, falls:

$$\mathbb{P}(X = k) = f(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad \text{für } k = 0,1,\dots,n,$$

und $f(k) = 0$ sonst.

Eigenschaften:

$$\boxed{\mathbb{E}(X) = np \quad \text{und} \quad \mathrm{Var}(X) = np(1-p)}$$

- **Binomialkoeffizient**: $\binom{n}{k} = \dfrac{n!}{k!(n-k)!}$ mit $n! = 1 \cdot 2 \cdot \ldots \cdot n$ und $0! = 1$.

- Die Summe der Erfolge in n unabhängigen Wiederholungen von Bern~~m~~oulli-Experimenten mit Erfolgswahrscheinlichkeit p besitzt eine Binomialverteilung.

- Insbesondere folgt, dass die Summe unabhängiger Binomialverteilungen mit demselben Parameter p wieder eine Binomialverteilung ist:

Addition von Binomialverteilungen

Sind $X \sim B(n,p)$ und $Y \sim B(m,p)$ unabhängig, so gilt $X + Y \sim B(n+m,p)$.

- Beispiele:
  - Anzahl der Ausfälle in einem Kreditportfolio (Annahme: Ausfälle erfolgen unabhängig voneinander.), $X \sim B(n, p)$ ← Ausfallwkt. ; n = Anzahl von Krediten im Pfl.
  - Anzahl der erfolgreich behandelten Patienten,
  - Schadenanzahl in einem Kollektiv von Versicherungsverträgen.

    Y, $Y \sim B(n, p)$ ← Wkt von einem Schaden ; n = Anzahl von Versicherungsverträgen

- Verschiedene Binomialverteilungen mit $n = 10$ (links) und $n = 10; n = 30;$ $p = 0{,}1; p = 0{,}5$ (rechts):

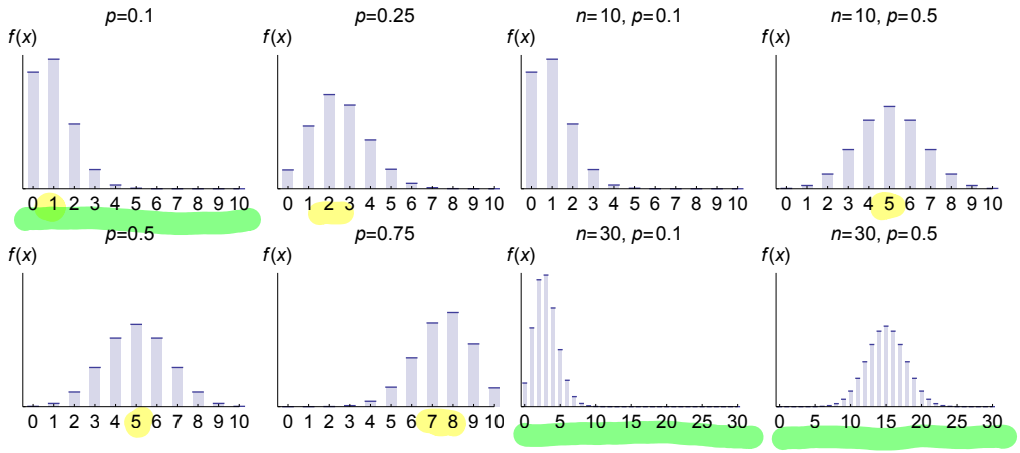

$$\mathbb{P}(X = k) = f(k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Beispiel 2.9.5. *Binomialverteilung*

Zufallsvariable X: $B(8; 0{,}75)$*-verteilt*

Wahrscheinlichkeit: $\mathbb{P}(X \leq 2) = \mathbb{P}(X=0) + \mathbb{P}(X=1) + \mathbb{P}(X=2) = \binom{8}{0} 0{,}75^0 (1-0{,}75)^8 + \binom{8}{1} 0{,}75^1 \cdot (1-0{,}75)^{8-1} + \binom{8}{2} 0{,}75^2 \cdot (1-0{,}75)^{8-2} = 0{,}0042$

Erwartungswert: $\mathbb{E}(X) = n \cdot p = 8 \cdot 0{,}75 = 6$

Varianz: $Var(X) = n \cdot p(1-p) = 8 \cdot 0{,}75(1-0{,}75) = 1{,}5$

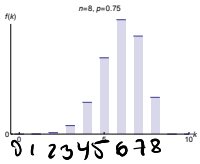

Beispiel 2.9.6. *Urnenmodell*

Gegeben:

- *Urne mit weißen und roten Kugeln*
- *Mischungsverhältnis* $\dfrac{\textit{Anzahl weißer Kugeln}}{\textit{Anzahl aller Kugeln}}$ *betrage* p

Experiment:

- *Zufällige Ziehung von* n *Kugeln hintereinander*
- *Gezogene Kugel wird vor dem nächsten Zug in die Urne zurückgelegt*

Zufallsvariable: $X =$ *Anzahl der gezogenen weißen Kugeln*

Folgerung: $X \sim B(n,p)$

Beispiel 2.9.7. *Kundenbefragung*

- *Starte eine Befragung von* n *Kunden um meine Services (mit Schwerpunkt App) zu verbessern. Bei der Befragung werden Kunden zufällig ausgewählt und können mehrfach teilnehmen. Anteil von Kunden, die das App nutzen beträgt insgesamt 10%.*

- *Zufallsvariable* A = *'Ausgewählter Kunde ist ein App-Nutzer' mit Werten* $a \in \{0(\textit{kein App-Nutzer}), 1(\textit{App-Nutzer})\}$. *ist Bernoulli-verteilt mit* $p = 0.1$.

- *Zufallsvariable* M = *'Anzahl der App-Nutzer bei der Kundenbefragung'.*

- M *binomialverteilt mit* $p = 0.1$ *und* $n = 100$: $M \sim B(100; 0{,}1)$.

k	10
P(X=k)	0,13186535
P(X<=k)	0,58315551

$$\mathbb{E}(M) = n \cdot p = 100 \cdot 0{,}1 = \underline{10}$$

$$Var(M) = n \cdot p(1-p) = 100 \cdot 0{,}1(1-0{,}1) = \underline{9}$$

$$\mathbb{P}(M > 10) = 1 - \mathbb{P}(M \leq 10) = 1 - (f(0) + f(1) + f(2) + \ldots + f(10)) \overset{\text{Excel}}{=} 0{,}5832$$

$$\mathbb{P}(M > 10) = \mathbb{P}(M = 11) + \mathbb{P}(M = 12) + \ldots + \mathbb{P}(M = 100)$$

Beispiel 2.9.8. *Kreditportfolio*

- *Betrachte ein homogenes Kreditportfolio mit 500 Krediten.*

- *Zufallsvariable* A = *'Ausfall eines Kredites' mit Werten* $a \in \{0(\textit{kein Ausfall}), 1(\textit{Ausfall})\}$. *ist Bernoulli-verteilt mit* $p = 0.01$.

- *Zufallsvariable* P = *'Anzahl der Ausfälle im Kreditportfolio' (Annahmen: Ausfälle geschehen unabhängig von einander und die Ausfallwkt bleibt gleich).*

- *Unter den Annahmen ist* P *binomialverteilt mit* $p = 0{,}01$ *und* $n = 500$ $P \sim B(500; 0{,}01)$.

$$\mathbb{E}(P) = n \cdot p = 500 \cdot 0{,}01 = 5$$

$$Var(P) = n \cdot p(1-p) = 500 \cdot 0{,}01(1-0{,}01) = 4{,}95$$

$$\mathbb{P}(P > 1) = 1 - \mathbb{P}(P \leq 1) = 1 - (\mathbb{P}(P=0) + \mathbb{P}(P=1)) =$$

$$= 1 - \left(\binom{500}{0} \cdot 0{,}01^0 \cdot 0{,}99^{500-0} + \binom{500}{1} \cdot 0{,}01^1 \cdot 0{,}99^{500-1}\right) =$$

$$= 1 - \left(\frac{500!}{0!(500-0)!} \cdot 0{,}01^0 \cdot 0{,}99^{500-0} + \frac{500!}{1!(500-1)!} 0{,}01^1 \, 0{,}99^{500-1}\right) =$$

$$= \underline{0{,}9602}$$

k	1
P(X=k)	0,03318426
P(X<=k)	0,03975474
P(X>k)	0,96024526

Beispiel 2.9.9. *Kundenaufkommen und Regen**

- *Zufallsvariable* R = *'Regen' mit Werten* $r \in \{0(\text{kein Regen}), 1(\text{Regen})\}$. *ist Bernoulli-verteilt mit* $p = \frac{1}{2}$.

- *Zufallsvariable* T = *'Anzahl Regentage in einer Woche' (Annahmen: Tage sind unabhängig von einander, was Wetterformationen betrifft und die Regenwahrscheinichkeit bleibt gleich)*

- *Unter den Annahmen ist* T *binomialverteilt mit* $p = \frac{1}{2}$ *und* $n = 7$ $T \sim B(7; \frac{1}{2})$.

$$\mathbb{E}(T) = 7 \cdot \frac{1}{2} = 3{,}5$$

$$Var(T) = 7 \cdot \frac{1}{2}\left(1 - \frac{1}{2}\right) = 1{,}75$$

$$\mathbb{P}(T = 7) = \binom{n}{k} p^k (1-p)^{n-k} = \binom{7}{7} 0{,}5^7 \cdot (1 - 0{,}5)^{7-7} = \frac{7!}{7!(7-7)!} \cdot 0{,}5^7 \cdot 0{,}5^0 = \underline{0{,}0078}$$

Beispiel 2.9.10. *Anwendung auf rel. Häufigkeit**

Experiment:

- *Ereignis* A, *das mit Wahrscheinlichkeit* $p = \mathbb{P}(A)$ *eintritt*
- *Wiederhole das Experiment* n*-mal unabhängig voneinander*

Häufigkeiten:

- $H_n(A) =$ *absolute Häufigkeit des Eintretens von* A *ist* $B(n,p)$*-verteilt*
- $h_n(A) = H_n(A)/n =$ *relative Häufigkeit*

Erwartungswert: $\mathbb{E}(h_n(A)) = \mathbb{E}\left(\frac{H_n(A)}{n}\right) = \frac{1}{n} \cdot n \cdot p = \mathbb{P}(A)$

Varianz: $Var(h_n(A)) = Var\left(\frac{H_n(A)}{n}\right) = \frac{1}{n^2} \cdot n \cdot p \cdot (1-p) = \frac{p(1-p)}{n} \to 0$, *für* $n \to \infty$

Folgerung:

- $h_n(A)$ *ist Schätzwert für die Wahrscheinlichkeit* $\mathbb{P}(A)$
- *Der Schätzwert ist eine umso bessere Näherung für* $\mathbb{P}(A)$, *je größer* n *ist*

II. Stetige Verteilungen

2.9.6 Normalverteilung

- Die **Normalverteilung** ist die bekannteste und bedeutendste Verteilung.
- Für viele Merkmale wird die empirische Verteilung hinreichend gut durch eine Normalverteilung approximiert.

- Die Normalverteilung ist insbesondere ein gutes Modell zur Beschreibung der Verteilung von Variablen, die in additiver Form aus einer großen Anzahl unabhängiger, zufälliger Effekte entstehen.
- Die theoretische Begründung für diese empirische Beobachtung liefert der **Zentrale Grenzwertsatz**.
- Die Normalverteilung wird häufig auch **Gauß-Verteilung** genannt, zu Ehren des Mathematikers und Universalgelehrten Carl Friedrich Gauß (1777–1855).
- Der ehemalige 10-DM-Schein zeigt C.F. Gauß und die Dichte der Normalverteilung.

Eine Zufallsvariable X besitzt eine **Normalverteilung** mit den Parametern $\mu \in \mathbb{R}$ und $\sigma > 0$, symbolisch $X \sim \mathsf{N}(\mu, \sigma^2)$, falls sie die folgende Dichte besitzt:

$$\boxed{\varphi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.}$$

$e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

Eigenschaften:

$$\boxed{\mathbb{E}(X) = \mu \quad \text{und} \quad \mathrm{Var}(X) = \sigma^2.}$$

- Verschiedene Normalverteilungen:

Dichte →

Verteilungsfkt →

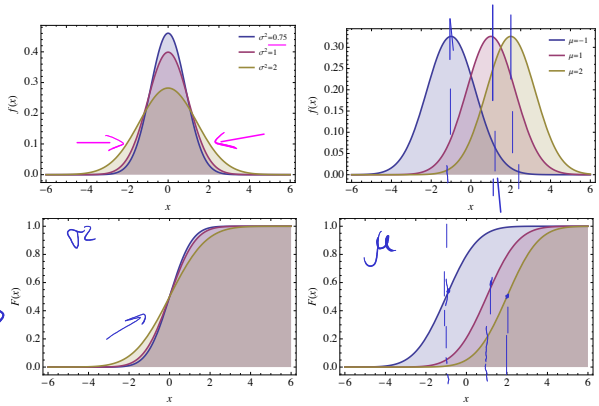

Die **Standardnormalverteilung** erhält man für $\mu = 0$ und $\sigma^2 = 1$; die Dichte ist gegeben durch $N(0;1)$

$$\boxed{\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \quad x \in \mathbb{R}.}$$

"phi"

- Notation: $\varphi(x)$ für die Dichte und $\mathsf{N}(x)$ für die Verteilungsfunktion.

Eigenschaften der Normalverteilung

- Additionseigenschaft der Normalverteilung:
  Sind $X \sim \mathsf{N}(\mu_X, \sigma_X^2)$ und $Y \sim \mathsf{N}(\mu_Y, \sigma_Y^2)$ unabhängig, so gilt

$$X + Y \sim \mathsf{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2).$$

- Die Dichte ist **symmetrisch** um μ, d. h.

$$\varphi(\mu - x) = \varphi(\mu + x), \quad x \in \mathbb{R}.$$

  Insbesondere gilt für $\mu = 0$: $\varphi(-x) = \varphi(x)$.

- **Standardisierung**:

$$X \text{ ist } \mathsf{N}(\mu,\sigma^2)\text{-verteilt.} \iff \frac{X-\mu}{\sigma} \text{ ist } \mathsf{N}(0,1)\text{-verteilt.}$$
$$Y \text{ ist } \mathsf{N}(0,1)\text{-verteilt.} \iff \mu + \sigma Y \text{ ist } \mathsf{N}(\mu,\sigma^2)\text{-verteilt.}$$

- Es gilt für $\mu = 0$: $\mathsf{N}(-x) = 1 - \mathsf{N}(x)$

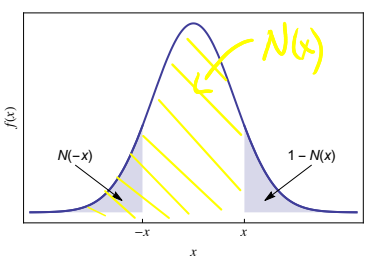

- Wahrscheinlichkeit, dass eine $\mathsf{N}(\mu,\sigma^2)$-verteilte Zufallsvariable Werte zwischen a und b annimmt:

Verteilungsfunktion der Standardnormalverteilung

$$\mathbb{P}(a \le X \le b) = \mathbb{P}\left(\frac{a-\mu}{\sigma} \le \underbrace{\frac{X-\mu}{\sigma}}_{\sim N(0,1)} \le \frac{b-\mu}{\sigma}\right) = \mathsf{N}_{0,1}\left(\frac{b-\mu}{\sigma}\right) - \mathsf{N}_{0,1}\left(\frac{a-\mu}{\sigma}\right).$$

  Hierbei bezeichnet $\mathsf{N}_{0,1}$ die Verteilungsfunktion der Standardnormalverteilung.

Beispiel 2.9.15. *Normalverteilung*

- *Es sei X eine* $\mathsf{N}(\overset{=\mu}{1{,}5}; \overset{=\sigma^2}{2})$*-verteilte Zufallsvariable. Dann gilt:*

mu	sig2
1,5	2

	a	b
	1	2,25
	(a-mu)/sig	(b-mu)/sig
Standardisie	-0,3536	0,5303
N_01	0,3618368	0,70205845
P(a<=X<=b)	0,3402	

(a) $\mathbb{P}(1 \le X \le 2{,}25) = \mathbb{P}\left(\frac{1-1{,}5}{\sqrt{2}} \le \frac{X-1{,}5}{\sqrt{2}} \le \frac{2{,}25-1{,}5}{\sqrt{2}}\right) = N_{01}\left(\frac{2{,}25-1{,}5}{\sqrt{2}}\right) - N_{01}\left(\frac{1-1{,}5}{\sqrt{2}}\right)$ $\sim N(0;1)$

$= N_{01}(0{,}5303) - \underbrace{N_{01}(-0{,}3536)}_{1-N_{01}(0{,}3536)} = 0{,}7019 - (1 - 0{,}6368) = \underline{0{,}3387}$

(b) $\mathbb{P}(X \ge -2{,}5) =$

$= 1 - \mathbb{P}(X < -2{,}5) = 1 - N_{01}\left(\frac{-2{,}5-1{,}5}{\sqrt{2}}\right) = \cancel{1} - \underbrace{N_{01}(-2{,}8284)}_{\cancel{1} - N_{01}(2{,}8284)} = \underline{0{,}9977}$

Wahrscheinlichkeiten mit Standardabweichungen (z-Scores)

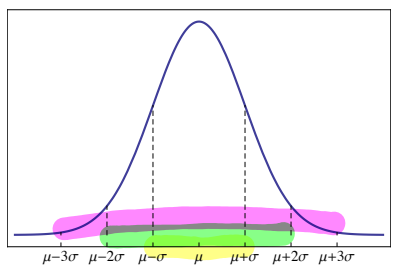

$$\mathbb{P}(|X-\mu| \le \sigma) = 0{,}6827$$
$$\mathbb{P}(|X-\mu| \le 2\sigma) = 0{,}9545$$
$$\mathbb{P}(|X-\mu| \le 3\sigma) = 0{,}9973$$

Beispiel 2.9.16. *Durchschnittliche Temperatur*

- *Zufallsvariable T : 'Durchschnittliche Temperatur in Berlin in Juli' mit Werten $t \in \mathbb{R}$.*
- $\boxed{T \sim N(\overset{=20{,}5}{\mu_T}, \overset{=12}{\sigma_T^2})}$ *mit* $\mu_T = \mathbb{E}(T) = 20{,}5$, $Var(T) = 12$ *und* $\sigma_T \approx 3{,}5$.
- *Wahrscheinlichkeiten:*

$\mathbb{P}(|T - 20{,}5| \le 3{,}5) \cong 0{,}6827$

$\mathbb{P}(|T - 20{,}5| \le 7) \cong 0{,}9545$

$\mathbb{P}(15 \le T \le 25) = \mathbb{P}\left(\frac{15-20{,}5}{\sqrt{12}} \le \frac{T-20{,}5}{\sqrt{12}} \le \frac{25-20{,}5}{\sqrt{12}}\right) = N_{01}\left(\frac{25-20{,}5}{\sqrt{12}}\right) -$

$- N_{01}\left(\frac{15-20{,}5}{\sqrt{12}}\right) = \underline{0{,}8469}$

	mu	sig2
	20,5	12

	a	b
	15	25
N_mu,sig2	0,0562	0,9030
P(a<=X<=b)	0,8469	

Standardnormalverteilung

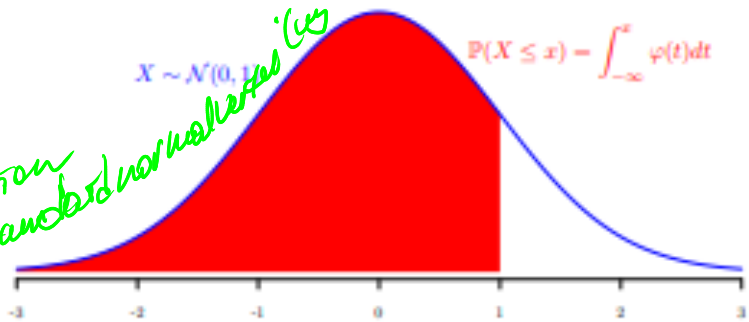

Werte der Verteilungsfunktion der Standardnormalverteilung

Für Werte kleiner als 0 benutze man die Identität: $\mathrm{N}(-x) = 1 - \mathrm{N}(x)$.

	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990

$$E\left(\sum_{i=1}^{n} X_i\right) = E(X_1 + X_2 + \dots + X_n) = \underbrace{E(X_1)}_{\mu} + \underbrace{E(X_2)}_{\mu} + \dots + \underbrace{E(X_n)}_{\mu} = n \cdot \mu$$

$$Var\left(\sum_{i=1}^{n} X_i\right) = Var(X_1 + X_2 + \dots + X_n) = \underbrace{Var(X_1)}_{\sigma^2} + \underbrace{Var(X_2)}_{\sigma^2} + \dots \underbrace{Var(X_n)}_{\sigma^2} = n \cdot \sigma^2$$

2.9.7 Zentraler Grenzwertsatz (ZGS)

- Der **Zentrale Grenzwertsatz** erklärt, warum die Normalverteilung als gute Approximation vieler Variablen in der Praxis dient.
- Es sei $X_1, X_2, \dots$ eine Folge von unabhängigen, identisch verteilten (iid) Zufallsvariablen mit $\mathbb{E}(X_i) = \mu$ und $\mathrm{Var}(X_i) = \sigma^2$, $0 < \sigma^2 < \infty$.
- Der ZGS besagt, dass die folgende standardisierte Summe in Verteilung gegen die Standardnormalverteilung konvergiert:

$$\boxed{\frac{\sum_{i=1}^{n} X_i - n \cdot \mu}{\sqrt{n \cdot \sigma^2}}} = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \frac{X_i - \mu}{\sigma} \to \mathrm{N}(0;1), \quad \text{für } n \to \infty.$$

Verteilung der Summe standardisiert geht mit zunehmendem n gegen die Standardnormalvert.

- Dies impliziert, dass der empirische Erwartungswert von n unabhängigen Wiederholungen eines Experiments **approximativ normalverteilt** ist:

$$\boxed{\frac{1}{n} \sum_{i=1}^{n} X_i \approx \mathrm{N}\left(\mu, \frac{\sigma^2}{n}\right)}.$$

$$E\left(\frac{1}{n}\sum X_i\right) = \frac{1}{n} E\left(\sum X_i\right) = \frac{1}{n} \cdot n \cdot \mu = \mu$$

$$Var\left(\frac{1}{n}\sum X_i\right) = \frac{1}{n^2} \cdot Var\left(\sum X_i\right) = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

- Dieses Aussage ist zentral für viele Resultate der Induktiven Statistik.

Normal-Approximation der Binomialverteilung

- $X \sim B(n,p)$, d. h. X besitzt eine Binomialverteilung mit den Parametern n und p. $\longrightarrow$ $E(X) = n \cdot p$; $Var(X) = n \cdot p(1-p)$
- Mit anderen Worten:

Summe $\longrightarrow$ $X = \sum_{k=1}^{n} X_k$ mit $X_1, \dots, X_n$ iid Bernoulli-verteilten Zufallsvariablen.

- Falls n hinreichend groß ist, besagt der ZGS:[2]

$$\boxed{\frac{X - np}{\sqrt{np(1-p)}}} \text{ ist approximativ } \mathrm{N}(0;1)\text{-normalverteilt.}$$

- Approximation der Binomialwahrscheinlichkeiten:

$$\mathbb{P}(a \le X \le b) \approx \mathrm{N}_{0,1}\left(\frac{b - np}{\sqrt{np(1-p)}}\right) - \mathrm{N}_{0,1}\left(\frac{a - np}{\sqrt{np(1-p)}}\right)$$

[2] $\mathbb{E}X = np$, $\mathrm{Var}(X) = np(1-p)$ und die standardisierte Variable hat Erwartungswert 0 und Varianz 1.

2.9.8 Chi-Quadrat-Verteilung und Student-t-Verteilung

- Viele Teststatistiken besitzen, vor allem für sogenannte Anpassungstests, unter geeigneten Voraussetzungen zumindest approximativ eine Chi-Quadrat-Verteilung.

"chi"

χ^2-Verteilung. Seien $X_1, \dots, X_n$ unabhängige und identisch $\mathsf{N}(0,1)$-verteilte Zufallsvariablen. Dann heißt die Verteilung der Zufallsvariablen

$$Z = X_1^2 + \cdots + X_n^2$$

Parameter: Freiheitsgrade

Chi-Quadrat-Verteilung mit n Freiheitsgraden, kurz $\chi^2(n)$-Verteilung, und Z heißt χ^2-verteilt, kurz $Z \sim \chi^2(n)$.

Es gilt:

$$\mathbb{E}(Z) = n \quad \text{und} \quad \mathrm{Var}(Z) = 2n.$$

Ausblick:
empir. Varianz:
$\hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$
$\frac{(n-1)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$

Beispiel 2.9.18. *Studierende aus 1.10.7*

- *Zur Grundgesamtheit der HWR-Studierenden liegt zu den Merkmalen*
  - A = *Fitnessgrad mit den Ausprägungen* s = *sportlich und* u = *unsportlich*
  - B = *Examensnote mit den Ausprägungen* e = *exzellent,* g = *gut und* a = *ausreichend*

  eine Stichprobe zum Umfang $n = 200$ *mit absoluter Häufigkeitsverteilung vor:*

H	$b_1 = e$	$b_2 = g$	$b_3 = a$	$H_{j\cdot}$
$a_1 = s$	14	72	34	120
$a_2 = u$	12	55	13	80
$H_{\cdot k}$	26	127	47	200

U	b_1	b_2	b_3
a_1	15,6	76,2	28,2
a_2	10,4	50,8	18,8

- *Damit berechnen wir:*

$$\hat{\chi}^2 = \frac{(14-15{,}6)^2}{15{,}6} + \frac{(72-76{,}2)^2}{76{,}2} + \cdots + \frac{(13-18{,}8)^2}{18{,}8} = \underline{3{,}9713.}$$

χ^2-Kennzahl: Zusammenhang zw. nominalskalierten Merkmalen

Bei Unabhängigkeit ist $\chi^2 \sim \chi^2(5)$ *und* $\mathbb{P}(\chi^2 > \hat{\chi}^2) = 0{,}55 \rightsquigarrow$ **statistisches Testen**

Verteilung der χ^2-Kennzahl über alle Stichproben

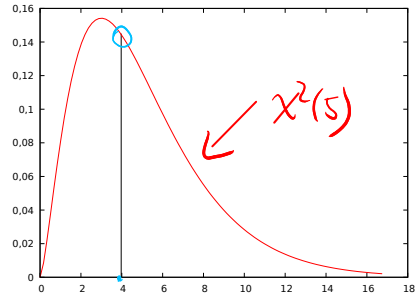

$\hat{\chi}^2 = \underline{3{,}9713}$

Student-t-Verteilung.

- Die t-Verteilung spielt eine Rolle in der Test-Theorie und bei der Festsetzung von Konfidenzintervallen.

Es seien $X \sim \mathsf{N}(0,1)$ und $Z \sim \chi^2(n)$ unabhängig. Dann besitzt die Zufallsvariable

$$T = \frac{X}{\sqrt{Z/n}}$$

eine **t-Verteilung** mit n Freiheitsgraden, symbolisch $T \sim t(n)$.
Eigenschaften:

$$\mathbb{E}(T) = 0 \quad (n > 1) \quad \text{und} \quad \mathrm{Var}(T) = \frac{n}{n-2} \quad (n > 2).$$

- Verschiedene t-Verteilungen:

Ausblick:

$$\frac{\bar{X} - \mu}{\frac{\hat{\sigma}}{\sqrt{n}}} \sim t(n-1)$$

empir. Standardabw.

Stichprobenumfang

t-Verteilung:

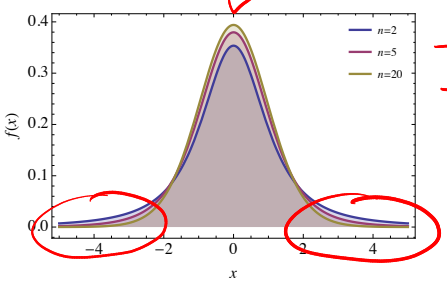

- symmetrisch
- mehr Wkt an den Rändern im Vergleich zu der Normalverteilung
- wenn n groß (n > 30) konvergiert gegen die Standardnormalverteilung

- Im Vergleich zur Normalverteilung hat die t-Verteilung mehr Wahrscheinlichkeitsmasse auf extremen Werten (heavy tails).

- Für $n \to \infty$ konvergiert die Dichte der t-Verteilung gegen die Dichte der Standardnormalverteilung.

Beispiel 2.9.19. *Lineare Regression aus 1.11.1, Seite 67*

- *Merkmale:*
  - U = *Umsatz pro Kunde mit Werten* $u \in \mathbb{R}^+$
  - T = *durchschnittliche Temperatur mit Werten* $\mathsf{temp} \in \mathbb{R}$.

  (Daten aus 1.10.1, Seite 53)

- *Bestimme die Regressionsgerade* $u = a + b \cdot \mathsf{temp}$.

- *Lösung:* $\hat{b} = 1.23$ *und* $\hat{a} = 5.12$

"Umsatzformel"

- *Umsatzfunktion:* $u = 5.12 + 1.23 \cdot temp$, *für* $9 \leq temp \leq 25$.
- **Können wir auch $b = 1$ setzen? $\rightsquigarrow$ statistisches Testen**
- *Modell:* $u_i = a + b \cdot temp_i + \varepsilon_i, \quad i = 1, \ldots, n$
- *unter der Annahme, dass die Fehlerterme normalverteilt sind, ist* $\hat{b} \sim N(b, \sigma^2_{\hat{b}})$.

- *wenn wir vermuten, dass* $b = 1$: $\hat{b} \sim N(1, \sigma^2_{\hat{b}})$.
- *Man kann zeigen, dass* $(n-2)\sigma^2_{\hat{b}} \sim \chi^2(n-2)$ *und somit:*

$$T = \frac{\hat{b} - 1}{\sigma_{\hat{b}}} \sim t(n-2)$$

- *Konret:* $t = \frac{1{,}23 - 1}{0.18} = 1{,}28$.
- $\mathbb{P}(T > t) = 0{,}12$.

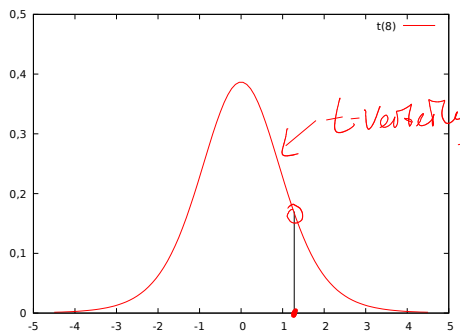

t-Verteilung

t=1,28

Ergebnis anhand nur einer Stichprobenrealisierung

Verteilung des standardisierten Schätzers über alle Stichproben